پاسخ مسئله‌ی ۱.

بخش اول

آ

برای $f : \mathbb{R}^n \to \mathbb{R}^m$، $g : \mathbb{R}^m \to \mathbb{R}^k$ و $h(x) = g(f(x))$، طبق قاعده زنجیره‌ای برای ژاکوبین داریم:

$$J_h(x) = J_g\big(f(x)\big)\ J_f(x)$$

که در آن $J_f(x) \in \mathbb{R}^{m\times n}$، $J_g(f(x)) \in \mathbb{R}^{k\times m}$ و بنابراین $J_h(x) \in \mathbb{R}^{k\times n}$.

ب

فرض کنید $f(x) = \mathrm{ReLU}(Ax + b)$ و $g(z) = Cz$.

۱. داریم:

$$h(x) = g(f(x)) = C\,\mathrm{ReLU}(Ax + b)$$

۲. اگر $u = Ax + b \in \mathbb{R}^m$، آنگاه $J_g(z) = C$ و $J_f(x) = D(u)\,A$ که در آن $D(u)$ یک ماتریس قطری است. پس:

$$J_h(x) = J_g(f(x))\,J_f(x) = C\,D(Ax + b)\,A$$

۳. مشتق ReLU را می‌توان به صورت ماتریس قطری زیر نوشت:

$$D(u) = \mathrm{diag}\big(r_1, \ldots, r_m\big), \qquad r_i = \frac{\partial\,\mathrm{ReLU}(u_i)}{\partial u_i} = \begin{cases} 1 & u_i > 0 \\ 0 & u_i < 0 \end{cases}$$

(در نقطه $u_i = 0$ مشتق کلاسیک تعریف نشده و می‌توان یکی از زیرگرادیان‌ها در بازه $[0, 1]$ را انتخاب کرد.)

ج

فرض کنید $f(x) = \mathrm{Softmax}(Ax + b)$ و $g(z) = Cz$. بگذارید $z = Ax + b$ و $s = \mathrm{Softmax}(z)$.

۱. تابع ترکیبی:

$$h(x) = g(f(x)) = C\,\mathrm{Softmax}(Ax + b) = C\,s$$

۲. برای محاسبه ژاکوبین Softmax:

$$s_i = \frac{e^{z_i}}{\sum_{t=1}^{m} e^{z_t}}$$
$$\frac{\partial s_i}{\partial z_j} = \frac{\partial}{\partial z_j}\left(\frac{e^{z_i}}{\sum_t e^{z_t}}\right) = \frac{\delta_{ij} e^{z_i}\left(\sum_t e^{z_t}\right) - e^{z_i} e^{z_j}}{\left(\sum_t e^{z_t}\right)^2} = \frac{e^{z_i}}{\sum_t e^{z_t}}\left(\delta_{ij} - \frac{e^{z_j}}{\sum_t e^{z_t}}\right)$$
$$= s_i(\delta_{ij} - s_j)$$

پس ژاکوبین به صورت ماتریسی نیز برابر است با:

$$J_{\mathrm{Softmax}}(z) = \mathrm{diag}(s) - s\,s^\top \in \mathbb{R}^{m\times m}$$

۳. با قاعده زنجیره‌ای:

$$J_h(x) = J_g(f(x))\,J_f(x) = C\;J_{\mathrm{Softmax}}(Ax+b)\;A$$
$$= C\Big(\mathrm{diag}(s) - ss^\top\Big)A, \qquad s = \mathrm{Softmax}(Ax+b)$$

که اندازه آن $k \times n$ است.

بخش دوم

آ

چون $z = Wx + b$، ژاکوبین z نسبت به x برابر است با:

$$\frac{\partial z}{\partial x} = W \in \mathbb{R}^{m\times n}$$

ب

داریم $L = \frac{1}{2}\|z-y\|^2 = \frac{1}{2}(z-y)^\top(z-y)$، پس:

$$\nabla_z L = z - y$$
$$\nabla_b L = \nabla_z L \cdot \frac{\partial z}{\partial b} = (z-y)\cdot I_m = z - y \in \mathbb{R}^m$$

ج

$$\nabla_x L = \left(\frac{\partial z}{\partial x}\right)^\top \nabla_z L = W^\top (z - y) \in \mathbb{R}^n$$

د

برای مشتق نسبت به W:

$$\nabla_W L = (z - y)\, x^\top \in \mathbb{R}^{m \times n}$$

پاسخ مسئله‌ی ۲.

۱. برای یک نمونه منفرد $x^{(i)} \in \mathbb{R}^{D_x \times ۱}$ و با توجه به اینکه $\hat{y}^{(i)}$ اسکالر است:

$$W_۱ \in \mathbb{R}^{D_{a۱} \times D_x}, \qquad b_۱ \in \mathbb{R}^{D_{a۱} \times ۱},$$
$$W_۲ \in \mathbb{R}^{۱ \times D_{a۱}}, \qquad b_۲ \in \mathbb{R}^{۱ \times ۱}.$$

در حالت vectorized، ابعاد وزن‌ها و بایاس‌ها تغییری نمی‌کند و فقط داده‌ها به‌صورت ماتریسی وارد می‌شوند:

$$X \in \mathbb{R}^{D_x \times m}, \qquad Y \in \mathbb{R}^{۱ \times m},$$

و در این حالت:

$$Z_۱ = W_۱ X + b_۱ \in \mathbb{R}^{D_{a۱} \times m}, \quad A_۱ = \tanh(Z_۱) \in \mathbb{R}^{D_{a۱} \times m}, \quad Z_۲ = W_۲ A_۱ + b_۲ \in \mathbb{R}^{۱ \times m}.$$

(در جمع با $b_۱, b_۲$، عمل broadcast روی m ستون انجام می‌شود.)

۲. با توجه به $J = \frac{۱}{m} \sum_{i=۱}^{m} \frac{۱}{۲} (\hat{y}^{(i)} - y^{(i)})^۲$، داریم:

$$\delta_۱^{(i)} = \frac{\partial J}{\partial \hat{y}^{(i)}} = \frac{۱}{m} \left(\hat{y}^{(i)} - y^{(i)} \right).$$

۳. چون $\hat{y}^{(i)} = z_۲$:

$$\delta_۲^{(i)} = \frac{\partial \hat{y}^{(i)}}{\partial z_۲} = ۱.$$

۴. چون $z_۲ = W_۲ a_۱ + b_۲$:

$$\delta_۳^{(i)} = \frac{\partial z_۲}{\partial a_۱} = W_۲ \quad \in \mathbb{R}^{۱ \times D_{a۱}}.$$

۵. چون $a_۱ = \tanh(z_۱)$ به‌صورت مؤلفه‌ای است:

$$\delta_۴^{(i)} = \frac{\partial a_۱}{\partial z_۱} = \operatorname{diag}\Big(۱ - \tanh^۲(z_۱) \Big) = \operatorname{diag}\Big(۱ - a_۱ \odot a_۱ \Big) \quad \in \mathbb{R}^{D_{a۱} \times D_{a۱}}.$$

۶. چون $z_۱ = W_۱ x^{(i)} + b_۱$، مشتق نسبت به $W_۱$ به‌صورت مؤلفه‌ای:

$$\delta_۵^{(i)} : \qquad \frac{\partial (z_۱)_p}{\partial (W_۱)_{pq}} = x_q^{(i)}, \qquad ۱ \le p \le D_{a۱}, \ ۱ \le q \le D_x.$$

(یعنی برای هر سطرِ $W_۱$، حساسیت همان سطر از $z_۱$ نسبت به آن سطر از $W_۱$ برابر $(x^{(i)})^\top$ است.)

۷. ابتدا گرادیان‌های میانی را می‌نویسیم (با دقت به ابعاد):

$$\frac{\partial J}{\partial z_۲} = \frac{\partial J}{\partial \hat{y}^{(i)}} \frac{\partial \hat{y}^{(i)}}{\partial z_۲} = \delta_۱^{(i)} \delta_۲^{(i)} = \frac{۱}{m} \left(\hat{y}^{(i)} - y^{(i)} \right) \quad \in \mathbb{R},$$
$$\frac{\partial J}{\partial a_۱} = \left(\frac{\partial z_۲}{\partial a_۱} \right)^\top \frac{\partial J}{\partial z_۲} = W_۲^\top \frac{\partial J}{\partial z_۲} \quad \in \mathbb{R}^{D_{a_۱} \times ۱},$$
$$\frac{\partial J}{\partial z_۱} = \left(\frac{\partial a_۱}{\partial z_۱} \right) \frac{\partial J}{\partial a_۱} = (۱ - a_۱ \odot a_۱) \odot \left(W_۲^\top \frac{\partial J}{\partial z_۲} \right) \quad \in \mathbb{R}^{D_{a_۱} \times ۱}.$$

حال با استفاده از $z_۱ = W_۱ x^{(i)} + b_۱$ نتیجه می‌گیریم:

$$\frac{\partial J}{\partial W_۱} = \frac{\partial J}{\partial z_۱} (x^{(i)})^\top = \left[\left(۱ - a_۱^{(i)} \odot a_۱^{(i)} \right) \odot \left(W_۲^\top \frac{۱}{m} (\hat{y}^{(i)} - y^{(i)}) \right) \right] (x^{(i)})^\top \quad \in \mathbb{R}^{D_{a_۱} \times D_x}.$$

و برای کل داده‌ها:

$$\nabla_{W_۱} J = \sum_{i=۱}^{m} \frac{\partial J}{\partial W_۱} \Big|_{(i)} = \frac{۱}{m} \sum_{i=۱}^{m} \left[\left(۱ - a_۱^{(i)} \odot a_۱^{(i)} \right) \odot \left(W_۲^\top (\hat{y}^{(i)} - y^{(i)}) \right) \right] (x^{(i)})^\top.$$

پاسخ مسئله‌ی ۳.

تابع $f(x,y) = ۵۰x^۲ + y^۲$ یک تابع درجه‌دو محدب با انحنای متفاوت در دو راستا است. ژاکوبین/گرادیان و هسین آن:

$$\nabla f(x,y) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} ۱۰۰x \\ ۲y \end{bmatrix}, \qquad \nabla^۲ f(x,y) = \begin{bmatrix} ۱۰۰ & ۰ \\ ۰ & ۲ \end{bmatrix}.$$

- Gradient Descent

(الف)

$$\nabla f(x,y) = \begin{bmatrix} ۱۰۰x \\ ۲y \end{bmatrix}.$$

(ب) چون هسین قطری است، بیشترین انحنا در راستای x برابر ۱۰۰ و در راستای y برابر ۲ است (مسئله بدشرط با نسبت ۵۰ = ۱۰۰/۲). برای پایداری GD روی تابع درجه‌دو، نرخ یادگیری ثابت باید با بزرگ‌ترین مقدار ویژه سازگار باشد:

$$۰ < \eta < \frac{۲}{L}, \qquad L = \lambda_{\max}(\nabla^۲ f) = ۱۰۰ \quad \Rightarrow \quad \eta < ۰/۰۲.$$

اگر η را به‌اندازه‌ای بزرگ بگیریم که در راستای y سریع باشد، در راستای x نوسان/واگرایی رخ می‌دهد؛ اگر هم η را کوچک کنیم تا x پایدار شود، حرکت در راستای y بسیار کند می‌شود.

(ج) با $\eta = ۰/۱$ و $(x_۰, y_۰) = (۱, ۱)$:

$$\nabla f(x_۰, y_۰) = (۱۰۰, ۲),$$
$$x_۱ = x_۰ - \eta(۱۰۰x_۰) = ۱ - ۰/۱(۱۰۰) = -۹,$$
$$y_۱ = y_۰ - \eta(۲y_۰) = ۱ - ۰/۱(۲) = ۰/۸.$$

تکرار دوم:

$$\nabla f(x_۱, y_۱) = (۱۰۰(-۹), ۲(۰/۸)) = (-۹۰۰, ۱/۶),$$
$$x_۲ = x_۱ - \eta(۱۰۰x_۱) = -۹ - ۰/۱(-۹۰۰) = ۸۱,$$
$$y_۲ = y_۱ - \eta(۲y_۱) = ۰/۸ - ۰/۱(۱/۶) = ۰/۶۴.$$

می‌بینیم x بین مقادیر بزرگ با علامت متناوب می‌پرد (نوسان شدید و واگرایی)، که همان مشکل بخش (ب) است.

- AdaGrad

(الف) در این تابع، گرادیان مؤلفه x معمولاً بسیار بزرگ‌تر از y است (به‌خاطر ضریب ۱۰۰ در مشتق). AdaGrad با جدا کردن نرخ یادگیری برای هر پارامتر، گام مؤثر x را کوچک و گام مؤثر y را بزرگ‌تر نگه می‌دارد؛ بنابراین با ناهمسانگردی (تفاوت انحنا/مقیاس) بهتر کنار می‌آید.

(ب) در گام اول با $(x_0, y_0) = (1, 1)$ داریم:

$$g_x^{(1)} = 100, \qquad g_y^{(1)} = 2.$$

پس (با $\epsilon = 10^{-8}$):

$$\eta_x^{(1)} = \frac{0.1}{\sqrt{(100)^2 + 10^{-8}}} \approx \frac{0.1}{100} = 0.001,$$
$$\eta_y^{(1)} = \frac{0.1}{\sqrt{(2)^2 + 10^{-8}}} \approx \frac{0.1}{2} = 0.05.$$

(ج) در AdaGrad مخرج $\sqrt{\sum_{j=1}^{k} (g_i^{(j)})^2}$ با k رشد می‌کند، بنابراین $\eta_i^{(k)}$ به‌مرور کاهش می‌یابد و گام‌ها کوچک‌تر می‌شوند؛ اثر آن این است که الگوریتم می‌تواند در بلندمدت خیلی کند شود (به‌خصوص اگر گرادیان‌ها در ابتدا بزرگ باشند).

- RMSProp

(الف) AdaGrad مجموع کل مربع گرادیان‌ها را جمع می‌کند و نرخ یادگیری را یکنواخت به سمت صفر می‌برد. RMSProp به‌جای جمع کل، از میانگین متحرک نمایی استفاده می‌کند:

$$s_{k+1} = \gamma s_k + (1 - \gamma) g_k^2,$$

بنابراین «حافظه محدود» دارد و نرخ یادگیری خیلی سریع به صفر میل نمی‌کند. یک مزیت واضح: جلوگیری از کوچک شدنِ دائمی نرخ یادگیری و سازگاری بهتر با گرادیان‌های اخیر.

(ب) در RMSProp پارامتر γ میزان حافظه/هموارسازی در تخمینِ مرتبه دوم (میانگین متحرک g^2) را کنترل می‌کند. در Momentum پارامتر β میزان حافظه/هموارسازی در سرعت (میانگین متحرک گرادیان‌ها) را کنترل می‌کند؛ یعنی β روی جهت حرکت (مرتبه اول) اثر می‌گذارد، ولی γ روی مقیاس تطبیقی گام (مرتبه دوم) اثر دارد.

- Adam

(الف) در Adam:

m_k : میانگین متحرک گرادیان (مرتبه اول، شبیه Momentum),

v_k : میانگین متحرک مربع گرادیان (مرتبه دوم، شبیه RMSProp/AdaGrad).

(ب) چون معمولاً $m_0 = v_0 = 0$ مقداردهی اولیه می‌شوند، در چند گام اول m_k و v_k به سمت صفر بایاس دارند (کم‌برآورد می‌شوند). تصحیح بایاس با تقسیم بر $(1 - \beta_1^k)$ و $(1 - \beta_2^k)$ این کم‌برآوردی را جبران می‌کند؛ بدون آن، در تکرارهای ابتدایی به‌روزرسانی‌ها بیش از حد کوچک می‌شوند و شروع یادگیری کند می‌شود.

(ج) برای $f(x, y) = 50x^2 + y^2$ انتظار می‌رود Adam بهتر از GD ساده عمل کند چون:

* گام‌ها را به‌صورت جداگانه برای x و y مقیاس می‌کند (به‌خاطر v_k)، پس در راستای x از جهش/نوسان می‌کاهد.
* با m_k (اثر Momentum) نوسان‌های رفت‌وبرگشتی را هموار می‌کند و همگرایی را در دره‌های کشیده سریع‌تر می‌کند.

پاسخ مسئله‌ی ۴.

در ادامه بگذارید $g_k := \nabla E(w^{(k)})$ و $H_k := \nabla^2 E(w^{(k)})$ و $p^{(k)} = -H_k^{-1} g_k$ باشد؛ لذا $w^{(k+1)} = w^{(k)} + p^{(k)}$.

الف

از تعریف گام نیوتون داریم:

$$g_k + H_k p^{(k)} = \nabla E(w^{(k)}) - \nabla^2 E(w^{(k)}) \nabla^2 E(w^{(k)})^{-1} \nabla E(w^{(k)}) = 0.$$

پس:

$$\begin{aligned}
\|\nabla E(w^{(k+1)})\| &= \|\nabla E(w^{(k+1)}) - 0\| \\
&= \|\nabla E(w^{(k+1)}) - (g_k + H_k p^{(k)})\| \\
&= \|\nabla E(w^{(k+1)}) - \nabla E(w^{(k)}) - \nabla^2 E(w^{(k)}) p^{(k)}\|.
\end{aligned}$$

ب

طبق بسط تیلورِ انتگرالی برای گرادیان (با $x = w^{(k)}$ و $p = p^{(k)}$):

$$\nabla E(w^{(k+1)}) = \nabla E(w^{(k)} + p^{(k)}) = g_k + \int_0^1 \nabla^2 E(w^{(k)} + t p^{(k)})\, p^{(k)}\, dt.$$

بنابراین:

$$\nabla E(w^{(k+1)}) - g_k - H_k p^{(k)} = \int_0^1 \Big(\nabla^2 E(w^{(k)} + t p^{(k)}) - H_k\Big) p^{(k)}\, dt.$$

اکنون با استفاده از خواص نُرم و انتگرال:

$$\begin{aligned}
\|\nabla E(w^{(k+1)})\| &= \|\nabla E(w^{(k+1)}) - g_k - H_k p^{(k)}\| \\
&\le \int_0^1 \Big\| \big(\nabla^2 E(w^{(k)} + t p^{(k)}) - H_k\big) p^{(k)} \Big\|\, dt \\
&\le \int_0^1 \|\nabla^2 E(w^{(k)} + t p^{(k)}) - H_k\| \cdot \|p^{(k)}\|\, dt.
\end{aligned}$$

ج

با فرض Lـ لیپشیتز بودن هسیان:

$$\|\nabla^2 E(w^{(k)} + t p^{(k)}) - H_k\| \le L \|t p^{(k)}\| = L t \|p^{(k)}\|.$$

جایگذاری در نامساوی بخش قبل:

$$\|\nabla E(w^{(k+1)})\| \le \int_0^1 (Lt\|p^{(k)}\|)\|p^{(k)}\|\,dt = L\|p^{(k)}\|^2 \int_0^1 t\,dt = \frac{L}{2}\|p^{(k)}\|^2.$$

از طرفی $\|p^{(k)}\| = \|H_k^{-1} g_k\| \le \|H_k^{-1}\| \cdot \|g_k\|$، پس:

$$\|\nabla E(w^{(k+1)})\| \le \frac{1}{2} L \|H_k^{-1}\|^2 \cdot \|\nabla E(w^{(k)})\|^2.$$

د

اگر $\|H_k^{-1}\| \le 2\|(\nabla^2 E(w^*))^{-1}\|$ در توپِ شعاع r برقرار باشد، آنگاه از نتیجه بخش (ج):

$$\begin{aligned}\|\nabla E(w^{(k+1)})\| &\le \frac{1}{2} L \big(2\|(\nabla^2 E(w^*))^{-1}\|\big)^2 \|\nabla E(w^{(k)})\|^2 \\ &= 2L\|(\nabla^2 E(w^*))^{-1}\|^2 \cdot \|\nabla E(w^{(k)})\|^2.\end{aligned}$$

این رابطه نشان می‌دهد اگر به اندازه کافی نزدیک w^* شروع کنیم، نُرم گرادیان‌ها به صفر میل می‌کند (همگرایی به نقطه مانا w^*)، و همچنین نرخ همگرایی برای نُرم گرادیان‌ها درجه دو است؛ یعنی در همسایگی w^* داریم:

$$\|\nabla E(w^{(k+1)})\| \le C\,\|\nabla E(w^{(k)})\|^2, \qquad C = 2L\|(\nabla^2 E(w^*))^{-1}\|^2,$$

پس خطا (به معنای $\|\nabla E(\cdot)\|$) در هر گام تقریباً به توان دو گام قبل کاهش می‌یابد.

پاسخ مسئله‌ی ۵.

۱. جمع توابع لیپشیتز

فرض کنید $f, g : \mathbb{R}^n \to \mathbb{R}^m$ به‌ترتیب L_fـ لیپشیتز و L_gـ لیپشیتز باشند و $h(x) = f(x) + g(x)$. برای هر x_1, x_2 داریم:

$$\begin{aligned}\|h(x_1) - h(x_2)\| &= \|f(x_1) + g(x_1) - f(x_2) - g(x_2)\| \\ &\le \|f(x_1) - f(x_2)\| + \|g(x_1) - g(x_2)\| \\ &\le L_f\|x_1 - x_2\| + L_g\|x_1 - x_2\| = (L_f + L_g)\|x_1 - x_2\|.\end{aligned}$$

پس h لیپشیتز است و یک کران بالا برای ثابت لیپشیتز آن:

$$L_h \le L_f + L_g.$$

۲. ترکیب توابع لیپشیتز

(الف) اثبات خاصیت ترکیب

فرض کنید $g : \mathbb{R}^n \to \mathbb{R}^m$، L_gـ لیپشیتز و $f : \mathbb{R}^m \to \mathbb{R}^k$، L_fـ لیپشیتز باشد و $h(x) = f(g(x))$. برای هر x_1, x_2:

$$\begin{aligned}\|h(x_1) - h(x_2)\| &= \|f(g(x_1)) - f(g(x_2))\| \le L_f\|g(x_1) - g(x_2)\| \\ &\le L_f\, L_g\, \|x_1 - x_2\|.\end{aligned}$$

پس h لیپشیتز است و:

$$L_h \le L_f L_g.$$

(ب) کران ثابت لیپشیتز یک لایه

لایه را به صورت $f_k(x) = \sigma(W_k x)$ در نظر بگیرید که σ، L_σـ لیپشیتز است. می‌دانیم نگاشت خطی $T(x) = W_k x$ نسبت به نُرم اقلیدسی $L_T = \|W_k\|_2$ـ لیپشیتز است، یعنی:

$$\|W_k x_1 - W_k x_2\| \le \|W_k\|_2 \|x_1 - x_2\|.$$

اکنون با استفاده از خاصیت ترکیب:

$$\begin{aligned}\|f_k(x_1) - f_k(x_2)\| &= \|\sigma(W_k x_1) - \sigma(W_k x_2)\| \le L_\sigma\|W_k x_1 - W_k x_2\| \\ &\le L_\sigma\|W_k\|_2\|x_1 - x_2\|.\end{aligned}$$

پس ثابت لیپشیتز لایه با رابطه زیر کران‌دار است:

$$L_k \le L_\sigma \cdot \|W_k\|_۲.$$

۳. ارتباط با مشتق (یک‌بعدی)

فرض کنید $f : \mathbb{R} \to \mathbb{R}$ مشتق‌پذیر باشد.

- اگر f، Lـ لیپشیتز باشد، برای هر x و هر $h \neq ۰$ داریم:

$$\left|\frac{f(x+h)-f(x)}{h}\right| \le L.$$

با گرفتن حد وقتی $h \to ۰$ نتیجه می‌شود:

$$|f'(x)| \le L \qquad \forall x.$$

- برعکس، اگر برای همه x داشته باشیم $|f'(x)| \le L$، آنگاه برای هر $x_۱ \neq x_۲$ طبق قضیه مقدار میانگین، عددی c بین $x_۱$ و $x_۲$ وجود دارد به‌طوری که:

$$f(x_۱)-f(x_۲) = f'(c)(x_۱-x_۲) \;\Rightarrow\; |f(x_۱)-f(x_۲)| = |f'(c)|\,|x_۱-x_۲| \le L|x_۱-x_۲|.$$

پس f، Lـ لیپشیتز است.

در نتیجه:

$$f \text{ لیپشیتز با ثابت } L \iff |f'(x)| \le L \quad \forall x.$$

پاسخ مسئله‌ی ۶.

فرض کنید $X \in \mathbb{R}^{n\times d}$ و $X^TX = nI$ و ستون iام برابر $x_{*i} \in \mathbb{R}^n$ است.

۱

$$\begin{aligned}
J_۱(w) &= \|Xw - y\|^۲ + \lambda\|w\|_۱ \\
&= (Xw-y)^T(Xw-y) + \lambda\sum_{i=۱}^{d}|w_i| \\
&= w^TX^TXw - ۲y^TXw + \|y\|^۲ + \lambda\sum_{i=۱}^{d}|w_i| \\
&= n\|w\|^۲ - ۲\sum_{i=۱}^{d} w_i\, x_{*i}^Ty + \|y\|^۲ + \lambda\sum_{i=۱}^{d}|w_i| \\
&= \|y\|^۲ + \sum_{i=۱}^{d}\Big(nw_i^۲ - ۲w_i(x_{*i}^Ty) + \lambda|w_i|\Big).
\end{aligned}$$

پس می‌توان نوشت:

$$J_۱(w) = \|y\|^۲ + \sum_{i=۱}^{d} f(x_{*i}, w_i), \qquad f(x_{*i}, w_i) \triangleq nw_i^۲ - ۲w_i(x_{*i}^Ty) + \lambda|w_i|.$$

۲

به‌علت جدایی‌پذیری، برای هر i کافی است

$$\phi_i(w_i) = nw_i^۲ - ۲c_iw_i + \lambda|w_i|, \qquad c_i \triangleq x_{*i}^Ty$$

را کمینه کنیم. شرط لازم و کافی بهینگی (شرط زیرگرادیان):

$$۰ \in \partial\phi_i(w_i) = ۲nw_i - ۲c_i + \lambda\,\partial|w_i|.$$

سه حالت:

- اگر $w_i^* > ۰$، آنگاه $\partial|w_i^*| = \{۱\}$ و:

$$۲nw_i^* - ۲c_i + \lambda = ۰ \;\;\Rightarrow\;\; w_i^* = \frac{c_i - \lambda/۲}{n}, \qquad w_i^* > ۰ \iff c_i > \lambda/۲.$$

- اگر $w_i^* > ۰$، آنگاه $\partial|w_i^*| = \{-۱\}$ و:

$$۲nw_i^* - ۲c_i - \lambda = ۰ \;\Rightarrow\; w_i^* = \frac{c_i + \lambda/۲}{n}, \qquad w_i^* < ۰ \iff c_i < -\lambda/۲.$$

- اگر $w_i^* = ۰$، آنگاه $\partial|۰| = [-۱, ۱]$ و:

$$۰ \in -۲c_i + \lambda[-۱, ۱] \iff |۲c_i| \le \lambda \iff |c_i| \le \lambda/۲.$$

۳

$$J_۲(w) = \|Xw - y\|^۲ + \lambda\|w\|_۲^۲ = w^T X^T X w - ۲y^T X w + \|y\|^۲ + \lambda w^T w$$
$$= (n + \lambda)\|w\|^۲ - ۲\sum_{i=۱}^{d} c_i w_i + \|y\|^۲.$$

شرط بهینگی:

$$\nabla J_۲(w) = ۲(n + \lambda)w - ۲X^T y = ۰ \;\Rightarrow\; w^{\#} = \frac{۱}{n + \lambda} X^T y.$$

پس:

$$w_i^{\#} = ۰ \iff (x_{*i}^T y) = ۰.$$

۴

طبق بخش (۲)، در Lasso اگر $|x_{*i}^T y| \le \lambda/۲$ باشد، دقیقاً $w_i^* = ۰$ می‌شود (آستانه‌گذاری و ایجاد صفر). اما طبق بخش (۳)، در Ridge داریم $w_i^{\#} = \frac{x_{*i}^T y}{n+\lambda}$ و فقط وقتی صفر می‌شود که دقیقاً $x_{*i}^T y = ۰$ باشد. بنابراین معمولاً w^* تُنُک‌تر از $w^{\#}$ است.