پاسخ مسئله‌ی ۱.

الف

برای هموردایی نسبت به انتقال کافی است نشان دهیم جابجایی از کانولوشن خارج می‌شود:

$$\begin{aligned}(T_{a,b}(K * I))(i,j) &= (K * I)(i-a, j-b) \\ &= \sum_{m,n} K(m,n)\, I(i-a-m,\, j-b-n) \\ &= \sum_{m,n} K(m,n)\, (T_{a,b}I)(i-m,\, j-n) \\ &= (K * T_{a,b}I)(i,j).\end{aligned}$$

پس کانولوشن نسبت به انتقال هموردااست.

ب

هر عملگر خطی هموردا نسبت به انتقال، کانولوشن است. کافی است پاسخ عملگر به دلتا را هسته بگیریم:

$$K(m,n) = \mathcal{L}(\delta)(m,n), \qquad \delta(i,j) = \begin{cases} ۱ & i = ۰,\, j = ۰ \\ ۰ & \text{otherwise} \end{cases}$$

با خطی بودن و هموردایی:

$$I(i,j) = \sum_{m,n} I(m,n)\, T_{m,n}\delta(i,j) \Rightarrow \mathcal{L}(I) = \sum_{m,n} I(m,n)\, T_{m,n}\mathcal{L}(\delta) = K * I.$$

نتیجه: طراحی شبکه‌های کانولوشنی دقیقا با اعمال قیود هموردایی (اشتراک وزن‌ها) انجام می‌شود و فضای پارامترها کوچک‌تر و تعمیم بهتر می‌شود.

ج

اگر تصویر به بردار $x \in \mathbb{R}^{HW}$ تبدیل شود، یک عملگر خطی هموردا نسبت به انتقال باید به صورت ماتریس Toeplitz (در دوبعد، block Toeplitz with Toeplitz blocks) باشد، چون هر شیفت خروجی باید با همان شیفت در ورودی متناظر شود و ضرایب وابسته به اختلاف اندیس‌ها هستند. لایه خطی کاملا متصل MLP چنین ساختار ثابتی ندارد و وزن‌ها آزادند، پس به طور کلی هموردایی نسبت به انتقال را تضمین نمی‌کند.

د

برای تشخیص یک الگوی $k \times k$ در هر مکان:

کانولوشنی: $k^۲$ وزن + بایاس۱ $\Rightarrow$ $k^۲ + ۱$.

کاملا متصل: برای هر مکان یک الگو لازم است

$$N_p = (H - k + ۱)(W - k + ۱) \text{مکان}$$

$$\Rightarrow (H - k + ۱)(W - k + ۱)\, k^۲ + (H - k + ۱)(W - k + ۱).$$

پس لایه کانولوشنی به طور چشمگیری پارامترهای کمتری نیاز دارد.

پاسخ مسئله‌ی ۲.

الف

با $\text{padding} = ۱$ و $\text{stride} = ۲$ داریم:

$$H_{out} = \left\lfloor \frac{۵ + ۲ \cdot ۱ - ۳}{۲} \right\rfloor + ۱ = ۳$$

پس $Y \in \mathbb{R}^{۳\times ۳}$ و (با کانولوشنِ رایج در CNN یعنی بدون برگرداندن کرنل):

$$Y = \begin{bmatrix} ۶ & ۵ & ۴ \\ ۳ & ۷ & ۰ \\ ۴ & ۰ & ۸ \end{bmatrix}$$

ب

$$\frac{\partial L}{\partial Y} = Y - T = \begin{bmatrix} ۶ - T_{۱۱} & ۵ - T_{۱۲} & ۴ - T_{۱۳} \\ ۳ - T_{۲۱} & ۷ - T_{۲۲} & -T_{۲۳} \\ ۴ - T_{۳۱} & -T_{۳۲} & ۸ - T_{۳۳} \end{bmatrix}$$

بگذارید $g_{ij} = \frac{\partial L}{\partial Y_{ij}}$.

$$\frac{\partial L}{\partial W} = \begin{bmatrix} g_{۲۲} + ۲g_{۳۳} & ۲g_{۲۱} + ۳g_{۲۲} + ۲g_{۲۳} + ۳g_{۳۱} + g_{۳۲} & g_{۲۱} + ۲g_{۳۲} \\ ۲g_{۱۲} + ۳g_{۱۳} + g_{۲۲} + g_{۲۳} + ۲g_{۳۲} & g_{۱۱} + g_{۱۳} + ۲g_{۲۲} + g_{۲۳} + g_{۳۱} + g_{۳۲} + ۳g_{۳۳} & ۲g_{۱۱} + ۳g_{۱۲} + g_{۲۱} + g_{۲۲} + ۲g_{۳۱} \\ g_{۱۲} + ۲g_{۲۳} & ۲g_{۱۱} + ۳g_{۱۲} + ۲g_{۱۳} + ۳g_{۲۱} + g_{۲۲} & g_{۱۱} + ۲g_{۲۲} \end{bmatrix}$$

در محاسبه $\frac{\partial L}{\partial X}$، به علت $\text{stride} = ۲$ ابتدا G با یک صفر بین سطرها و ستون‌ها رقیق می‌شود و سپس با کرنل چرخیده

$$W^{rot} = \begin{bmatrix} ۰ & ۱ & -۱ \\ ۱ & ۲ & ۰ \\ -۱ & ۰ & ۱ \end{bmatrix}$$

کانولوشن full گرفته می‌شود و به علت $\text{padding} = ۱$ حاشیه حذف می‌گردد. نتیجه:

$$\frac{\partial L}{\partial X} = \begin{bmatrix} ۲g_{۱۱} & g_{۱۲} & ۲g_{۱۲} & g_{۱۳} & ۲g_{۱۳} \\ g_{۲۱} & g_{۱۱} - g_{۱۲} - g_{۲۱} & g_{۲۲} & g_{۱۲} - g_{۱۳} - g_{۲۲} & g_{۲۳} \\ ۲g_{۲۱} & g_{۲۲} & ۲g_{۲۲} & g_{۲۳} & ۲g_{۲۳} \\ g_{۳۱} & g_{۲۱} - g_{۲۲} - g_{۳۱} & g_{۳۲} & g_{۲۲} - g_{۲۳} - g_{۳۲} & g_{۳۳} \\ ۲g_{۳۱} & g_{۳۲} & ۲g_{۳۲} & g_{۳۳} & ۲g_{۳۳} \end{bmatrix}$$

ابعاد گرادیان‌ها به ترتیب $\frac{\partial L}{\partial Y} \in \mathbb{R}^{3\times3}$، $\frac{\partial L}{\partial W} \in \mathbb{R}^{3\times3}$ و $\frac{\partial L}{\partial X} \in \mathbb{R}^{5\times5}$ است؛ stride باعث رقیق شدن گرادیان خروجی و padding باعث حذف حاشیه در گرادیان ورودی می‌شود.

پاسخ مسئله‌ی ۳.

۱) کانولوشن عمقی قابل تفکیک

الف

اندازه خروجی به علت padding برابر $H \times W \times C_{out}$ است. برای هر پیکسل خروجی، $K^۲C_{in}$ ضرب‌وجمع داریم، پس:

$$\text{MACs} = HW\,C_{out}\,C_{in}\,K^۲$$
$$\text{FLOPs} \approx ۲HW\,C_{out}\,C_{in}\,K^۲$$

ب

در Depthwise Separable Convolution ابتدا یک depthwise انجام می‌شود؛ یعنی برای هر کانال ورودی یک فیلتر $K \times K$ مستقل اعمال می‌گردد و تعداد کانال‌ها ثابت می‌ماند. سپس یک pointwise یا کانولوشن ۱×۱ انجام می‌شود تا کانال‌ها با هم ترکیب شده و به C_{out} برسیم. هدف کاهش هزینه و پارامترهاست.

ج

هزینه:

$$\text{Depthwise} : HW\,C_{in}\,K^۲$$
$$\text{Pointwise} : HW\,C_{in}\,C_{out}$$
$$\Rightarrow \text{Total} : HW\,C_{in}\,(K^۲ + C_{out})$$

نسبت به کانولوشن استاندارد:

$$\frac{K^۲ + C_{out}}{C_{out}K^۲} = \frac{۱}{C_{out}} + \frac{۱}{K^۲}.$$

د

بردار پچ را $x \in \mathbb{R}^{k^۲C_{in}}$ بگیرید. در حالت استاندارد:

$$y = Wx, \quad W \in \mathbb{R}^{C_{out} \times k^۲C_{in}}.$$

در حالت تفکیک‌پذیر:

$$x \xrightarrow{D} z \xrightarrow{P} y,$$

که در آن

$$D \in \mathbb{R}^{C_{in} \times k^۲C_{in}} \text{ بلوکی‌ـقطری (هر کانال یک فیلتر)}, \quad P \in \mathbb{R}^{C_{out} \times C_{in}}.$$

پس:

$$W \approx PD.$$

این ضرب دقیقاً همه‌ی ماتریس‌های W را پوشش نمی‌دهد، چون D ساختار بلوکی دارد و $\mathrm{rank}(PD) \le C_{in}$ است. اگر $\mathrm{rank}(P) = \mathrm{rank}(D) = ۳$ آنگاه $\mathrm{rank}(PD) \le ۳$. طبق قضیه Eckart–Young، بهترین تقریب رتبه ۳ در نرم ۲ از تجزیه SVD بدست می‌آید:

$$W \approx W_{۳} = U_{۳}\Sigma_{۳}V_{۳}^{\mathsf{T}}.$$

۲) کانولوشن گروهی

الف

کانولوشن ۱×۱ برای ترکیب کانال‌ها و کاهش بُعد استفاده می‌شود. در GoogLeNet به‌عنوان bottleneck قبل از کانولوشن‌های سنگین، و در ResNet برای هم‌ابعادسازی شاخه‌ها و افزودن غیرخطی‌بودن به کار می‌رود.

ب

ShuffleNet به جای pointwise کامل، از group convolution در کانولوشن ۱×۱ استفاده می‌کند: کانال‌ها به g گروه تقسیم می‌شوند و هر گروه مستقل کانولوشن می‌شود، پس هزینه تقریبا g برابر کمتر می‌شود. سپس با channel shuffle تبادل اطلاعات بین گروه‌ها برقرار می‌گردد.

ج

در کانولوشن گروهی هر خروجی فقط به C_{in}/g ورودی متصل است:

$$\text{MACs} = HW\,C_{out}\,\frac{C_{in}}{g}\,K^{۲}$$
$$\text{FLOPs} \approx ۲HW\,C_{out}\,\frac{C_{in}}{g}\,K^{۲}$$

برای ۱×۱ داریم:

$$HW\,\frac{C_{in}C_{out}}{g},$$

پس هزینه نسبت به حالت کامل به اندازه‌ی g کاهش می‌یابد.

۳) شافل کردن کانال‌ها

الف

قرار دادن چند لایه group convolution پشت سر هم با همان گروه‌بندی باعث می‌شود کانال‌های گروه‌ها با هم مخلوط نشوند؛ در نتیجه شبکه به g زیرشبکه مستقل تبدیل می‌شود و جریان اطلاعات بین گروه‌ها کاهش می‌یابد.

ب

Channel Shuffle خروجی را به‌صورت یک جایگشت کانالی بازآرایی می‌کند تا هر گروه در لایه بعدی از کانال‌های گروه‌های متفاوت تغذیه شود. این عمل مشکل جداسازی گروه‌ها را رفع می‌کند. چون شافل یک تبدیل خطی و معکوس‌پذیر بدون پارامتر است، در پس‌انتشار گرادیان تنها جایگشت معکوس اعمال می‌شود و مانعی برای جریان گرادیان ایجاد نمی‌کند.

پاسخ مسئله‌ی ۴.

بخش اول

الف

با ادغام Conv و BN داریم:

$$
\begin{aligned}
y_c &= \gamma_c \frac{(W_c * X + b_c) - \mu_c}{\sqrt{\sigma_c^2 + \epsilon}} + \beta_c \\
&= (W'_c * X) + b'_c
\end{aligned}
$$

که

$$
\begin{aligned}
W'_c &= \frac{\gamma_c}{\sqrt{\sigma_c^2 + \epsilon}} W_c, \\
b'_c &= \frac{\gamma_c}{\sqrt{\sigma_c^2 + \epsilon}} (b_c - \mu_c) + \beta_c.
\end{aligned}
$$

ب

تبدیل ۱ × ۱ به ۳ × ۳ با صفرکردن همهٔ درایه‌ها به‌جز مرکز:

$$
\tilde{W}_{c_{\text{out}}, c_{\text{in}}, p, q} = \begin{cases} W^{1\times 1}_{c_{\text{out}}, c_{\text{in}}} & (p, q) = (1, 1) \\ 0 & \text{سایر حالات} \end{cases}
$$

ج

برای دو کانولوشن موازی:

$$
\begin{aligned}
W^{(\text{fused})} &= W^{(1)} + W^{(2)}, \\
b^{(\text{fused})} &= b^{(1)} + b^{(2)}.
\end{aligned}
$$

بخش دوم

الف

اگر $C_{\text{in}} = C_{\text{out}} = C$ و stride$= 1$، کرنل شناسه:

$$
W^{\text{id}}_{c,c,1,1} = 1, \quad W^{\text{id}}_{c,c',p,q} = 0 \text{ در غیر این صورت}
$$

و بنابراین $W^{\text{id}} * X = X$.

ب

اگر $C_{\text{in}} \neq C_{\text{out}}$، تعداد کانال‌های خروجی تغییر می‌کند و نگاشت شناسه ممکن نیست. اگر stride> ۱، ابعاد مکانی خروجی $\frac{H}{s} \times \frac{W}{s}$ است و برابر با X نمی‌شود. بنابراین کرنلی برای $W * X = X$ وجود ندارد. در این حالت از Projection Shortcut با کانولوشن ۱×۱ استفاده می‌شود که هم‌ارز شناسه نیست و اطلاعات را خطی ترکیب می‌کند.

ج

پس از ادغام Conv+BN در هر لایه، کرنل‌های $\hat{W}_۱, \hat{W}_۲$ را داریم. کرنل شاخه اصلی:

$$W_{\text{main}} = \hat{W}_۲ * \hat{W}_۱,$$
$$b_{\text{main},c} = \hat{b}_{۲,c} + \sum_{c'} \hat{b}_{۱,c'} \sum_{p,q} \hat{W}_{۲,c,c',p,q}.$$

(اندازهٔ W_{main} برابر ۵×۵ است.) اگر شاخهٔ میانبر کرنل W_{skip} داشته باشد:

$$W_{\text{fused}} = W_{\text{main}} + \text{pad}(W_{\text{skip}}),$$
$$b_{\text{fused}} = b_{\text{main}} + b_{\text{skip}}.$$

بخش سوم

الف

برای شاخه‌های موازی خطی:

$$F_{\text{multi}}(X) = \sum_i (W_i * X + b_i),$$
$$F_{\text{fused}}(X) = \Big(\sum_i W_i\Big) * X + \sum_i b_i.$$

هم‌ارزی زمانی برقرار است که همهٔ شاخه‌ها خطی باشند، stride/padding یکسان باشد، BN در حالت استنتاج با آمار ثابت استفاده شود و بین شاخه‌ها غیرخطی‌سازی نباشد.

ب

برای $H = W = ۵۶$ و $C = ۲۵۶$:

$$\begin{aligned}
\text{MAC}_{\text{before}} &= (۹ + ۱)C^۲HW, \\
\text{FLOPs}_{\text{before}} &= ۲(۹ + ۱)C^۲HW, \\
\text{MAC}_{\text{after}} &= ۹C^۲HW, \\
\text{FLOPs}_{\text{after}} &= ۲۰۹C^۲HW.
\end{aligned}$$

$$\begin{aligned}
C^۲HW &= ۲۰۵,۵۲۰,۸۹۶, \\
\text{FLOPs}_{\text{before}} &= ۴,۱۱۰,۴۱۷,۹۲۰, \\
\text{FLOPs}_{\text{after}} &= ۳,۶۹۹,۳۷۶,۱۲۸.
\end{aligned}$$

اختلاف فقط یک ثابت (حدود ٪۱۰) است و مرتبهٔ محاسباتی تغییر نمی‌کند.

ج

شدت محاسباتی:

$$\begin{aligned}
\text{AI}_{\text{multi}} &\approx \frac{۲(۹ + ۱)C^۲HW}{۲C^۲HW + ۲CHW}, \\
\text{AI}_{\text{fused}} &\approx \frac{۲۰۹C^۲HW}{C^۲HW + ۲CHW}.
\end{aligned}$$

برای C بزرگ، $\text{AI}_{\text{fused}} > \text{AI}_{\text{multi}}$ و مدل ادغام‌شده به‌علت دسترسی کمتر به حافظهٔ وزن‌ها و فعال‌سازی‌های میانی، از نظر سخت‌افزاری کارآمدتر است.

پاسخ مسئله‌ی ۵.

بخش اول

ابتدا داریم

$$L = \frac{۱}{۲}(h_T - y^*)^۲ \quad \Rightarrow \quad \frac{\partial L}{\partial w} = (h_T - y^*)\frac{\partial h_T}{\partial w}.$$

برای $\frac{\partial h_T}{\partial w}$ با باز کردن وابستگی زمانی:

$$\frac{\partial h_T}{\partial w} = \sum_{t=۱}^{T} \frac{\partial h_T}{\partial h_t}\,\frac{\partial h_t}{\partial w}.$$

از رابطه‌ی بازگشتی $h_t = \tanh(w h_{t-۱})$ و $\frac{d}{dx}\tanh(x) = ۱ - \tanh^۲(x)$ داریم

$$\frac{\partial h_t}{\partial h_{t-۱}} = w(۱ - h_t^۲), \qquad \frac{\partial h_t}{\partial w} = (۱ - h_t^۲)h_{t-۱}.$$

پس

$$\frac{\partial h_T}{\partial h_t} = \prod_{j=t+۱}^{T} w(۱ - h_j^۲) = w^{T-t} \prod_{j=t+۱}^{T} (۱ - h_j^۲),$$

و در نتیجه

$$\frac{\partial h_T}{\partial w} = \sum_{t=۱}^{T} w^{T-t}(۱ - h_t^۲)h_{t-۱} \prod_{j=t+۱}^{T} (۱ - h_j^۲).$$

در نهایت:

$$\frac{\partial L}{\partial w} = (h_T - y^*) \sum_{t=۱}^{T} w^{T-t}(۱ - h_t^۲)h_{t-۱} \prod_{j=t+۱}^{T} (۱ - h_j^۲).$$

الف

با توجه به $h_i = \tanh(w h_{i-۱})$ داریم $-۱ < h_i < ۱$ پس $۰ < ۱ - h_i^۲ \leq ۱$. بنابراین

$$\gamma_i = w(۱ - h_i^۲) \quad \Rightarrow \quad |\gamma_i| = |w|\,(۱ - h_i^۲),$$

و در نتیجه

$$۰ \leq |\gamma_i| \leq |w|.$$

ب

از رابطه‌ی گرادیان، ترم اصلی به صورت

$$w^{T-t} \prod_{j=t+۱}^{T} (۱ - h_j^۲) = \prod_{j=t+۱}^{T} |w| \, (۱ - h_j^۲) = \prod_{j=t+۱}^{T} |\gamma_j|$$

ظاهر می‌شود. بنابراین شرط محو شدن گرادیان این است که

$$\prod_{j=t+۱}^{T} |\gamma_j| \longrightarrow ۰ \quad (T \to \infty).$$

یک شرط کافی:

$\exists \rho < ۱ : \ |\gamma_j| \leq \rho$ برای همه‌ی $j \geq j_.$.

به طور خاص اگر $|w| < ۱$ باشد، همواره گرادیان محو می‌شود.

ج

انفجار گرادیان زمانی رخ می‌دهد که

$$\prod_{j=t+۱}^{T} |\gamma_j| \longrightarrow \infty \quad (T \to \infty).$$

یک شرط کافی:

$\exists \rho > ۱ : \ |\gamma_j| \geq \rho$ برای همه‌ی $j \geq j_.$.

از آنجا که $|\gamma_j| = |w|(۱ - h_j^۲) \leq |w|$، برای انفجار لازم است $|w| > ۱$ و حالت‌های پنهان اشباع نشده باشند، یعنی $(۱ - h_j^۲)$ به اندازه‌ی کافی بزرگ بماند.

پاسخ مسئله‌ی ۶.

بخش اول

الف

با فرض $o_t = ۱$ و $f_t = ۱ - i_t$ داریم:

$$h_t = \tanh(c_t), \qquad c_t = (۱ - i_t) \odot c_{t-۱} + i_t \odot \tilde{c}_t,$$
$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-۱} + b_c), \qquad c_{t-۱} = \tanh^{-۱}(h_{t-۱})$$

پس:

$$h_t = \tanh\Big((۱ - i_t) \odot \tanh^{-۱}(h_{t-۱}) + i_t \odot \tanh(W_c x_t + U_c h_{t-۱} + b_c)\Big).$$

ب

در GRU داریم:

$$h_t = (۱ - z_t) \odot h_{t-۱} + z_t \odot \tilde{h}_t.$$

شباهت: i_t نقش گیت به‌روزرسانی مانند z_t دارد و بین حالت قبلی و کاندیدا وزن‌دهی می‌کند. تفاوت: در LSTM ترکیب روی $c_{t-۱}$ انجام شده و سپس $\tanh$ بیرونی اعمال می‌شود، و گیت بازنشانی r_t وجود ندارد.

بخش دوم

الف

نقش r_t در GRU کنترل میزان استفاده از $h_{t-۱}$ در ساخت کاندیدا است؛ $r_t \approx ۰$ یعنی قطع اثر گذشته. برای مشابه‌سازی در LSTM می‌توان:

$$r_t = \sigma(W_r x_t + U_r h_{t-۱} + b_r),$$
$$\tilde{c}_t = \tanh\big(W_c x_t + U_c(r_t \odot h_{t-۱}) + b_c\big).$$

ب

فرض $o_t = ۱$ یعنی خروجی مستقیماً برابر $\tanh(c_t)$ است و حذف کنترل خروجی؛ فرض $f_t = ۱ - i_t$ یعنی یک گیت واحد نقش نگه‌داری/به‌روزرسانی را بازی می‌کند. با افزودن r_t، هر دو مدل دو گیت اصلی دارند: گیت به‌روزرسانی و گیت بازنشانی؛ تفاوت اصلی در وجود حالت سلولی c_t و $\tanh$ بیرونی در LSTM است.

پاسخ مسئله‌ی ۷.

بخش اول ـ الف

با فرض $\frac{\partial f_t}{\partial c_{t-1}} = \frac{\partial i_t}{\partial c_{t-1}} = \frac{\partial \tilde{c}_t}{\partial c_{t-1}} = 0$ داریم:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$
$$\implies \frac{\partial c_t}{\partial c_{t-1}} = f_t$$

(به‌صورت مولفه‌ای.)

بخش اول ـ ب

با زنجیره‌ای کردن گرادیان‌ها روی دنباله:

$$\frac{\partial c_T}{\partial c_t} = \prod_{k=t+1}^{T} f_k$$

(حاصل‌ضرب مولفه‌ای.) اگر بایاس فراموشی b_f را بزرگ و مثبت بگیریم، در ابتدا $f_k \approx 1$ و بنابراین $\frac{\partial c_T}{\partial c_t} \approx 1$ می‌شود؛ پس مشکل محوشدن گرادیان کاهش می‌یابد. در RNN استاندارد، گرادیان‌ها حاصل‌ضرب وزن‌های بازگشتی و مشتق tanh هستند و به‌سادگی محو یا منفجر می‌شوند، اما در LSTM مسیر خطیِ Constant Error Carousel با $f_k \approx 1$ گرادیان را حفظ می‌کند.

بخش دوم ـ الف

در GRU داریم:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$
$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$
$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h)$$
$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

در MGU اگر $r_t = z_t = f_t$ و پارامترها را مشترک کنیم $(W_z, U_z, b_z) = (W_r, U_r, b_r) = (W_f, U_f, b_f)$، معادلات MGU به‌دست می‌آید؛ پس MGU یک حالت خاص از GRU است.

بخش دوم ـ ب

حالت ۱: اگر $f_t \to ۱$:

$$h_t = \tilde{h}_t$$
$$\tilde{h}_t = \tanh(W_h x_t + U_h h_{t-۱} + b_h)$$

که همان رفتار RNN کلاسیک است.

حالت ۲: اگر $f_t \to ۰$:

$$h_t = h_{t-۱}$$
$$\tilde{h}_t = \tanh(W_h x_t + b_h)$$

بنابراین حالت پنهان کپی می‌شود (حافظه کامل) و برای مدل‌سازی وابستگی‌های بلندمدت مفید است، هرچند ورودی جدید عملا وارد حالت نمی‌شود.