پاسخ مسئله‌ی ۱.

الف

با factorisation داده‌شده و ساختار Markov مدل مولد، از نامساوی Jensen شروع می‌کنیم:

$$\begin{aligned}\log p_\theta(x) &\geq \mathbb{E}_{q_\phi(z|x)}\left[\log \frac{p_\theta(x,z)}{q_\phi(z|x)}\right] = \mathcal{L}(\theta,\phi;x)\\ &= \mathbb{E}_{q_\phi(z|x)}\left[\log p_\theta(x \mid z_1) + \log p_\theta(z_L) + \sum_{i=1}^{L-1} \log p_\theta(z_i \mid z_{i+1}) - \sum_{i=1}^{L} \log q_\phi(z_i \mid z_{i+1}, x)\right]\end{aligned}$$

با گروه‌بندی جملات هم‌لایه و استفاده از $z_{L+1} \equiv \emptyset$ (پس $p_\theta(z_L \mid z_{L+1}) = p_\theta(z_L)$):

$$\mathcal{L}(\theta,\phi;x) = \underbrace{\mathbb{E}_{q_\phi(z_1|x)}[\log p_\theta(x \mid z_1)]}_{\text{reconstruction}} - \sum_{i=1}^{L} \underbrace{\mathbb{E}_{q_\phi(z_{i+1}|x)}\Big[\mathrm{KL}\big(q_\phi(z_i \mid z_{i+1}, x) \,\|\, p_\theta(z_i \mid z_{i+1})\big)\Big]}_{\text{regularisation}}$$

هر جملهٔ KL برای لایهٔ i، با Gaussian بودن q و p، چنین است:

$$\mathrm{KL}_i = \frac{1}{2} \sum_d \left(\frac{\sigma_{q,i,d}^2 + (\mu_{q,i,d} - \mu_{p,i,d})^2}{\sigma_{p,i,d}^2} - 1 + \log \frac{\sigma_{p,i,d}^2}{\sigma_{q,i,d}^2} \right)$$

سازوکار ARD: وقتی واحد نهان d از لایهٔ i اطلاعاتی دربارهٔ x حمل نکند، بهینه‌سازی KL_i را با راندن q به سمت p کمینه می‌کند:

$$\mu_{q,i,d} \to \mu_{p,i,d}, \quad \sigma_{q,i,d}^2 \to \sigma_{p,i,d}^2 \implies \mathrm{KL}_{i,d} \to 0$$

آنگاه $q_\phi(z_{i,d} \mid \cdot) = p_\theta(z_{i,d} \mid \cdot)$ و آن واحد عملاً خاموش («pruned») می‌شود؛ پس عبارت منظم‌سازی به‌طور خودکار واحدهای بی‌استفاده را حذف می‌کند.

ب

با ضرب دو Gaussian، posterior متناسب با حاصل‌ضرب likelihood و prior است:

$$\begin{aligned}q(z_i) &\propto \mathcal{N}(z_i \mid \hat{\mu}_{q,i}, \hat{\sigma}_{q,i}^2)\,\mathcal{N}(z_i \mid \mu_{p,i}, \sigma_{p,i}^2)\\ &\propto \exp\left(-\frac{(z_i - \hat{\mu}_{q,i})^2}{2\hat{\sigma}_{q,i}^2} - \frac{(z_i - \mu_{p,i})^2}{2\sigma_{p,i}^2}\right)\end{aligned}$$

نمایِ توان را برحسب z_i مرتب و مربع کامل می‌کنیم:

$$-\frac{۱}{۲}\left[\left(\hat{\sigma}_{q,i}^{-۲}+\sigma_{p,i}^{-۲}\right)z_i^{۲}-۲\left(\hat{\mu}_{q,i}\hat{\sigma}_{q,i}^{-۲}+\mu_{p,i}\sigma_{p,i}^{-۲}\right)z_i\right]+\text{const}$$

مقایسه با فرم استاندارد $-\frac{۱}{۲\sigma_{q,i}^{۲}}(z_i-\mu_{q,i})^{۲}$ ضرایب را می‌دهد:

$$\sigma_{q,i}^{-۲}=\hat{\sigma}_{q,i}^{-۲}+\sigma_{p,i}^{-۲}\implies\sigma_{q,i}^{۲}=\frac{۱}{\hat{\sigma}_{q,i}^{-۲}+\sigma_{p,i}^{-۲}}$$
$$\frac{\mu_{q,i}}{\sigma_{q,i}^{۲}}=\hat{\mu}_{q,i}\hat{\sigma}_{q,i}^{-۲}+\mu_{p,i}\sigma_{p,i}^{-۲}\implies\mu_{q,i}=\frac{\hat{\mu}_{q,i}\hat{\sigma}_{q,i}^{-۲}+\mu_{p,i}\sigma_{p,i}^{-۲}}{\hat{\sigma}_{q,i}^{-۲}+\sigma_{p,i}^{-۲}}$$

که همان (۱۹) است. تفسیر: $\hat{\mu}_{q,i},\hat{\sigma}_{q,i}^{۲}$ دقیقاً نقش پارامترهای یک Gaussian likelihood وابسته به داده را بازی می‌کنند؛ شبکهٔ bottom-up به‌جای تولید مستقیم posterior، یک likelihood گاوسی روی z_i می‌سازد که با precision-weighted ترکیب‌شدن با prior مولد، posterior را پدید می‌آورد.

ج

در مسیر top-down، prior هر لایه از همان شبکهٔ مولد می‌آید:

$$p_\theta(z_i\mid z_{i+۱})=\mathcal{N}\big(z_i\,\big|\,\mu_{p,i}(z_{i+۱}),\,\sigma_{p,i}^{۲}(z_{i+۱})\big)$$

استنتاج LVAE همین $\mu_{p,i},\sigma_{p,i}^{۲}$ را در (۱۹) به‌کار می‌برد؛ یعنی پارامترهای generative path مستقیماً وارد محاسبهٔ posterior تقریبی می‌شوند. مزیت این اشتراک پارامتر در KL آشکار است:

$$\mathrm{KL}\big(q_\phi(z_i\mid z_{i+۱},x)\,\|\,p_\theta(z_i\mid z_{i+۱})\big)$$

هر دو توزیع از $\mu_{p,i},\sigma_{p,i}^{۲}$ یکسان استفاده می‌کنند، پس q و p ذاتاً هم‌تراز («aligned») هستند و KL نزدیک صفر آغاز می‌شود. در مقابل، یک inference network purely bottom-up باید q را بدون هیچ دانشی از p_θ بسازد؛ آنگاه q و p در فضای پارامتر دور از هم قرار می‌گیرند و سطح بهینه‌سازی پرشیب‌تر و ناهموارتر می‌شود. اشتراک مسیر top-down این بدتنظیمی را حذف می‌کند و همگرایی را آسان‌تر می‌سازد.

د

(i)

با $\beta=۰$ در (۲۰):

$$\mathcal{L}_T(\theta,\phi;x)\big|_{\beta=۰}=\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x\mid z)]$$

عبارت KL حذف می‌شود؛ هیچ فشاری $q_\phi(z \mid x)$ را به سمت prior نمی‌راند، پس بهینه‌سازی آزاد است q را تا حد ممکن متمرکز (واریانس $\to ۰$) کند:

$$q_\phi(z \mid x) \to \delta\big(z - f_\phi(x)\big) \implies \mathcal{L}_T \to \log p_\theta\big(x \mid f_\phi(x)\big)$$

که دقیقاً هدف یک deterministic autoencoder با encoder نگاشت f_ϕ و خطای بازسازی است.

(ii)

Collapse وقتی رخ می‌دهد که عبارت KL زودتر از آنکه decoder یاد بگیرد از z استفاده کند، آن را به صفر براند؛ آنگاه واحد نهان به prior فرومی‌پاشد و بی‌اطلاع می‌ماند. با $\beta = ۰$ در ابتدا:

$$\beta \approx ۰ \implies \text{فشار KL} \approx ۰ \implies q_\phi(z \mid x) \not\to p_\theta(z)$$

در این مرحله شبکه آزادانه اطلاعات معناداری در z رمزگذاری می‌کند و decoder به آن وابسته می‌شود؛ سپس با افزایش تدریجی β تا ۱، عبارت KL فعال می‌شود اما واحدهای نهان دیگر «استفاده‌شده» و در برابر collapse مقاوم‌اند.

(iii)

با $\beta = ۱$ از ابتدا، هدف از همان آغاز ELBO کامل است:

$$\mathcal{L}_T = -\mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p_\theta(z)\big) + \mathbb{E}_{q_\phi}[\log p_\theta(x \mid z)]$$

در گام‌های نخست decoder هنوز ضعیف است و جملهٔ بازسازی سهم اندکی دارد؛ پس کمینه‌سازی با راندن KL به صفر آسان‌تر است:

$$q_\phi(z \mid x) \to p_\theta(z) \implies \mathrm{KL} \to ۰, \quad z \perp x$$

نتیجه posterior collapse: واحدهای نهان بی‌اطلاع می‌شوند، z از x مستقل می‌گردد و مدل به یک decoder بی‌توجه به z تنزل می‌یابد.

پاسخ مسئله‌ی ۲.

الف

(آ)

$$f^*(v) = \sup_u (uv - u\log u) \implies u^* = e^{v-1} \implies f^*(v) = e^{v-1}$$

$$D_{\mathrm{KL}}(P\|Q) = \frac{1}{2}\left[\left.\frac{|\Sigma_2|}{|\Sigma_1|}\right|_{\log} - d + \mathrm{tr}(\Sigma_2^{-1}\Sigma_1) + (\mu_1-\mu_2)^\top \Sigma_2^{-1}(\mu_1-\mu_2)\right] = \frac{\|\mu_1-\mu_2\|^2}{2\sigma^2}$$

(ب)

$D_{\mathrm{KL}}(P\|Q)$ میانگین‌گرا (mean-seeking) است:

$$\mu^\star = \arg\min_\mu \mathbb{E}_{x\sim P}\|x-\mu\|^2 = \bar{\mu}$$

$D_{\mathrm{KL}}(Q\|P)$ مدگرا (mode-seeking) است؛ امید نسبت به Q هر جا p کوچک باشد جریمهٔ نامتناهی می‌دهد، پس Q به یک مد می‌چسبد — ریشهٔ mode collapse. چون جملهٔ دوم D_{JS} همین ساختار را دارد، GAN استاندارد به این رفتار متمایل است.

(ج)

الف. برای $f(u) = u\log u - (u+1)\log(u+1)$:

$$T^*(x) = f'(p/q) = \log\frac{p}{p+q} < 0 \implies \mathrm{dom}(f^*) = \{t < 0\}$$

پیامد: وقتی تفکیک‌گر مطمئن شود ($p/q \to 0, \infty$)، $T^* \to -\infty, 0^-$ و گرادیان مولد محو می‌شود (اشباع).

ب. برای معکوس KL، $f(u) = -\log u \implies T^* = f'(p/q) = -q/p < 0$، که با $\mathrm{dom}(f^*) = \mathbb{R}^-$ سازگار است؛ کلاً $\mathrm{dom}(f^*)$ همان برد f' روی $u > 0$ است.

ب

(آ)

$$\frac{\partial}{\partial D}[p\log D + q\log(۱ - D)] = ۰ \implies D^* = \frac{p}{p+q}$$

$$\begin{aligned} L_D^* &= \mathbb{E}_P \log \tfrac{p}{(p+q)/۲} + \mathbb{E}_Q \log \tfrac{q}{(p+q)/۲} - ۲\log ۲ \\ &= ۲D_{\mathrm{JS}}(P\|Q) - \log ۴ \end{aligned}$$

در تعادل $P = Q$، $D^* \equiv \frac{۱}{۲}$ و $L_D^* = -\log ۴$ ثابت می‌ماند؛ این کفِ تخت یعنی نزدیک تعادل گرادیان مولد محو می‌شود — اشباع.

(ب)

آ) $D_{\mathrm{JS}}(\delta_{x_۱}\|\delta_{x_۲}) = \frac{۱}{۲}\log\frac{۱}{۱/۲} + \frac{۱}{۲}\log\frac{۱}{۱/۲} = \log ۲$ (مستقل از $\|x_۱ - x_۲\|$)

ب) $W_۱(\delta_{x_۱}, \delta_{x_۲}) = \|x_۱ - x_۲\|$

(ج)

چون پشتیبان‌ها مجزا، $D_{\mathrm{JS}} = \log ۲$ همواره ثابت است، پس $\nabla_\theta D_{\mathrm{JS}} = ۰$ (اشباع کامل)، در حالی که $W_۱$ متناسب با فاصلهٔ هندسی پیوسته تغییر می‌کند و گرادیان غیرصفر می‌دهد.

برای $P = \mathcal{N}(\mu_P, I), Q = \mathcal{N}(\mu_Q, I)$، نگاشت بهینه $T(x) = x + (\mu_P - \mu_Q)$ و تابع دوگان بهینه $f^*(x) = \langle x, \frac{\mu_P - \mu_Q}{\|\mu_P - \mu_Q\|}\rangle$:

$$\nabla_x f^*(x) = \frac{\mu_P - \mu_Q}{\|\mu_P - \mu_Q\|} = \text{const} \neq ۰ \quad \forall x$$

گرادیان در همهٔ نقاط یکسان و غیرصفر است؛ برخلاف D_{JS} که در نواحی مجزا اشباع می‌شود، WGAN همیشه سیگنال سالم می‌دهد.

ج

(آ)

الف. GAN عملاً D_{JS} کمینه می‌کند که جملهٔ مدگرای معکوس KL در آن وزن دارد $\implies$ تمرکز روی زیرمجموعهٔ مدها (precision بالا) و نادیده‌گرفتن بقیه (recall پایین).

ب. هدف score matching با $D_{\mathrm{KL}}(P\|Q_\theta)$ پیشرو هم‌خانواده است که zero-avoiding است:

$D_{\mathrm{KL}}(P\|Q_\theta) \to \infty$ اگر $q_\theta \to 0$ در پشتیبان P

پس هیچ مدی حذف نمی‌شود recall) بالا) و precision نیز حفظ می‌شود.

ج. ذاتیِ خودِ D_{JS} است، نه صرفاً مشکل بهینه‌سازی؛ حتی با تفکیک‌گر کاملاً بهینه، جملهٔ مدگرا پوشش ناقص را پاداش می‌دهد.

(ب)

آ) GAN $\implies$ تخمین $p(x)/q(x)$ $\implies$ گرادیان محو $\implies$ $D^* \to 0,1$ در نواحی کم‌چگالی

ب) Diffusion $\implies$ $\nabla_x \log p_t(x)$ در سرتاسر فضا تعریف‌شده و غیرصفر

ج) $\nabla_x \log p_t(x)$ $\implies$ اگر مدی نادیده گرفته شود همچنان نمونه را به سمت آن مد هل می‌دهد

د

(آ)

الف.

$$D_{\mathrm{KL}}(P\|Q_\theta) = \frac{\|\theta\|^2}{2\sigma^2}, \qquad W_2^2(P,Q_\theta) = \|\theta\|^2 + \mathrm{tr}(\cdots) = \|\theta\|^2$$

هر دو $\propto \|\theta\|^2$ و گرادیان غیرصفر در $\theta \neq 0$؛ وقتی پشتیبان‌ها هم‌پوشانند هر دو معیار خوش‌رفتارند.

ب. از قبل: $D_{\mathrm{JS}} = \log 2$ (ثابت) ولی $W_1 = \|x_1 - x_2\|$ (خطی). چون داده روی منیفلد کم‌بعد است، پشتیبان مولد و داده تقریباً همیشه مجزاست؛ پس D_{JS} گرادیان محو می‌دهد ولی WGAN حل می‌کند.

ج. در نواحی دور از بهینه (پشتیبان مجزا)، $D_{\mathrm{JS}} \to \log 2$ ثابت $\implies$ چشم‌انداز تخت (flat). W_1 متناسب با فاصله رشد می‌کند $\implies$ چشم‌انداز شیب‌دار باقی می‌ماند.

(ب)

آ. هدف را با جملهٔ پیشروِ زیرو–avoiding ترکیب می‌کنیم:

$$\mathcal{L} = D_{\mathrm{JS}}(P\|Q) + \lambda D_{\mathrm{KL}}(P\|Q), \quad \lambda > 0$$

که مدهای ناپوشانده را جریمه و فروپاشی مد را مهار می‌کند.

ب. انتشار، چون هدفش zero-avoiding است و میدان امتیاز همه‌جا گرادیان سالم می‌دهد، پوشش کامل بدون تنظیم ظریفِ تعادل مین‌ماکس تضمین می‌کند.

ج. FID یک عدد مجتمع از فاصلهٔ دو گاوسی برازش‌شده است و کیفیت را از تنوع تفکیک نمی‌کند؛ Precision/Recall این دو محور را جدا می‌سازند و دقیقاً همان trade-off کیفیت ـ پوشش را آشکار می‌کنند.

پاسخ مسئله‌ی ۳.

بخش اول

الف

فرآیند معکوس $q(x_{t-1} \mid x_t)$ گوسی نیست زیرا طبق قاعدهٔ بِیز

$$q(x_{t-1} \mid x_t) = \frac{q(x_t \mid x_{t-1})\, q(x_{t-1})}{q(x_t)}$$

و $q(x_{t-1})$ مارجینال داده‌هاست که توزیعی دلخواه و پیچیده است؛ ضرب آن در یک گوسی، گوسی نمی‌دهد. اما اگر $\beta_t = 1 - \alpha_t$ به‌اندازهٔ کافی کوچک باشد (گام‌های نویز ریز)، $q(x_{t-1})$ روی همسایگی کوچک x_t تقریباً ثابت/هموار است و در آن بازه با یک گوسی تقریب می‌خورد؛ پس برای $\beta_t \to 0$ می‌توان فرض کرد فرآیند معکوس نیز گوسی است.

ب

ضرب در $q(x_{t-1})$ مشکل‌ساز است:

$$\begin{aligned} q(x_{t-1} \mid x_t) &= \frac{q(x_t \mid x_{t-1})\, q(x_{t-1})}{q(x_t)} \\ q(x_{t-1}) &= \int q(x_{t-1} \mid x.)\, q(x.)\, \mathrm{d}x. \\ q(x_t) &= \int q(x_t \mid x.)\, q(x.)\, \mathrm{d}x. \end{aligned}$$

هر دو مارجینال به انتگرال روی توزیع نامعلوم دادهٔ $q(x.)$ وابسته‌اند که فاقد فرم بسته است؛ پس $q(x_{t-1} \mid x_t)$ به‌تنهایی Intractable است و نمونه‌برداری از آن ممکن نیست.

ج

با شرطی‌کردن نسبت به $x.$، وابستگی به مارجینال نامعلوم حذف می‌شود و همهٔ جملات گوسی با فرم بسته می‌گردند:

$$q(x_{t-1} \mid x_t, x.) = \frac{q(x_t \mid x_{t-1}, x.)\, q(x_{t-1} \mid x.)}{q(x_t \mid x.)} = \frac{q(x_t \mid x_{t-1})\, q(x_{t-1} \mid x.)}{q(x_t \mid x.)}$$

که نیازمند روابط زیر است (با $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$):

$$\begin{aligned} q(x_t \mid x_{t-1}) &= \mathcal{N}(x_t; \sqrt{\alpha_t}\, x_{t-1}, (1-\alpha_t) I) \\ q(x_t \mid x.) &= \mathcal{N}\big(x_t; \sqrt{\bar{\alpha}_t}\, x., (1-\bar{\alpha}_t) I\big) \\ q(x_{t-1} \mid x.) &= \mathcal{N}(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}}\, x., (1-\bar{\alpha}_{t-1}) I) \end{aligned}$$

هر سه tractable و گوسی‌اند، پس حاصل نیز گوسی و قابل نمونه‌برداری است.

بخش دوم

الف

با ضرب سه گوسی و جمع‌بستن نمایی‌ها بر حسب x_{t-1}:

$$q(x_{t-1} \mid x_t, x_0) \propto \exp\left(-\frac{1}{2}\left[\frac{(x_t - \sqrt{\alpha_t}x_{t-1})^2}{1-\alpha_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0)^2}{1-\bar{\alpha}_{t-1}}\right]\right)$$
$$\propto \exp\left(-\frac{1}{2}\left[\left(\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}\right)x_{t-1}^2 - 2\left(\frac{\sqrt{\alpha_t}}{1-\alpha_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right)x_{t-1}\right]\right)$$

این فرم درجه‌دوم در x_{t-1} یک گوسی است. واریانس از معکوس ضریب x_{t-1}^2:

$$\tilde{\beta}_t^{-1} = \frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}} = \frac{\alpha_t(1-\bar{\alpha}_{t-1}) + (1-\alpha_t)}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})} = \frac{1-\bar{\alpha}_t}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}$$
$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}(1-\alpha_t) = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

میانگین از ضریب جملهٔ خطی، در واریانس:

$$\tilde{\mu}_t(x_t, x_0) = \tilde{\beta}_t\left(\frac{\sqrt{\alpha_t}}{1-\alpha_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right)$$
$$= \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0$$

ب

ELBO با اعمال زنجیرهٔ مارکوف و قاعدهٔ بِیز روی جملات:

$$\log p_\theta(x_0) \geq \mathbb{E}_q\left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)}\right]$$
$$= \mathbb{E}_q\Bigg[\underbrace{\log p_\theta(x_0 \mid x_1)}_{L_0} - \underbrace{D_{KL}\big(q(x_T \mid x_0) \,\|\, p(x_T)\big)}_{L_T}$$
$$- \sum_{t=2}^{T} \underbrace{D_{KL}\big(q(x_{t-1} \mid x_t, x_0) \,\|\, p_\theta(x_{t-1} \mid x_t)\big)}_{L_{t-1}}\Bigg]$$

L_T ثابت است (بدون پارامتر، چون $p(x_T)$ پیشین ثابت و $q(x_T \mid x_0)$ معلوم)؛ L_0 جملهٔ بازسازی گام آخر؛ L_{t-1} جملات اصلی آموزش‌اند که توزیع معکوس آموخته را به $q(x_{t-1} \mid x_t, x_0)$ نزدیک می‌کنند.

اگر $p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \tilde{\beta}_t I)$ با همان واریانس فرض شود، KL بین دو گوسی هم‌واریانس تنها به فاصلهٔ میانگین‌ها بستگی دارد:

$$L_{t-1} = \mathbb{E}_q\left[\frac{1}{2\tilde{\beta}_t}\left\|\tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t)\right\|^2\right] + C$$

پس کمینه‌کردن KL معادل کمینه‌کردن خطای مجذور وزنی میان میانگین واقعی و پیش‌بینی است.

ج

از $x_t = \sqrt{\bar{\alpha}_t} x_۰ + \sqrt{۱ - \bar{\alpha}_t}\,\varepsilon$ داریم $x_۰ = \frac{۱}{\sqrt{\bar{\alpha}_t}}(x_t - \sqrt{۱ - \bar{\alpha}_t}\,\varepsilon)$. جای‌گذاری در $\tilde{\mu}_t$:

$$\begin{aligned}\tilde{\mu}_t &= \frac{\sqrt{\alpha_t}(۱ - \bar{\alpha}_{t-۱})}{۱ - \bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-۱}}\,\beta_t}{۱ - \bar{\alpha}_t} \cdot \frac{x_t - \sqrt{۱ - \bar{\alpha}_t}\,\varepsilon}{\sqrt{\bar{\alpha}_t}} \\ &= \frac{۱}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{۱ - \bar{\alpha}_t}}\,\varepsilon \right)\end{aligned}$$

که دقیقاً فرم μ_θ را با $\varepsilon \to \varepsilon_\theta(x_t, t)$ توجیه می‌کند. اختلاف میانگین‌ها:

$$\tilde{\mu}_t - \mu_\theta = \frac{۱}{\sqrt{\alpha_t}} \cdot \frac{\beta_t}{\sqrt{۱ - \bar{\alpha}_t}} \big(\varepsilon_\theta(x_t, t) - \varepsilon \big)$$

جای‌گذاری در $L_{t-۱}$:

$$L_{t-۱} = \mathbb{E}\left[\frac{۱}{۲\tilde{\beta}_t} \cdot \frac{\beta_t^۲}{\alpha_t(۱ - \bar{\alpha}_t)} \left\| \varepsilon - \varepsilon_\theta(x_t, t) \right\|^۲ \right] = \mathbb{E}_{x_۰, \varepsilon, t}\big[\lambda_t \left\| \varepsilon - \varepsilon_\theta(x_t, t) \right\|^۲ \big]$$

$$\lambda_t = \frac{\beta_t^۲}{۲\tilde{\beta}_t\, \alpha_t(۱ - \bar{\alpha}_t)} = \frac{\beta_t^۲}{۲\alpha_t(۱ - \bar{\alpha}_t)} \cdot \frac{۱ - \bar{\alpha}_t}{(۱ - \bar{\alpha}_{t-۱})\beta_t} = \frac{\beta_t}{۲\alpha_t(۱ - \bar{\alpha}_{t-۱})}$$

د

۱. چون

$$\lambda_t = \frac{\beta_t}{۲\alpha_t(۱ - \bar{\alpha}_{t-۱})}$$

در گام‌های کوچک t (نویز کم، $\bar{\alpha}_{t-۱} \to ۱$) مخرج $۰ \to ۱ - \bar{\alpha}_{t-۱}$ است، پس λ_t بزرگ می‌شود و ELBO اصلی وزن زیادی به این گام‌ها می‌دهد؛ در گام‌های بزرگ t (نویز زیاد) مخرج به ۱ نزدیک و λ_t کوچک است. قراردادن $\lambda_t = ۱$ این وزن‌دهی را یکنواخت می‌کند و تمرکز را از گام‌های کم‌نویز برداشته و به‌طور نسبی به گام‌های پرنویز منتقل می‌کند.

۲. در گام‌های کم‌نویز شبکه فقط جزئیات ریز با اطلاعات کم را بازسازی می‌کند؛ وزن بزرگ λ_t در ELBO اصلی، ظرفیت مدل را صرف این جملات کم‌اهمیت می‌کند. گام‌های پرنویز ساختار کلان و محتوای ادراکی تصویر را شکل می‌دهند که برای کیفیت نمونهٔ نهایی تعیین‌کننده‌ترند. با $\lambda_t = ۱$ توجه شبکه از جزئیات ریز به این گام‌های پرنویزِ ساختارساز معطوف می‌شود؛ افزون بر این، حذف ضریب بزرگ، واریانس گرادیان را کاهش داده و آموزش را پایدارتر می‌کند —— نتیجه نمونه‌هایی با کیفیت ادراکی بالاتر است.

پاسخ مسئله‌ی ۴.

بخش الف

آ

$$s^*(x) = \nabla \log p(x) = \frac{[x_0 \mid x] - x}{\sigma^2}, \qquad D^*(x) = \arg\min_D \mathbb{E}\|D(x) - x_0\|^2 = [x_0 \mid x]$$

پس $s^*(x) = \dfrac{D^*(x) - x}{\sigma^2}$ — تفاضل و مقیاس‌دهی ساده از بازساز بهینه.

ب

گرادیان رگرسیون $D_\theta = \mathbb{E}[x_0 \mid x]$ صفر نمی‌شود؛ اما در GAN، $D^* \to 1$ یعنی تا $\propto (D_\theta(x) - x_0)\nabla_\theta D_\theta$

$$\nabla_x \log D^*(x)\big|_{D^* \to 1} \to 0,$$

گرادیان مولد محو می‌شود (vanishing gradient). رگرسیون به مقدار هدف وابسته است نه به اطمینان تفکیک‌گر، پس در نقطهٔ زینی اشباع نمی‌شود.

ج

$s^*(x) = \frac{1}{\sigma^2}(\mathbb{E}[x_0 \mid x] - x)$ روی کل فضای هموارشده تعریف و غیرصفر است (جهت به سمت دادهٔ نزدیک). در مقابل با تکیه‌گاه‌های جدا:

$$\mathrm{JS}(P\|Q) = \log 2 = \text{const} \implies \nabla_\theta \,\mathrm{JS} = 0.$$

امتیاز همه‌جا گرادیان هموار دارد؛ تفکیک‌گر GAN در نواحی خالی هیچ سیگنالی نمی‌دهد.

بخش ب

آ

$$\begin{aligned} x_t &= \sqrt{\alpha_t \alpha_{t-1}}\, x_{t-2} + \sqrt{\alpha_t(1-\alpha_{t-1})}\,\epsilon_{t-2} + \sqrt{1-\alpha_t}\,\epsilon_{t-1} \\ &= \sqrt{\alpha_t \alpha_{t-1}}\, x_{t-2} + \sqrt{1-\alpha_t\alpha_{t-1}}\,\bar{\epsilon} \quad \text{(ادغام دو گاوسی مستقل)} \end{aligned}$$

با استقرا تا x_0: $q(x_t \mid x_0) = (x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$.

ب

حاصل‌ضرب دو گاوسی در $x_{t-۱}$:

$$\tilde{\beta}_t^{-۱} = \frac{\alpha_t}{\beta_t} + \frac{۱}{۱-\bar{\alpha}_{t-۱}} \implies \tilde{\beta}_t = \frac{۱-\bar{\alpha}_{t-۱}}{۱-\bar{\alpha}_t}\beta_t$$
$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-۱}}\beta_t}{۱-\bar{\alpha}_t}x_۰ + \frac{\sqrt{\alpha_t}(۱-\bar{\alpha}_{t-۱})}{۱-\bar{\alpha}_t}x_t$$

چون هر دو توزیع گاوسی با کوواریانس مشترک $\sigma_t^۲ I$اند، KL به $\frac{۱}{۲\sigma_t^۲}\|\tilde{\mu}_t - \mu_\theta\|^۲$ فرو می‌کاهد که همان $\mathcal{L}_{t-۱}$ است.

ج

با $x_۰ = \frac{۱}{\sqrt{\bar{\alpha}_t}}(x_t - \sqrt{۱-\bar{\alpha}_t}\epsilon)$ در $\tilde{\mu}_t$:

$$\tilde{\mu}_t = \frac{۱}{\sqrt{\alpha_t}}\Big(x_t - \frac{\beta_t}{\sqrt{۱-\bar{\alpha}_t}}\epsilon\Big) \implies \tilde{\mu}_t - \mu_\theta \propto \epsilon_\theta(x_t,t) - \epsilon$$

با حذف وزن $\mathcal{L}_{\text{simple}} = \mathbb{E}\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_۰ + \sqrt{۱-\bar{\alpha}_t}\epsilon, t)\|^۲$. ⇒ هدف ϵ همواره گاوسی استاندارد با مقیاس ثابت است؛ هدف $\tilde{\mu}_t$ یا $x_۰$ با t بدمقیاس می‌شود (نزدیک $t \to T$، $۱/\sqrt{\bar{\alpha}_t}$ نویز را تشدید می‌کند) — پیش‌بینی ϵ گرادیانی پایدارتر می‌دهد.

بخش ج

آ

با $\sigma_t = ۰$، $x_{t-۱} = \sqrt{\bar{\alpha}_{t-۱}}\hat{x}_۰(x_t) + \sqrt{۱-\bar{\alpha}_{t-۱}}\epsilon_\theta(x_t,t)$ تابعی قطعی از x_t است؛ با تثبیت x_T کل مسیر یکتاست.

ب

$\mathbb{E}[x_{t-۱} \mid x_۰] = \sqrt{\bar{\alpha}_{t-۱}}x_۰$ با واریانس $(۱-\bar{\alpha}_{t-۱})I$ — مستقل از σ_t، یعنی حاشیه‌های $q(x_t \mid x_۰)$ حفظ می‌شوند. چون

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_۰,\epsilon,t}\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_۰ + \sqrt{۱-\bar{\alpha}_t}\epsilon, t)\|^۲$$

فقط به حاشیه‌ها وابسته است نه به $q(x_{۱:T} \mid x_۰)$ کامل، شبکهٔ آموزش‌دیده بدون بازآموزی برای هر عضو خانوادهٔ DDIM معتبر است.

ب (SDE)

$$dx = \Big[f(x,t) - \tfrac{۱}{۲}g(t)^۲\nabla_x \log p_t(x)\Big]dt$$

نیمی از جملهٔ امتیاز جذب drift می‌شود و $\{p_t\}$ حفظ می‌شود؛ نگاشت قطعی و invertible است، پس change-of-variables درست‌نمایی دقیق می‌دهد — کاری که SDE تصادفی اجازه نمی‌دهد. در مقابل، نویز SDE خطاهای score را تصحیح و تنوع نمونه می‌افزاید.

بخش د

آ

(آ) $D^* = \dfrac{p}{p+q}$ در $q \to 0$ یک نسبت چگالی است؛ اشباع می‌شود — طبقه‌بندی.

(ب) $s_\theta \approx \nabla \log p_t$. یک رگرسیون است که جهت رشد چگالی را همه‌جا یاد می‌گیرد.

(ج) $p_t > 0 \Rightarrow \nabla \log p_t$ روی مد ازدست‌رفته به سمت آن هل می‌دهد؛ گرادیان GAN آنجا صفر است.

مثال: $P = \frac{1}{2}\mathcal{N}(-\mu, \sigma^2) + \frac{1}{2}\mathcal{N}(\mu, \sigma^2)$، $Q_\theta = \mathcal{N}(\theta, \sigma^2)$ با $\theta \approx \mu$. برای $x \ll -\mu$:

$$\nabla \log P(x) \to -\frac{x+\mu}{\sigma^2} \neq 0, \qquad D^*(x) \to 1 \Rightarrow \nabla_\theta \,\mathrm{JS} \to 0.$$

امتیاز مد چپ را بازمی‌یابد؛ GAN در آن «می‌میرد».

ب

(آ) تنوع بالا: DDPM تصادفی، $T \approx 1000$ — پوشش کامل مدها مهم‌تر از کیفیت تک‌نمونه.

(ب) کیفیت بالا، زمان آزاد: DDPM تصادفی، $T = 1000$ — کمینهٔ خطای گسسته‌سازی و تصحیح score در مسیر.

(ج) تعادل تعاملی: DDIM قطعی، $T \approx 20$–50 — گام بزرگ بدون انباشت نویز، نتیجهٔ تکرارپذیر.

پاسخ مسئله‌ی ۵.

الف) Langevin و میانگین متحرک نویز

آ

معادلهٔ Fokker–Planck متناظر با SDE پیوستهٔ این دینامیک:

$$\partial_t \rho = -\nabla \cdot \big(\rho \nabla \log p - \nabla \rho\big)$$

در حالت ایستا ($\partial_t \rho = ۰$) جریان احتمال صفر می‌شود:

$$\nabla \log \rho_\infty = \nabla \log p \implies \rho_\infty \propto p(x)$$

با $\eta \to ۰$ خطای گسسته‌سازی Euler–Maruyama ($O(\eta)$) حذف و x_k به این توزیع ایستا همگرا می‌شود.

ب

از رابطهٔ Tweedie، $\mathbb{E}[x_۰ \mid x_\sigma] = x_\sigma + \sigma^۲ \nabla_{x_\sigma} \log p_\sigma$، و تخمین شبکه $\mathbb{E}[x_۰ \mid x_\sigma] \approx x_\sigma - \sigma \epsilon_\theta$:

$$\boxed{\nabla_{x_\sigma} \log p_\sigma(x_\sigma) \approx -\frac{\epsilon_\theta(x_\sigma)}{\sigma}}$$

با σ بزرگ، p_σ (کانولوشن $p_۰$ با هستهٔ گاوسی) پشتیبان وسیع‌تری دارد، پس score در حجم بزرگ‌تری از فضا غیرصفر است.

ج

با نویز کوچک، p_σ تقریباً فقط نزدیک manifold داده غیرصفر است؛ score در نقاط دور نامعتبر/صفر است و عبور بین modeها (poor mixing) رخ نمی‌دهد. شروع با σ بزرگ چگالی را هموار و یک‌مُده می‌کند تا walker سریع به ناحیهٔ پرجرم برسد؛ کاهش تدریجی σ سپس آن را به جزئیات $p_۰$ می‌رساند (annealing/continuation). عکس آن چون از نقطهٔ دور با گرادیان صفر آغاز می‌شود، هرگز به داده نمی‌رسد.

ب) هدایت با دسته‌بند

آ

از Bayes، $\log p(x \mid c) = \log p(x) + \log p(c \mid x) - \log p(c)$، پس:

$$\nabla_x \log p(x \mid c) = \nabla_x \log p(x) + \nabla_x \log p(c \mid x)$$

جملهٔ اول واقعی‌بودن را تضمین می‌کند، جملهٔ دوم به سمت کلاس c می‌برد.

ب

امتیاز هدایت‌شده معادل نمونه‌برداری از $\tilde{p}(x_t \mid c) \propto p(x_t)\, p(c \mid x_t)^w$ است:

$$w \to \infty \implies \tilde{p} \to \delta\big(x - \arg\max_x p(c \mid x)\big)$$

یعنی mode collapse: کیفیت/وفاداری بالا، تنوع به صفر.

ج

دسته‌بند روی تصاویر تمیز آموزش دیده ولی ورودی x_t نویزی و off-distribution است؛ گرادیانش بی‌اعتبار/گمراه‌کننده بوده و حرکت در جهت آن دقیقاً ساختن adversarial example است.

ج) CFG

آ

از Bayes: $\nabla \log p(c \mid x_t) = \nabla \log p(x_t \mid c) - \nabla \log p(x_t)$. با جایگذاری $\nabla \log p \approx -\epsilon/\sigma$ و ساده‌سازی $\hat{\nabla} \log p(x_t \mid c) = \nabla \log p(x_t) + w \nabla \log p(c \mid x_t)$ در فضای نویز:

$$\boxed{\hat{\epsilon}(x_t, t, c) = \epsilon_\theta(x_t, t, \emptyset) + w\big(\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)\big)}$$

ب

همان توزیع $\tilde{p} \propto p(x_t) p(c \mid x_t)^w$ حاکم است؛ $w \to \infty$ آن را روی $\arg\max p(c \mid x_t)$ متمرکز می‌کند — نمونهٔ دترمینیستیک و نوعی، نه تصادفی از $p(x_t \mid c)$؛ همان overcooked.

آ

dropout تصادفی شرط c، یک شبکه را وادار می‌کند هم $\epsilon_\theta(\cdot, c)$ و هم $\epsilon_\theta(\cdot, \emptyset)$ را یاد بگیرد؛ تفاضلشان implicit classifier است — این همان «هک هوشمندانه».

ب

(۱) نیازی به دسته‌بند جداگانه نیست. (۲) جهت هدایت از مدلی می‌آید که خودش روی x_t نویزی آموزش دیده، پس off-distribution نبوده و گرادیان adversarial تولید نمی‌کند.

د) مقایسه و طراحی

آ

ویژگی	Classifier Guidance	CFG
دسته‌بند جداگانه؟	بله	خیر
آموزش روی تصاویر نویزی؟	بله، لازم است	موضوعیت ندارد
تعداد مدل‌ها	دو	یک
خطر گرادیان خصمانه؟	بالا	کم

ب

آ w بزرگ: $\tilde{p} \propto p\,p(c \mid x)^w$ روی mode کلاس تیز می‌شود — کیفیت بالا، تنوع پایین، دقیقاً مطلوب.

ب $w \approx ۱$: توان نزدیک یک، $\tilde{p}$ نزدیک به $p(x \mid c)$ واقعی می‌ماند و تنوع حفظ می‌شود.

ج ترکیب مرحله‌ای: DDPM تصادفی در گام‌های اولیه (نویز بالا) برای تنوع، DDIM دترمینیستیک در گام‌های پایانی (نویز کم) برای پرداخت کیفیت؛ همراه با w کوچک در ابتدا و بزرگ‌تر در انتها.