پاسخ مسئله‌ی ۱.

الف

چون $\forall i : W_i^Q = W^Q, W_i^K = W^K, W_i^V = W^V$، همهٔ هاheadخروجی یکسان H دارند:

$$\text{MHA} = \text{Concat}(H, \dots, H)\, W^O = H \underbrace{\sum_{b=1}^{h} W_b^O}_{=: \widetilde{W}^O} = \text{Attention}(QW^Q, KW^K, VW^V)\, \widetilde{W}^O$$

این معادل یک single-head attention با projection خروجی $\widetilde{W}^O$ است. نتیجه: ارزش MHA از تنوع زیرفضاهای ،هاستheadنه از تعداد آن‌ها.

ب

اهمیت هر هد را با گرادیان و افزونگی را با شباهت کسینوسی ماتریس attention می‌سنجیم:

$$I_i = \left| \mathbb{E}\left[H_i^\top \tfrac{\partial \mathcal{L}}{\partial H_i} \right] \right|, \qquad \rho_i = \max_{j \neq i} \cos\big(\text{vec}(A_i), \text{vec}(A_j)\big)$$

$$s_i = I_i - \lambda\, \rho_i \implies \mathcal{K} = \underset{i}{\text{top-k}}\ s_i$$

حذف تکراری (بازمحاسبهٔ ρ_i پس از هر حذف) از نگه‌داشتن هایheadپراهمیت ولی هم‌رفتار جلوگیری می‌کند.

ج

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \alpha \sum_i z_i + \beta \sum_{i<j} z_i z_j R(i,j)$$

جملهٔ دوم تنکی می‌سازد؛ جملهٔ سوم جریمهٔ افزونگی است. پس از آموزش، k مقدار بزرگ‌تر z_i انتخاب می‌شوند.

اگر $A_a = A_b$، آنگاه $R(a,b) = 1$ و $\mathcal{L}_{\text{task}}$ تنها به $z_a + z_b = c$ وابسته است:

$$\min_{z_a + z_b = c} z_a z_b \implies (z_a, z_b) \in \{(c, 0), (0, c)\}$$

پس جریمهٔ افزونگی یکی از دو هدِ هم‌رفتار را به صفر می‌راند و نگه‌داشتن هر دو را نامطلوب می‌کند.

پاسخ مسئله‌ی ۲.

الف

در Post-LN، با $x_{l+1} = \mathrm{LN}(x_l + \mathrm{Sublayer}(x_l))$:

$$\frac{\partial \mathcal{L}}{\partial x_l} = \frac{\partial \mathcal{L}}{\partial x_{l+1}} \, J_{\mathrm{LN}}(u_l)(I + J_{\mathrm{Sub},l}) \,, \qquad u_l = x_l + \mathrm{Sublayer}(x_l)$$

ژاکوبین LayerNorm برابر است با:

$$J_{\mathrm{LN}}(u) = \frac{\gamma}{\sigma}\big(I - \tfrac{1}{d}\mathbf{1}\mathbf{1}^\top - \tfrac{1}{d}\hat{u}\hat{u}^\top\big)$$

ضریب γ/σ هم اندازه و هم جهت گرادیان را تغییر می‌دهد؛ در L لایه این ضرایب انباشته می‌شوند و گرادیان را در معرض محو یا انفجار می‌گذارند.

در Pre-LN، با $x_{l+1} = x_l + \mathrm{Sublayer}(\mathrm{LN}(x_l))$:

$$\frac{\partial \mathcal{L}}{\partial x_l} = \frac{\partial \mathcal{L}}{\partial x_{l+1}} (I + J_{\mathrm{Sub},l} \, J_{\mathrm{LN}}(x_l))$$

جملهٔ I خارج از LN است؛ مسیر residual مستقیماً بدون عبور از J_{LN} منتقل می‌شود و گرادیان کران‌دار می‌ماند. این پایداری نیاز به warmup را حذف می‌کند، زیرا در Post-LN گرادیان‌های اولیه در لایه‌های نزدیک به خروجی بزرگ‌اند و warmup برای مهار آن‌ها لازم است.

ب

(۱) در Pre-LN، $\mathrm{Var}(x_l) \sim l$ رشد می‌کند پس $\|J_{\mathrm{LN}}\| \sim 1/\sqrt{l}$؛ سهم لایه‌های عمیق در تبدیل ویژگی کوچک می‌شود و عمق مؤثر کاهش می‌یابد.

(۲) مسیر residual نرمال نمی‌شود و دامنهٔ x_L با L رشد می‌کند؛ توزیع ورودی لایهٔ نهایی بدمقیاس است و ظرفیت مدل را در لایه‌های آخر محدود می‌کند.

(۳) نرمال‌سازی پیاپی در Post-LN نوفه‌ای تنظیم‌کننده تولید می‌کند؛ Pre-LN با مسیر مستقیم این اثر را تضعیف می‌کند و قدرت تعمیم اندکی کاهش می‌یابد.

ج

Fixup initialization: وزن‌های آخرین لایهٔ هر شاخهٔ residual صفر و بقیه با $L^{-\frac{1}{2m-2}}$ مقیاس می‌شوند:

$$W_l \leftarrow L^{-\frac{1}{2m-2}} W_l^{(\cdot)}$$

در آغاز هر بلوک همانی است، پس $\mathrm{Var}(x_{l+1}) \approx \mathrm{Var}(x_l)$ و گرادیان بدون عبور از هیچ LN کران‌دار می‌ماند.

از دید نظری، ناپایداری از واگراییِ $\prod_l \|\partial x_{l+1}/\partial x_l\|$ ناشی می‌شود. LayerNorm این حاصل‌ضرب را کنترل می‌کند، اما شرطِ لازم نیست؛ هر طرحی که هم‌زمان واریانسِ پیش‌رو و نُرمِ گرادیانِ پس‌رو را در عمق ثابت نگه دارد — مانند T-Fixup و DeepNorm — آموزش پایدار می‌دهد.

پاسخ مسئله‌ی ۳.

الف

(۱) $dk = ۴۰۹۶^۲ = ۱۶,۷۷۷,۲۱۶$

(۲) $r(d+k) = ۸ \times ۸۱۹۲ = ۶۵,۵۳۶$

(۳) $۱ - \frac{۶۵,۵۳۶}{۱۶,۷۷۷,۲۱۶} \approx ۹۹/۶۱٪$

ب

چون $\text{rank}(BA) \leq r \ll \min(d,k)$، فضای تغییرات کم‌بعد است. اگر adaptation ذاتاً کم‌رتبه باشد، BA آن را به‌خوبی تقریب می‌زند.

(I) $y = Wx + BAx$ $\rightarrow$ دو ضرب، سربار تأخیر، حافظهٔ جداگانه، تعویض آنی $adapter$

(II) $y = (W+BA)x$ $\rightarrow$ یک ضرب، بدون سربار، چند $adapter$ نیاز به بازسازی دارد

ج

$$P_N = r\big(۱ - (۱-p)^N\big), \quad p = ۰/۳۵,\ r = ۰/۸$$

$$P_۱ = ۰/۲۸۰, \quad P_۲ = ۰/۴۶۲, \quad P_۴ = ۰/۶۵۷, \quad P_۸ = ۰/۷۷۴$$

$$P_N - P_{N-۱} = rp(۱-p)^{N-۱} \ \searrow\ ۰ \quad (N \uparrow)$$

د

$C_A = ۲۰۰k + ۶۰۰ \leq ۶۰۰۰ \ \Rightarrow\ k \leq ۲۷$, با قید $k \leq ۵ \ \Rightarrow\ k^* = ۵$

$p_A^* = ۰/۳۵ + ۰/۰۸ \times ۵ = ۰/۷۵$

$C_B = ۶۰۰N \leq ۶۰۰۰ \ \Rightarrow\ N^* = ۱۰$

$P_{۱۰} = ۰/۸\big(۱ - ۰/۵۵^{۱۰}\big) \approx ۰/۷۹۸$

$۰/۷۹۸ > ۰/۷۵ \ \Rightarrow$ راهبرد دوم بهتر است.

LoRA برای وظایف تکراری با آموزش یک‌بارهٔ مقرون‌به‌صرفه مناسب است؛ inference-time scaling برای وظایف متنوع و غیرتکراری که verifier دارند. ترکیب هر دو نیز ممکن است.

پاسخ مسئله‌ی ۴.

الف

چون $hd_k = d$، چهار مرحله:

$$\text{QKV} = ۳bnd^۲, \quad QK^\top = bn^۲d, \quad AV = bn^۲d, \quad \text{Out} = bnd^۲$$

$$\begin{aligned}\text{MAC}_{\text{full}} &= ۴bnd^۲ + ۲bn^۲d \\ &= ۴(۴)(۴۰۹۶)(۱۰۲۴)^۲ + ۲(۴)(۴۰۹۶)^۲(۱۰۲۴) \approx ۲/۰۷ \times ۱۰^{۱۴}\end{aligned}$$

ب

پنجرهٔ w جایگزین n در جملات توجه می‌شود:

$$\begin{aligned}\text{MAC}_{\text{local}} &= ۴bnd^۲ + ۲bnwd \\ &\approx ۷/۰۴ \times ۱۰^{۱۳} + ۴/۲۹ \times ۱۰^{۱۲} \approx ۷/۴۷ \times ۱۰^{۱۳}\end{aligned}$$

جملهٔ دوم از $O(n^۲)$ به $O(nw)$ خطی کاهش یافت.

ج

هر جمله ضرب ماتریس $d \times d$، پس:

$$\text{MAC}_{\text{conv}} = bnwd^۲ = ۴(۴۰۹۶)(۱۲۸)(۱۰۲۴)^۲ \approx ۲/۲۰ \times ۱۰^{۱۵}$$

از هر دو حالت بیشتر است؛ چون کرنل $C_r \in \mathbb{R}^{d\times d}$ در هر گام channel mixing کامل انجام می‌دهد ($d^۲$ به ازای هر جفت)، حال‌آنکه در attention آمیختن کانالی فقط در $W^{Q,K,V,O}$ رخ می‌دهد و تعامل توکن‌ها روی $d_k \ll d^۲$ است.

د

با $a_r = \text{softmax}_r(\beta_r)$ که مستقل از t است:

$$H_t = \sum_{r=۰}^{w-۱} a_r \, Z_{t-r} W^V = \sum_{r=۰}^{w-۱} Z_{t-r}(a_r W^V)$$

یک causal convolution با $C_r = a_r W^V$ است. پس از ادغام h هد:

$$\text{MHA}(Z)_t = \sum_{r=۰}^{w-۱} Z_{t-r}\, C_r, \qquad C_r = \sum_{i=۱}^{h} a_r^{(i)} W_i^V W_i^O \in \mathbb{R}^{d\times d}$$

۵

در حالت کلی $\alpha_{t,j}(Z)$ به محتوای z_t, z_j وابسته است نه فقط به $t-j$؛ پس کرنل مؤثر $C_{t,j} = \alpha_{t,j}(Z)W^V$ برای هر ورودی تغییر می‌کند. این رفتار یک dynamic/input-dependent convolution است، نه کانولوشن ثابت. تنها در حالت تباهیدهٔ بند د که α از Z مستقل می‌شود، به کانولوشن ثابت فرو می‌کاهد.

پاسخ مسئله‌ی ۵.

الف

هر وظیفه: پارامتر ۳۵۰×۱۰^۶

مجموع برای ۲۰ وظیفه: $۲۰ \times ۳۵۰ \times ۱۰^۶ = ۷ \times ۱۰^۹ = ۷$ میلیارد

ب

(۱) $m \times d = ۵۰ \times ۱۰۲۴ = ۵۱,۲۰۰$

(۲) $۲۰ \times ۵۱,۲۰۰ = ۱,۰۲۴,۰۰۰ \approx ۱/۰۲ \times ۱۰^۶$

ج

در هر لایه دو بردار prefix (Key و Value) با طول $p = ۱۰$ و بعد $d = ۱۰۲۴$، و $L = ۲۴$ لایه:

(۱) $L \times ۲ \times p \times d = ۲۴ \times ۲ \times ۱۰ \times ۱۰۲۴ = ۴۹۱,۵۲۰$

(۲) $۲۰ \times ۴۹۱,۵۲۰ = ۹,۸۳۰,۴۰۰ \approx ۹/۸۳ \times ۱۰^۶$

د

نسبت پارامترهای اختصاصی هر روش به full fine-tuning برابر ۳۵۰×۱۰^۶:

(۱) $\frac{۵۱,۲۰۰}{۳۵۰ \times ۱۰^۶} = ۱/۴۶ \times ۱۰^{-۴} \approx \frac{۱}{۶۸۳۶}$

(۲) $\frac{۴۹۱,۵۲۰}{۳۵۰ \times ۱۰^۶} = ۱/۴۰ \times ۱۰^{-۳} \approx \frac{۱}{۷۱۲}$

یعنی Prompt Tuning حدود ۶۸۳۶ برابر و Prefix Tuning حدود ۷۱۲ برابر صرفه‌جویی در ذخیره‌سازی دارند.

ه

تفاوت اصلی: در Prompt Tuning تنها چند بردار به ورودیِ لایهٔ نخست (embedding) افزوده می‌شود و مدل تنها از طریق همان ورودی تأثیر می‌پذیرد؛ اما در Prefix Tuning بردارهای قابل‌آموزش به Key و Value ِattention در همهٔ لایه‌ها تزریق می‌شوند و مستقیماً بر محاسبات داخلی هر لایه اثر می‌گذارند.

Prompt Tuning — مزیت: کمترین تعداد پارامتر و سبک‌ترین ذخیره‌سازی؛ محدودیت: ظرفیت بیان پایین و ناپایداری/ضعف در مدل‌های کوچک‌تر.

Prefix Tuning — مزیت: تأثیرگذاری در تمام لایه‌ها و در نتیجه دقت و انعطاف بالاتر روی وظایف دشوار؛ محدودیت: تعداد پارامتر و حافظهٔ بیشتر (در اینجا حدود ۶/۹ برابر).

پاسخ مسئله‌ی ۶.

الف

گزینهٔ (۱) — Convolutional Stem — را انتخاب می‌کنیم.

(۱) تبدیل ورودی: چند لایهٔ ۳ × ۳ کانولوشن تصویر را به توکن تبدیل می‌کنند:

$$x \in \mathbb{R}^{H\times W\times ۳} \xrightarrow{convstem} \{z_i\}_{i=۱}^{n}, \quad z_i \in \mathbb{R}^d$$

(۲) اطلاعات مکانی: میدان دریافت هم‌پوشان هر کانولوشن، همسایگی پیکسلی را در هر توکن رمزگذاری می‌کند؛ برخلاف patchify خطی که مرز patchها را می‌گسلد.

(۳) Inductive bias افزوده: locality و translation equivariance از وزن‌های مشترک کانولوشن.

(۴) اثر بر داده: سوگیری محلی فضای فرضیه را محدود می‌کند و نیاز به پیش‌آموزش گسترده (مشکل اصلی ViT ساده) را کاهش می‌دهد.

(۵) محدودیت: هزینهٔ محاسباتی اندک افزوده و انعطاف یادگیری الگوهای سراسری در لایه‌های ابتدایی کمی کاهش می‌یابد.

ب

در لایهٔ اول attention فقط درون پنجره است، پس $x_۴ \in W_۱$ و $x_۵ \in W_۲$ با هم ارتباط ندارند. پس از shift به اندازهٔ ۲:

$$W' = [x_۳, x_۴, x_۵, x_۶] \implies \mathrm{Attn}(x_۴, x_۵) \neq ۰$$

با تکرار این دو لایه، میدان دریافت خطی گسترش می‌یابد:

$$R_L \approx ۱ + L(w-۱), \qquad \text{هزینه: } \mathcal{O}(n^۲) \to \mathcal{O}(nw)$$

شباهت با CNN: توجه موضعی محدود؛ تفاوت: وزن‌های attention پویا و وابسته به محتوا هستند، نه ثابت.

ج

هر object query یک بردار آموختنی است که از طریق cross-attention با ویژگی‌های تصویر، حداکثر یک شیء پیش‌بینی می‌کند:

$$q_i \xrightarrow{decoder} \hat{y}_i = (\hat{p}_i, \hat{b}_i)$$

خروجی مجموعه‌ای (نه دنباله‌ای) است، زیرا queryها فاقد ترتیب ذاتی‌اند و آموزش با تطابق یک‌به‌یک متقارن نسبت به جایگشت انجام می‌شود.

د

Hungarian Matching جایگشت بهینه را می‌یابد تا هزینهٔ کل کمینه شود:

$$\hat{\sigma} = \arg\min_{\sigma \in \mathfrak{S}_N} \sum_{j=1}^{m} \mathcal{C}_{\sigma(j),j}, \qquad \mathcal{C}_{ij} = -\log \hat{p}_i(c_j) + \lambda_1 \|\hat{b}_i - b_j\|_1 + \lambda_{\text{giou}}\big(1 - \text{GIoU}(\hat{b}_i, b_j)\big)$$

سه جمله: classification cost کلاس را تطبیق می‌دهد؛ L1 خطای مطلق جعبه را می‌سنجد؛ GIoU هم‌پوشانی هندسی را، مستقل از مقیاس، اندازه می‌گیرد. queryهای بدون تطابق ($N - m$ مورد) به کلاس $\varnothing$ اختصاص می‌یابند.

ه

پس از یافتن $\hat{\sigma}$، تابع زیان نهایی:

$$\mathcal{L} = \sum_{i=1}^{N} \Big[-\log \hat{p}_i\big(c_{\hat{\sigma}^{-1}(i)}\big) + \mathbb{1}_{\{c_i \neq \varnothing\}} \big(\lambda_1 \|\hat{b}_i - b_{\hat{\sigma}^{-1}(i)}\|_1 + \lambda_{\text{giou}}(1 - \text{GIoU})\big) \Big]$$

(۱) Cross-entropy برای همهٔ N query؛ (۲) زیان جعبه فقط برای queryهای تطابق‌یافته ($\mathbb{1}_{\{c_i \neq \varnothing\}}$)؛ (۳) کلاس $\varnothing$ تشخیص‌های کاذب را سرکوب می‌کند؛ چون $N \gg m$، وزنش کاهش می‌یابد؛ (۴) λ_1 و λ_{giou} تعادل میان دقت طبقه‌بندی و دقت مکانی را کنترل می‌کنند.

ضعف DETR: همگرایی کند و کارایی پایین در اشیای کوچک، زیرا encoder روی نقشهٔ تک‌مقیاس با $\mathcal{O}(n^2)$ کار می‌کند. بهبود پیشنهادی — Deformable Attention: هر query فقط به K نقطهٔ آموختنی روی چند مقیاس از feature pyramid توجه می‌کند:

$$\mathcal{O}(n^2) \longrightarrow \mathcal{O}(nK), \quad K \ll n$$

این تغییر ویژگی‌های با تفکیک بالا را برای اشیای کوچک حفظ و سرعت همگرایی را به‌شدت افزایش می‌دهد.

پاسخ مسئله‌ی ۷.

الف

با اتحاد جمع زاویه:

$$p_i(t+k) = \begin{bmatrix} \sin(\omega_i t)\cos(\omega_i k) + \cos(\omega_i t)\sin(\omega_i k) \\ \cos(\omega_i t)\cos(\omega_i k) - \sin(\omega_i t)\sin(\omega_i k) \end{bmatrix} = \underbrace{\begin{bmatrix} \cos\omega_i k & \sin\omega_i k \\ -\sin\omega_i k & \cos\omega_i k \end{bmatrix}}_{A_i(k)} p_i(t)$$

خاصیت جمعی مستقیم از ضرب دو ماتریس دوران نتیجه می‌شود:

$$A_i(k_1)A_i(k_2) = R(\omega_i k_1)R(\omega_i k_2) = R(\omega_i(k_1+k_2)) = A_i(k_1+k_2)$$

این رابطه نشان می‌دهد جابه‌جایی موقعیت یک دوران خطی است که فقط به اندازهٔ جابه‌جایی k وابسته است، نه به موقعیت مطلق t.

ب

$$p_i(m)^\top p_i(n) = \sin\omega_i m \sin\omega_i n + \cos\omega_i m \cos\omega_i n = \cos(\omega_i(m-n))$$

$$PE(m)^\top PE(n) = \sum_i p_i(m)^\top p_i(n) = \sum_i \cos(\omega_i(m-n))$$

شباهت تنها به $m-n$ وابسته است، نه به موقعیت‌های مطلق.

ج

$$p_i(m)^\top B_i p_i(n) = a_i \cos(\omega_i(m-n)) + b_i \sin(\omega_i(n-m))$$

هر دو جمله تنها به $m-n$ وابسته‌اند، پس g_B فقط تابع فاصلهٔ نسبی است. برای B دلخواه این الزامی نیست؛ هر بلوکی خارج از $\mathrm{span}\{I, J\}$ جملاتی نظیر $\cos(\omega_i(m+n))$ پدید می‌آورد.

د

چون $R(\phi)^\top = R(-\phi)$ و $R(\alpha)R(\beta) = R(\alpha+\beta)$:

$$\tilde{q}_m^\top \tilde{k}_n = q^\top R(m\theta)^\top R(n\theta)\, k = q^\top R((n-m)\theta)\, k$$

attention score دقیقاً فقط تابع فاصلهٔ نسبی $n-m$ است.

ه

چون ماتریس دوران کل بلوک‌قطری است:

$$\tilde{q}_m^\top \tilde{k}_n = \sum_{i=0}^{d/2-1} (q^{(i)})^\top R((n-m)\theta_i)\, k^{(i)}$$

نقطهٔ ورود اطلاعات مکانی در هر روش:

$$absolute/sinusoidal \longrightarrow inputembedding$$

$$RoPE \longrightarrow query/key \Rightarrow attentionscore$$

در دو روش نخست اطلاعات مطلق پیش از W^Q, W^K وارد می‌شود و وابستگی نسبی ضمنی است. در RoPE وابستگی به $n-m$ ساختاری و دقیق است، پارامتر وابسته به طول ثابتی وجود ندارد و مدل به context بلندتر تعمیم می‌یابد.