بسم الله الرحمن الرحیم

دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری عمیق
نیم‌سال دوم ۰۵-۰۴
مدرس: مهدیه سلیمانی

تمرین اول | ددلاین تمرین : ۱۹ تیر

- برای ارسال هر تمرین تا ساعت ۲۳:۵۹ روز ددلاین فرصت دارید. مهلت تاخیر (مجاز و غیر مجاز) برای این تمرین ۳ روز است (یعنی حداکثر تاریخ ارسال تمرین ۲۲ تیر است)
- در هر کدام از سوالات، اگر از منابع خارجی استفاده کرده‌اید باید آن را ذکر کنید. در صورت همفکری با افراد دیگر هم باید نام ایشان را در سوال مورد نظر ذکر نمایید.
- پاسخ تمرین باید ماحصل دانسته‌های خود شما باشد. در صورت رعایت این موضوع، استفاده از ابزارهای هوش مصنوعی با ذکر نحوه و مصداق استفاده بلامانع است.
- پاسخ ارسالی واضح و خوانا باشد. در غیر این صورت ممکن است منجر به از دست دادن نمره شود.
- از تحویل تمارین نظری به شکل تایپ شده (فایل Word-Latex یا هر نوع تایپ شده دیگری) بپرهیزید و حتما پاسخ دست نویس تحویل دهید.
- پاسخ ارسالی باید توسط خود شما نوشته شده باشد. به اسکرین‌شات از منابع یا پاسخ افراد دیگر نمره‌ای تعلق نمی‌گیرد.
- در صورتی که بخشی از سوال‌ها را جای دیگری آپلود کرده و لینک آن را قرار داده باشید، حتما باید تاریخ آپلود مشخص و قابل اتکا باشد.
- محل بارگذاری سوالات نظری و عملی در هر تمرین مجزا خواهد بود. به منظور بارگذاری بایستی تمارین تئوری در یک فایل pdf با نام HW1_[First-Name]_[Last-Name]_[Student-Id].pdf بارگذاری شوند.
- در صورت وجود هرگونه ابهام یا مشکل، در کوئرای درس آن مشکل را بیان کنید و از پیغام دادن مستقیم به دستیاران آموزشی خودداری کنید.
- طراحان این تمرین : محمد محمدبیگی - محمد امانلو - مریم ولی - محمد شیرخانی - عرشیا یوسف نیا - حسین شاه‌آبادی

بخش نظری (۱۲۰ نمره)

پرسش ۱ : تحلیل ریاضی و مفهومی CLIP، Prompt Learning و اهداف آموزش در مدل‌های بینایی–زبان (۳۰ نمره)

یک مدل بینایی–زبان از نوع dual-encoder مانند CLIP را در نظر بگیرید. این مدل برای هر تصویر I_i و متن T_j، دو نمایش نرمال‌شده تولید می‌کند:

$$z_i^I = \frac{f_\theta(I_i)}{\|f_\theta(I_i)\|}, \qquad z_j^T = \frac{g_\phi(T_j)}{\|g_\phi(T_j)\|}$$

و امتیاز تطابق تصویر و متن را به‌صورت زیر تعریف می‌کند:

$$s_{ij} = \tau (z_i^I)^\top z_j^T$$

که در آن τ یک پارامتر دما یا temperature scale است. مدل با تابع هزینه‌ی کنتراستی متقارن آموزش داده می‌شود:

$$\mathcal{L}_{I\to T} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp(s_{ii})}{\sum_{j=1}^{N}\exp(s_{ij})}$$

$$\mathcal{L}_{T\to I} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp(s_{ii})}{\sum_{j=1}^{N}\exp(s_{ji})}$$

$$\mathcal{L}_{CLIP} = \frac{1}{2}\left(\mathcal{L}_{I\to T} + \mathcal{L}_{T\to I}\right)$$

اکنون فرض کنید در داده‌ی آموزشی، عبارت‌هایی مانند موارد زیر به‌عنوان نمونه‌های منفی سخت یا hard negative ظاهر می‌شوند:

```
blue sphere above red cube
```

```
red cube above blue sphere
```

همچنین فرض کنید برای zero-shot classification به‌جای prompt دستی مانند

```
a photo of a {class}
```

از prompt learning استفاده می‌شود و ورودی text encoder به‌شکل زیر است:

$$[C_1, C_2, \ldots, C_m, \text{class}]$$

که در آن $C_1, \ldots, C_m$ بردارهای قابل‌آموزش هستند.

آ) توضیح دهید چرا تابع هزینه‌ی کنتراستی CLIP برای image-text retrieval و zero-shot classification مناسب است، اما ممکن است برای یادگیری روابط ترکیبی و فضایی مانند above و below ضعیف عمل کند. در پاسخ خود به نقش hard negatives و ساختار فضای embedding اشاره کنید.

ب) نشان دهید که اگر تعداد نمونه‌های منفی آسان در batch زیاد باشد، گرادیان تابع هزینه ممکن است بیشتر توسط نمونه‌های ساده کنترل شود و مدل به‌جای یادگیری روابط دقیق، روی هم‌بستگی‌های سطحی مثل هویت شیء یا رنگ تمرکز کند. توضیح خود را با تکیه بر مخرج softmax در تابع هزینه‌ی بالا ارائه دهید.

ج) منظور از compositionality (ترکیب‌پذیری) این است که معنای یک عبارت از ترکیب معنای اجزای آن به‌همراه نحوه‌ی چیدمان و روابط میان آن‌ها ساخته می‌شود؛ برای نمونه دو عبارت `blue sphere above red cube` و `red cube above blue sphere` دقیقا از اجزای یکسان تشکیل شده‌اند و تنها در رابطه‌ی میان اشیا تفاوت دارند. همچنین منظور از «رابطه» در اینجا ساختار رابطه‌ای یا فضایی میان اشیاست (مانند above، below، left of، right of) که مشخص می‌کند اشیا چگونه نسبت به یکدیگر قرار گرفته‌اند، و نه خودِ اشیا یا ویژگی‌هایی مانند رنگ. با در نظر گرفتن این توضیحات، بیان کنید چگونه می‌توان داده یا تابع هزینه را طوری تغییر داد که مدل نسبت به compositionality حساس‌تر شود. حداقل دو راهکار پیشنهاد دهید؛ مثلا hard negative mining، تابع هزینه‌ی کنتراستی آگاه از رابطه، یا ساخت داده‌های جفتی که فقط در رابطه‌ی فضایی تفاوت دارند.

د) در prompt learning توضیح دهید چرا بردارهای قابل‌آموزش $C_1, \ldots, C_m$ می‌توانند در حالت few-shot learning از promptهای دستی بهتر عمل کنند. سپس تحلیل کنید چرا همین روش ممکن است روی دامنه‌ی جدید یا کلاس‌های دیده‌نشده باعث overfitting شود.

ه) ابتدا دو نسخه‌ی unified context و class-specific context را در بستر prompt learning تعریف کنید: در حالت unified context یک مجموعه‌ی واحد از بردارهای بافتار قابل‌آموزش $C_1, \ldots, C_m$ میان همه‌ی کلاس‌ها به اشتراک گذاشته می‌شود، در حالی که در حالت class-specific context برای هر کلاس یک مجموعه‌ی مجزا از بردارهای بافتار قابل‌آموزش یاد گرفته می‌شود. سپس این دو حالت را مقایسه کنید و از دیدگاه bias-variance trade-off توضیح دهید کدام روش ظرفیت بیشتری دارد، کدام روش پایدارتر است، و در چه شرایطی هرکدام مناسب‌تر است.

و) حالا فرض کنید مدل علاوه بر تابع هزینه‌ی کنتراستی، یک decoder زبانی هم دارد و با تابع هزینه‌ی تولیدی زیر آموزش می‌بینند:

$$\mathcal{L}_{gen} = -\sum_{t=1}^{L} \log p_\psi(w_t \mid w_{<t}, I)$$

یک هدف ترکیبی به‌شکل زیر تعریف می‌کنیم:

$$\mathcal{L} = \lambda_c \mathcal{L}_{CLIP} + \lambda_g \mathcal{L}_{gen}$$

تحلیل کنید افزایش یا کاهش λ_c و λ_g چه اثری روی قابلیت‌های زیر دارد:

۱. zero-shot classification
۲. image-text retrieval
۳. caption generation
۴. یادگیری با داده‌ی برچسب‌دار محدود

ز) توضیح دهید چرا ترکیب هدف کنتراستی و هدف تولیدی می‌تواند در برخی کاربردها مفید باشد، اما در برخی موارد باعث کاهش specialization مدل شود.

پرسش ۲: طراحی و انتخاب معماری مدل‌های بینایی–زبان با توجه به ظرفیت، گلوگاه اطلاعاتی و داده‌ی آموزشی (۳۰ نمره)

سه معماری زیر را در نظر بگیرید:

۱) **مدل CLIP-style:** یک image encoder و یک text encoder دارد و با هدف کنتراستی آموزش داده می‌شود.

۲) **مدل BLIP-2-style:** یک image encoder ثابت یا نیمه‌ثابت دارد و از یک Q-Former با تعداد محدودی query token برای اتصال تصویر به LLM استفاده می‌کند.

۳) **مدل LLaVA-style:** ویژگی‌های image encoder با یک projector به فضای LLM منتقل می‌شوند و مدل با داده‌های چندرسانه‌ای instruction-following تنظیم یا fine-tune می‌شود.

در معماری BLIP-2، فرض کنید image encoder مجموعه‌ای از ویژگی‌های تصویری تولید می‌کند:

$$V = [v_1, v_2, \ldots, v_K], \qquad v_i \in \mathbb{R}^d$$

و Q-Former تعداد M بردار پرسش قابل‌آموزش دارد:

$$Q = [q_1, q_2, \ldots, q_M], \qquad q_i \in \mathbb{R}^d$$

خروجی Q-Former را می‌توان به‌صورت ساده‌شده‌ی زیر در نظر گرفت:

$$H = \mathrm{CrossAttention}(Q, V)$$

سپس H به LLM داده می‌شود. در مقابل، در روش ساده‌تر projector، ویژگی‌های تصویر مستقیما با یک نگاشت خطی یا MLP به فضای LLM منتقل می‌شوند:

$$P(V) = \mathrm{MLP}(V)$$

آ) روش projector ساده و روش Q-Former را مقایسه کنید. توضیح دهید چرا Q-Former در وظایفی مانند visual question answering و captioning معمولا قوی‌تر است.

ب) فرض کنید عملکرد مدل روی یک وظیفه به‌صورت تقریبی تابعی از تعداد query tokenها باشد:

$$\mathrm{Perf}(M) = a(1 - e^{-bM}) - cM$$

که در آن بخش اول نشان‌دهنده‌ی افزایش اطلاعات تصویری و بخش دوم نشان‌دهنده‌ی هزینه یا نویز ناشی از افزایش تعداد query tokenهاست. تفسیر کنید چرا این تابع ممکن است ابتدا افزایش یابد و سپس به حالت اشباع یا حتی افت برسد. از این تحلیل برای توضیح trade-off در انتخاب M استفاده کنید.

ج) برای سه کاربرد زیر، از بین CLIP، BLIP-2 و LLaVA مناسب‌ترین معماری را انتخاب کنید و دلیل بیاورید:

۱. zero-shot classification و image-text retrieval
۲. visual question answering با داده‌ی آموزشی محدود
۳. دستیار چندرسانه‌ای که باید دستورهای کاربر را دنبال کند و پاسخ گفت‌وگویی بدهد

در هر مورد توضیح دهید هدف آموزشی، نحوه‌ی اتصال بخش بینایی و زبان، و نوع داده‌ی موردنیاز چگونه با نیاز کاربرد سازگار است.

د) برای هر کاربرد بخش قبل، حداقل یک معماری نامناسب‌تر معرفی کنید و توضیح دهید چرا آن معماری با نیاز مسئله سازگاری کمتری دارد. مثلا چرا CLIP برای پاسخ‌گویی گفت‌وگویی کافی نیست، یا چرا LLaVA برای retrieval ساده ممکن است بیش‌ازحد سنگین باشد.

ه) فرض کنید محدودیت اصلی شما یکی از موارد زیر باشد. برای هر مورد توضیح دهید انتخاب معماری چگونه تغییر می‌کند:

۱. محدودیت شدید حافظه و محاسبات
۲. کمبود داده‌ی instruction-following
۳. نیاز بالا به رفتار گفت‌وگویی، reasoning و تبعیت از دستور کاربر

و) حالا یک هدف کلی برای آموزش یا fine-tuning یک مدل بینایی–زبان چندمنظوره پیشنهاد دهید که بتواند هم retrieval، هم captioning، و هم VQA/instruction-following را پوشش دهد. مثلا می‌توانید از فرم زیر استفاده کنید:

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{contrastive} + \lambda_2 \mathcal{L}_{caption} + \lambda_3 \mathcal{L}_{VQA} + \lambda_4 \mathcal{L}_{instruction}$$

توضیح دهید هر ضریب λ_i چه نقشی دارد و اگر یکی از آن‌ها بیش از حد بزرگ انتخاب شود، چه اثری روی specialization یا generalization مدل می‌گذارد.

ز) در پایان، یک معماری پیشنهادی برای حالتی طراحی کنید که داده محدود است، اما مدل باید هم تصویر را بفهمد، هم به سوال پاسخ دهد، و هم تا حدی قابلیت zero-shot داشته باشد. انتخاب خود را از نظر هدف آموزشی، داده‌ی آموزشی، ثابت یا قابل‌آموزش بودن image encoder و LLM، و هزینه‌ی محاسباتی توجیه کنید.

پرسش ۳: تکامل معماری‌های خودنظارتی: از رمزگذارهای مومنتوم تا بازسازی تصویر پوشانده شده (۳۵ نمره)

بخش اول: مومنتوم و پایداری در یادگیری مقابله‌ای (MoCo)

آ) روش MoCo با هدف جداسازی اندازه دسته از تعداد نمونه‌های منفی طراحی شده است.

i) مکانیسم به‌روزرسانی مومنتوم $\theta_k \leftarrow m\theta_k + (1-m)\theta_q$ را در نظر بگیرید. اگر ضریب مومنتوم $m = 0.999$ باشد، تبیین کنید که چرا این تغییرات بسیار کند برای پایداری صف (Queue) ضروری است؟

ii) فرض کنید در یک لحظه، رمزگذار پرس‌وجو (θ_q) به سمتی تغییر کند که بردار ویژگی q به مقدار δ جابجا شود. نشان دهید پس از T گام آموزش، تاثیر این جابجایی بر رمزگذار کلید (θ_k) با چه ضریبی اعمال می‌شود؟ بحث کنید چرا برای mهای نزدیک به ۱، مدل در برابر نوسانات ناگهانی مقاوم است.

بخش دوم: یادگیری بدون نمونه منفی (BYOL و DINO)

آ) مدل‌های BYOL و DINO بدون استفاده از نمونه‌های منفی آموزش می‌بینند.

i) (**اثبات فروپاشی‌ناپذیری در BYOL**) مدل خطی‌شده‌ی زیر را از BYOL در نظر بگیرید و تعاریف زیر را مبنا قرار دهید:

- ورودی $x \in \mathbb{R}^d$ با کوواریانس متقارن و مثبت‌معین $\Sigma = \mathbb{E}[xx^\top]$.
- شبکه‌ی آنلاین خطی با ماتریس وزن W (پارامتر θ) و خروجی $z = Wx$.
- شبکه‌ی هدف خطی با وزن W' (پارامتر ξ) که با میانگین متحرک نمایی به‌روزرسانی می‌شود، $W' = \eta(W - W')$، و خروجی آن $z' = W'x$ است که روی آن عملگر stop-gradient اعمال می‌شود.
- پیش‌بینی‌کننده‌ی خطی و متقارن P.
- تابع هزینه: $L(W,P) = \mathbb{E}\big[\|Pz - \mathrm{sg}(z')\|_2^2\big] = \mathrm{tr}\big[(PW - W')\,\Sigma\,(PW - W')^\top\big]$.

فرض ساده‌سازی: ماتریس‌های W، P و Σ هم‌زمان قطری‌شدنی‌اند؛ در پایه‌ی ویژه‌ی مشترک، Σ مقادیر ویژه‌ی $\lambda_j > 0$، ماتریس W مقادیر تکین w_j، و P مقادیر ویژه‌ی p_j دارد، و مقدار ویژه‌ی کوواریانسِ ویژگی را $\sigma_j = w_j^2\lambda_j$ تعریف می‌کنیم. همچنین رژیم هم‌ترازِ هدف ($W' \approx W$، ناشی از سریع‌بودن میانگین متحرک) را فرض کنید. موارد زیر را **اثبات** کنید:

۱. راه‌حل فروپاشیده‌ی $W = 0$ (نمایش ثابتِ صفر برای همه‌ی ورودی‌ها) یک نقطه‌ی تعادلِ دینامیک گرادیان است؛ یعنی نشان دهید در $W = W' = 0$ داریم $\nabla_W L = 0$ و $\nabla_P L = 0$. بنابراین فروپاشی یک نقطه‌ی بحرانی (critical point) تابع هزینه است.

۲. با محاسبه‌ی $\nabla_P L$، نشان دهید دینامیک پیش‌بینی‌کننده $\dot{P} = -\nabla_P L$ در رژیم هم‌تراز به‌صورت $\dot{P} = -2(P - I)F$ درمی‌آید که در آن $F = W\Sigma W^\top$. سپس اثبات کنید هر مؤلفه‌ی ویژه از رابطه‌ی $\dot{p}_j = -2\sigma_j(p_j - 1)$ پیروی می‌کند و نتیجه بگیرید که برای $\sigma_j > 0$ داریم $p_j(t) \to 1$ (همگرایی نمایی پیش‌بینی‌کننده به همانی روی زیرفضای فعال) و برای $\sigma_j = 0$ آن مؤلفه ثابت می‌ماند.

۳. با محاسبه‌ی $\nabla_W L$، نشان دهید دینامیک مؤلفه‌های نمایش به‌صورت $\dot{w}_j = -2\lambda_j\, p_j(p_j - 1)\, w_j$ به‌دست می‌آید. با تحلیل پایداری خطی حول نقطه‌ی فروپاشی $w_j = 0$، اثبات کنید نرخ رشد این مؤلفه برابر $-2\lambda_j\, p_j(p_j - 1)$ است و هرگاه $0 < p_j < 1$ باشد این نرخ اکیداً مثبت است. از این‌جا نتیجه بگیرید که در حضور پیش‌بینی‌کننده، نقطه‌ی فروپاشی یک نقطه‌ی زینی و ناپایدار (saddle / unstable equilibrium) است و جاذب (attractor) نیست؛ حال آن‌که اگر پیش‌بینی‌کننده حذف شود و $P = I$ ثابت بماند این سازوکارِ دفع‌کننده از میان می‌رود. بدین‌ترتیب اثبات می‌شود ترکیبِ پیش‌بینی‌کننده‌ی نامتقارن، stop-gradient و هدفِ مومنتومی از فروپاشی نمایش جلوگیری می‌کند.

ii) در مدل DINO، مکانیزم‌های «مرکزگرایی» (Centering) و «تیزسازی» (Sharpening) خروجی‌ها به صورت متضاد عمل می‌کنند. تحلیل کنید که تعادل بین این دو چگونه نقش «نمونه‌های منفی» را در جلوگیری از خروجی ثابت ایفا می‌کند؟

بخش سوم: بازگشت به بازسازی و مدل‌سازی پوشانده شده (MIM)

آ) روش‌های MAE و BEiT انقلابی در استفاده از ترانسفورمرها در SSL ایجاد کردند.

i) در مدل MAE، نرخ ماسک‌گذاری ٪۷۵ انتخاب می‌شود. تحلیل کنید که چرا نرخ‌های پایین (مثلاً ٪۱۵ مشابه متن) در تصاویر منجر به «یادگیری سطحی» (Trivial Interpolation) می‌شود؟

ii) فرض کنید یک تصویر به $N = 256$ وصله تقسیم شده است. در معماری MAE، اگر رمزگذار فقط روی وصله‌های مشاهده شده عمل کند و هزینه محاسباتی توجه (Attention) با توان دوم تعداد توکن‌ها رابطه داشته باشد، صرفه‌جویی محاسباتی بخش رمزگذار را نسبت به حالتی که کل تصویر پردازش شود، به صورت درصدی محاسبه کنید.

iii) با تحلیل جدول نتایج نهایی، تبیین کنید چرا روش‌های مبتنی بر بازسازی (MIM) در مقیاس‌های بسیار بزرگ (ViT-Huge) نسبت به روش‌های مقابله‌ای برتری مطلق دارند؟ (به مفهوم چگالی سیگنال اشاره کنید).

پرسش ۴: تحلیل بنیادی یادگیری مقابله‌ای: از نظریه اطلاعات تا بهینه‌سازی سخت‌افزاری (۲۵ نمره)

بخش اول: مبانی بازنمایی و وظایف بهانه‌ای

آ) در یادگیری خودنظارتی (SSL)، هدف اصلی استخراج ویژگی‌های «عام» است.

i) تفاوت مبنایی SSL با یادگیری مولد (Generative) را از منظر مدل‌سازی توزیع $p(x)$ تبیین کنید.

ii) با تحلیل وظایف بهانه‌ای (Pretext Tasks) مانند پیش‌بینی چرخش (Rotation)، توضیح دهید که چرا این روش‌ها به جای ویژگی‌های معنایی (Semantic)، دچار «سوگیری وظیفه‌محور» (Task-specific bias) می‌شوند؟

iii) در پروتکل ارزیابی Linear Probe، فرض کنید دقت مدل روی وظیفه بهانه‌ای پازل (Jigsaw) ٪۹۹ باشد اما در طبقه‌بندی خطی روی ImageNet تنها ٪۴۰. این تضاد را چگونه تفسیر می‌کنید؟

بخش دوم: کالبدشکافی ریاضی زیان InfoNCE و اطلاعات متقابل

آ) تابع ضرر InfoNCE به صورت زیر تعریف شده است:

$$L = -\mathbb{E}_X \left[\log \frac{\exp(s(f(x), f(x^+))/\tau)}{\exp(s(f(x), f(x^+))/\tau) + \sum_{j=1}^{N-1} \exp(s(f(x), f(x_j^-))/\tau)} \right]$$

i) فرض کنید برای یک نمونه مرجع، امتیاز شباهت با نمونه مثبت $s_+ = 0.9$ و با سه نمونه منفی به ترتیب $s_1 = 0.2, s_2 = 0.4, s_3 = 0.5$ باشد. با فرض دمای $\tau = 0.1$، مقدار عددی زیان L را محاسبه کنید. (از تقریب $e^9 \approx 8103, e^2 \approx 7, e^4 \approx 55, e^5 \approx 148$ استفاده کنید).

ii) ثابت کنید که اگر مدل کاملاً تصادفی عمل کند (یعنی تمام امتیازات s با هم برابر باشند)، مقدار زیان همواره برابر با $\log(N)$ خواهد بود.

iii) با تکیه بر رابطه $MI(f(x), f(x^+)) \geq \log(N) - L$، تحلیل کنید که چرا افزایش تعداد نمونه‌های منفی (N) منجر به بهبود بازنمایی ویژگی‌ها می‌شود؟ این موضوع چه رابطه‌ای با «تنگی حد پایین» (Tightness of Lower Bound) دارد؟

بخش سوم: تحلیل مهندسی و مدیریت حافظه در SimCLR

آ) معماری SimCLR به شدت به اندازه دسته (Batch Size) وابسته است.

i) نقش لایه پیش‌افکن غیرخطی $g(\cdot)$ را در حفظ اطلاعات معنایی در فضای h تحلیل کنید. چرا حذف این لایه پس از آموزش برای تسک‌های پایین‌دستی ضروری است؟

ii) فرض کنید می‌خواهیم SimCLR را با $N = 8192$ و ابعاد ویژگی $d = 2048$ آموزش دهیم. اگر هر عدد از نوع float32 (۴ بایت) باشد، حجم حافظه مورد نیاز برای ذخیره «ماتریس قرابت» (Affinity Matrix) بین تمام $2N$ نمونه در یک گام آموزش را بر حسب گیگابایت محاسبه کنید. (توجه: ابعاد ماتریس $2N \times 2N$ است).