پاسخ مسئله‌ی ۱.

الف

برای retrieval و zero-shot classification کافی است هم‌ترازی سراسری تصویر ـ متن خوب باشد:

$$p_{ij}^{I\to T}=\frac{\exp(s_{ij})}{\sum_{k=1}^{N}\exp(s_{ik})},\qquad \hat{T}(I_i)=\arg\max_j s_{ij}$$

$$\hat{y}(I)=\arg\max_c\ \tau z_I^\top z_T(c)$$

اما تابع هزینه فقط زوج درست را از کل منفی‌ها جدا می‌کند، نه الزاماً ساختار رابطه‌ای جمله را:

$$T_1=\text{blue sphere above red cube},\qquad T_2=\text{red cube above blue sphere}$$

$$\{\text{اشیا و رنگ‌ها در } T_1\}=\{\text{اشیا و رنگ‌ها در } T_2\}$$

$$z_T(T_1)\approx z_T(T_2)\implies s(I_1,T_1)\approx s(I_1,T_2)$$

پس اگر hard negatives رابطهٔ فضایی را عوض نکنند یا کم باشند، فضای embedding می‌تواند بیشتر بر هم‌وقوعی اشیا، رنگ و کلاس تکیه کند تا جهت رابطه‌هایی مثل below/above.

ب

برای یک تصویر:

$$\ell_i=-\log\frac{\exp(s_{ii})}{\sum_j\exp(s_{ij})}$$

$$p_{ij}=\frac{\exp(s_{ij})}{\sum_k\exp(s_{ik})}$$

$$\frac{\partial\ell_i}{\partial s_{ij}}=p_{ij}-[j=i]$$

$$\frac{\partial\ell_i}{\partial z_i^I}=\tau\left(\sum_j p_{ij}z_j^T-z_i^T\right)$$

اگر منفی‌های آسان زیاد باشند:

$$D = \exp\big(s^+\big) + N_e \exp(a) + N_h \exp(b)$$
$$M_e = \sum_{j \in E} p_{ij} = \frac{N_e \exp(a)}{D}, \qquad M_h = \frac{N_h \exp(b)}{D}$$
$$N_e \exp(a) \gg N_h \exp(b) \implies M_e \gg M_h$$
$$\frac{\partial \ell_i}{\partial z_i^I} \approx \tau \left(M_e \mu_E - z_i^T\right)$$

در این حالت جهت گرادیان را مرکز جرم منفی‌های آسان تعیین می‌کند. اگر μ_E عمدتاً بر شباهت‌های سطحی مثل رنگ یا هویت شیء بنا شده باشد، سیگنال رابطه‌ای حاصل از hard negatives در گرادیان ضعیف می‌شود.

ج

Compositionality یعنی:

$$\text{معنا}(o_1, r, o_2) = F\big(\text{معنا}(o_1), \text{معنا}(r), \text{معنا}(o_2), \text{ترتیب}\big)$$
$$z_T(o_1, r, o_2) \neq z_T(o_2, r, o_1), \qquad z_T(o_1, r, o_2) \neq z_T(o_1, r', o_2)$$

دو تغییر کافی:

$$\ell_i^{\text{hard}} = -\log \frac{\exp\big(s(I_i, T_i^+)\big)}{\exp\big(s(I_i, T_i^+)\big) + \sum_{T^- \in H_i} \exp(s(I_i, T^-))}$$
$$H_i = \{T^- : \text{اشیا و رنگ‌ها ثابت، رابطه یا ترتیب عوض شده است}\}$$

یا با margin رابطه‌ای:

$$\ell_i^{\text{rel}} = \sum_{T^- \in H_i} \max\left(0, \gamma - s(I_i, T_i^+) + s(I_i, T^-)\right)$$

همچنین دادهٔ پادواقعی می‌سازیم:

(I, T^+) : blue sphere above red cube

(I, T^-) : blue sphere below red cube

فقط در رابطهٔ فضایی، نه در اشیا و رنگ‌ها = تفاوت

د

در prompt learning:

$$T_c(C) = [C_1, \dots, C_m, c]$$
$$C^\star = \arg\min_C \sum_{(I,y)} -\log \frac{\exp\big(\tau z_I^\top z_T(T_y(C))\big)}{\sum_c \exp\big(\tau z_I^\top z_T(T_c(C))\big)}$$

پس $C_1, \dots, C_m$ در فضای پیوستهٔ text encoder بهترین قالب را برای دادهٔ few-shot پیدا می‌کنند؛ بنابراین از prompt دستی که گسسته، زبانی و شکننده است بهترند.

اما:

$\#\text{پارامترها} = md$ یا در حالت کلاسی $|\mathcal{Y}|md$

$K \ll md \implies$ می‌تواند بایاس کلاس‌های آموزشی را حفظ کند $C^\star$

$c' \notin \mathcal{Y}_{\text{train}} \implies$ الزاماً روی منیفولد زبانی مناسب نیست $z_T([C^\star, c'])$

پس روی کلاس یا دامنهٔ ندیده امکان overfitting وجود دارد.

ه

تعریف دو حالت:

$$\text{unified context}: \quad T_c = [C_1, \dots, C_m, c], \qquad \#\theta = md$$
$$\text{class-specific context}: \quad T_c = [C_{c,1}, \dots, C_{c,m}, c], \qquad \#\theta = |\mathcal{Y}|md$$

مقایسهٔ bias-variance:

unified : ظرفیت کمتر، bias بیشتر، variance کمتر، پایدارتر، انتقال بهتر به کلاس ندیده

class-specific : ظرفیت بیشتر، bias کمتر، variance بیشتر، خطر overfitting بیشتر

پس:

K کم یا کلاس ندیده مهم $\implies$ unified context

K زیاد و کلاس‌ها ناهمگن $\implies$ class-specific context

و

گرادیان کل:

$$\nabla\mathcal{L} = \lambda_c \nabla\mathcal{L}_{CLIP} + \lambda_g \nabla\mathcal{L}_{gen}$$

اثر وزن‌ها:

$$\lambda_c \uparrow \implies \text{zero-shot classification} \uparrow, \quad \text{image-text retrieval} \uparrow$$

$$\lambda_c \downarrow \implies \text{هم‌ترازی تصویر ـ متن و جداسازی کلاسی ضعیف‌تر}$$

$$\lambda_g \uparrow \implies \text{caption generation} \uparrow, \quad \text{جزئیات زبانی و توصیفی بیشتر}$$

$$\lambda_g \gg \lambda_c \implies \text{کاهش خاصیت تمایزی embedding برای retrieval/classification}$$

$$\lambda_g \downarrow \implies \text{کاهش کیفیت و روانی caption}$$

برای دادهٔ برچسب‌دار محدود:

$$\lambda_g > 0 \implies \text{نظارت dense در سطح token و regularization}$$

$$\lambda_c > 0 \implies \text{حفظ فضای مشترک تصویر ـ متن برای retrieval و zero-shot}$$

$$\lambda_g \gg \lambda_c \implies \text{یادگیری توزیع caption به‌جای مرز تصمیم کلاسی}$$

ز

ترکیب دو هدف زمانی مفید است که گرادیان‌ها هم‌جهت باشند:

$$\langle \nabla\mathcal{L}_{CLIP}, \nabla\mathcal{L}_{gen} \rangle > 0 \implies \text{انتقال مثبت، grounding بهتر، regularization}$$

اما در صورت تعارض:

$$\langle \nabla\mathcal{L}_{CLIP}, \nabla\mathcal{L}_{gen} \rangle < 0 \implies \text{negative transfer}$$

$$\theta^\star(\lambda_c, \lambda_g) = \arg\min_\theta \lambda_c \mathcal{L}_{CLIP} + \lambda_g \mathcal{L}_{gen}$$

$$\theta^\star \neq \arg\min_\theta \mathcal{L}_{CLIP}, \qquad \theta^\star \neq \arg\min_\theta \mathcal{L}_{gen}$$

زیرا هدف کنتراستی embedding تمایزی و فشرده می‌خواهد، ولی هدف تولیدی مدل را به پیش‌بینی توکن‌های پرتکرار، نحو و جزئیات زبانی سوق می‌دهد. بنابراین برای مدل عمومی چندوظیفه‌ای مفید است، اما برای pure retrieval، pure zero-shot classification یا pure captioning با ظرفیت محدود می‌تواند specialization را کاهش دهد.

پاسخ مسئله‌ی ۲.

الف

در projector ساده:

$$P(V) = \mathrm{MLP}(V), \qquad P(V) \in \mathbb{R}^{K \times d_L}$$

ولی در Q-Former:

$$\begin{aligned} H &= \mathrm{CrossAttn}(Q, V) \\ &= \mathrm{softmax}\left(\frac{QW_Q(VW_K)^\top}{\sqrt{d}}\right) VW_V, \qquad H \in \mathbb{R}^{M \times d_L}, \quad M \ll K \end{aligned}$$

پس:

$\mathrm{MLP}(V)$: نگاشت مستقیم، بدون انتخاب تطبیقی ویژگی‌ها

Q-Former : فشرده‌سازی آموختنی، انتخاب معنایی، حذف نویز، هم‌ترازسازی با فضای LLM

برای VQA و captioning، خروجی باید شیء، رابطه، صفت و ناحیهٔ مهم تصویر را خلاصه کند؛ بنابراین:

$$M \ll K, \qquad H = \sum_{j=1}^{K} \alpha_{ij} v_j, \qquad \alpha_{ij} = \mathrm{Attn}(q_i, v_j)$$

یعنی Q-Former یک bottleneck معنایی می‌سازد، در حالی که projector فقط embedding خام هاpatch را منتقل می‌کند.

ب

$$\begin{aligned} \mathrm{Perf}(M) &= a(1 - e^{-bM}) - cM \\ \mathrm{Perf}'(M) &= abe^{-bM} - c \\ \mathrm{Perf}''(M) &= -ab^2 e^{-bM} < 0 \end{aligned}$$

اگر $ab > c$:

$$\begin{aligned} \mathrm{Perf}'(M^\star) = 0 \quad &\Longrightarrow \quad abe^{-bM^\star} = c \\ M^\star &= \frac{1}{b} \log \frac{ab}{c} \end{aligned}$$

اگر $ab \le c$، افزایش token query از ابتدا به‌صرفه نیست. بنابراین:

$M < M^\star$: اطلاعات تصویری مفید غالب است

$M > M^\star$: هزینه، نویز و بار محاسباتی غالب است

ج

classification zero-shot / retrieval $\Rightarrow$ CLIP

$$z_I = f_I(I), \qquad z_T = f_T(T), \qquad s(I,T) = \frac{z_I^\top z_T}{\|z_I\|\|z_T\|}$$

هدف آموزشی:

$$\mathcal{L}_{\text{contrastive}} = -\log \frac{\exp(s(I_i,T_i)/\tau)}{\sum_j \exp(s(I_i,T_j)/\tau)}$$

دادهٔ مناسب: pair image-text بزرگ؛ اتصال بینایی و زبان: فضای embedding مشترک.

BLIP-۲ $\Rightarrow$ VQA با دادهٔ محدود

$$V = f_I(I), \qquad H = \text{CrossAttn}(Q,V), \qquad p(a|I,q) = \text{LLM}(q,H)$$

هدف آموزشی:

$$\mathcal{L} = \lambda_۲\mathcal{L}_{\text{caption}} + \lambda_۳\mathcal{L}_{\text{VQA}}$$

دادهٔ مناسب: caption و question-answer؛ اتصال: query های token کم، با encoder image و LLM عمدتاً frozen.

LLaVA $\Rightarrow$ assistant چندرسانه‌ای instruction-following

$$X_v = P(f_I(I)), \qquad p(y|I,u) = \prod_t p(y_t|y_{<t},u,X_v)$$

هدف آموزشی:

$$\mathcal{L}_{\text{instruction}} = -\sum_{t} \log p(y_t | y_{<t}, u, I)$$

دادهٔ مناسب: multimodal؛ instruction/dialogue اتصال: projection به فضای هایLLM token و fine-tuning دستورمحور.

د

برای :retrieval

مدل generative است، embedding متقارن تصویر_متن ندارد، scoring آن autoregressive و پرهزینه است. : بهینه ≉ LLaVA

برای VQA با دادهٔ محدود:

ندارد، فقط شباهت image-text را می‌آموزد. $p(a|I,q)$: کافی ≉ CLIP

به دادهٔ instruction و fine-tuning سنگین‌تر نیاز دارد. : بهینه ≉ LLaVA

برای :assistant

decoder زبانی، حافظهٔ مکالمه و instruction-following ندارد. : کافی ≉ CLIP

برای گفت‌وگوی چندنوبتی و تبعیت دقیق از دستور ضعیف‌تر است. : کافی اگر instruction-tuned نباشد ≉ BLIP-۲

ه

$$\text{محدود memory/compute} \Rightarrow \begin{cases} \text{CLIP} & \text{برای retrieval/zero-shot} \\ \text{BLIP-۲, } M \text{ کوچک} & \text{برای VQA/caption} \end{cases}$$

$$\Rightarrow \text{اجتناب از fine-tuning کامل LLaVA}$$

با encoder image و frozen LLM ⇒ BLIP-۲ کمبود data instruction

یا BLIP-۲ همراه tuning instruction ⇒ LLaVA نیاز شدید به conversation/reasoning/instruction-following

و

$$\mathcal{L}_{total} = \lambda_۱\mathcal{L}_{contrastive} + \lambda_۲\mathcal{L}_{caption} + \lambda_۳\mathcal{L}_{VQA} + \lambda_۴\mathcal{L}_{instruction}, \qquad \lambda_i \geq ۰$$

$\lambda_۱$: zero-shot retrieval، image-text، هم‌ترازی

$\lambda_۲$: توصیف عمومی تصویر و grounding زبانی

$\lambda_۳$: پاسخ‌گویی سؤال‌محور و انتخاب ناحیهٔ مرتبط

$\lambda_۴$: تبعیت از دستور، مکالمه، پاسخ ساختاریافته

اگر یکی از ضرایب غالب شود:

$\lambda_۱ \gg$: مدل محور retrieval و generative ضعیف

$\lambda_۲ \gg$: caption خوب ولی reasoning/VQA محدود

$\lambda_۳ \gg$: تخصص روی VQA و افت generalization

$\lambda_۴ \gg$: وابستگی به سبک data instruction و احتمال overfitting رفتاری

ز

انتخاب مناسب:

BLIP-۲ style : encoder image frozen + Q-Former trainable + LLM LoRA / frozen

$$V = f_I(I), \qquad f_I \text{ frozen}$$
$$H = \text{CrossAttn}(Q, V), \qquad Q, \text{Q-Former trainable}$$
$$p(a|I, q) = \text{LLM}(q, H), \qquad \text{LLM سبک LoRA یا frozen}$$

هدف آموزشی:

$$\mathcal{L} = \lambda_۱\mathcal{L}_{contrastive} + \lambda_۲\mathcal{L}_{caption} + \lambda_۳\mathcal{L}_{VQA}, \qquad \lambda_۳ > \lambda_۲ > \lambda_۱, \quad \lambda_۴ \approx ۰$$

دلیل:

پارامتر trainable کم $\Rightarrow$ داده محدود

Q-Former + LLM $\Rightarrow$ نیاز به پاسخ سؤال

و encoder image از پیش‌آموزش‌دیده$\mathcal{L}_{contrastive}$ $\Rightarrow$ نیاز به zero-shot نسبی

هزینه $\approx O(MKd) + O((T+M)^2), \qquad M \ll K$

پاسخ مسئله‌ی ۳.

بخش اول

آ ـ ۱

$$\theta_k^{(t)} = m^t \theta_k^{(۰)} + (۱ - m) \sum_{i=۱}^{t} m^{t-i} \theta_q^{(i)}$$

$$m = ۰/۹۹۹ \Rightarrow \tau_{\text{EMA}} \simeq \frac{۱}{۱ - m} = ۱۰۰۰, \qquad t_{۱/۲} = \frac{\log(۱/۲)}{\log m} \simeq ۶۹۳$$

$$\|\theta_k^{(t)} - \theta_k^{(t-۱)}\| = (۱ - m)\|\theta_q^{(t)} - \theta_k^{(t-۱)}\| = ۱۰^{-۳}\|\theta_q^{(t)} - \theta_k^{(t-۱)}\|$$

پس کلیدهای ذخیره‌شده در Queue، با وجود تولیدشدن در زمان‌های متفاوت، در یک دستگاه نمایش تقریباً ایستا باقی می‌مانند؛ وگرنه نمونه‌های منفی کهنه، نمایش‌های ناسازگار با پرس‌وجوی فعلی می‌شدند.

آ ـ ۲

اگر تغییر δ در θ_q پایدار بماند:

$$\Delta\theta_k^{(T)} = (۱ - m) \sum_{i=۰}^{T-۱} m^i \delta = (۱ - m^T)\delta$$

$$m = ۰/۹۹۹ \Rightarrow ۱ - m^T \simeq ۱ - e^{-T/۱۰۰۰} \simeq \frac{T}{۱۰۰۰} \qquad (T \ll ۱۰۰۰)$$

اگر تغییر فقط یک شوک یک‌گامی باشد:

$$\Delta\theta_k^{(T)} = (۱ - m)m^{T-۱}\delta$$

بنابراین نوسان ناگهانی ابتدا با ضریب $۱۰^{-۳}$ وارد شاخهٔ کلید می‌شود و سپس با ضریب $m^{T-۱}$ مستهلک می‌گردد؛ برای $m \simeq ۱$، شاخهٔ کلید یک فیلتر پایین‌گذر با ثابت زمانی بزرگ است.

بخش دوم

آ ـ ۱

بگذارید $E = PW - W'$. آنگاه:

$$
\begin{aligned}
L &= \operatorname{tr}(E\Sigma E^\top) \\
\nabla_P L &= ۲E\Sigma W^\top \\
\nabla_W L &= ۲P^\top E\Sigma \\
W = W' = ۰ \Rightarrow E = ۰ \Rightarrow \nabla_P L = ۰, &\quad \nabla_W L = ۰, \quad \dot{W}' = \eta(W - W') = ۰
\end{aligned}
$$

پس نمایش ثابت صفر یک نقطهٔ بحرانی و تعادل دینامیکی است.

آ ـ ۲

در رژیم هم‌ترازی $W' \simeq W$:

$$
\begin{aligned}
\nabla_P L &= ۲(PW - W)\Sigma W^\top \\
&= ۲(P - I)W\Sigma W^\top \\
&= ۲(P - I)F, \qquad F = W\Sigma W^\top \\
\dot{P} &= -\nabla_P L = -۲(P - I)F
\end{aligned}
$$

در پایهٔ قطری مشترک:

$$
\begin{aligned}
F &= \operatorname{diag}(w_j^۲ \lambda_j) = \operatorname{diag}(\sigma_j) \\
\dot{p}_j &= -۲\sigma_j(p_j - ۱) \\
p_j(t) - ۱ &= (p_j(۰) - ۱)e^{-۲\sigma_j t} \\
\sigma_j > ۰ \Rightarrow p_j(t) \to ۱, &\qquad \sigma_j = ۰ \Rightarrow p_j(t) = p_j(۰)
\end{aligned}
$$

آ ـ ۳

$$
\begin{aligned}
\nabla_W L &= ۲P(PW - W)\Sigma \\
&= ۲P(P - I)W\Sigma \\
\dot{W} &= -۲P(P - I)W\Sigma
\end{aligned}
$$

پس برای مؤلفهٔ j:

$$\dot{w}_j = -۲\lambda_j p_j(p_j - ۱)w_j$$
$$w_j(t) = w_j(۰)e^{r_j t}, \qquad r_j = -۲\lambda_j p_j(p_j - ۱)$$
$$۰ < p_j < ۱ \Rightarrow p_j(p_j - ۱) < ۰ \Rightarrow r_j > ۰$$

بنابراین فروپاشی با وجود Predictor نقطهٔ زینی ناپایدار است، نه جاذب. اگر Predictor حذف شود و $P = I$ ثابت بماند:

$$r_j = -۲\lambda_j \cdot ۱ \cdot ۰ = ۰$$

و سازوکار دافعه از فروپاشی از بین می‌رود. Stop-gradient هدف را از دنبال‌کردن همان گرادیان بازمی‌دارد و EMA هم‌ترازی کند $W' \simeq W$ را پایدار می‌کند.

ب

در DINO:

$$p_t(y|x) = \mathrm{softmax}\left(\frac{g_t(x) - c}{\tau_t}\right), \qquad c \leftarrow \mu c + (۱ - \mu)\frac{۱}{B}\sum_{b=۱}^{B} g_t(x_b)$$
$$p_s(y|x) = \mathrm{softmax}\left(\frac{g_s(x)}{\tau_s}\right)$$
$$L = -\sum_y p_t(y|x)\log p_s(y|x)$$

Centering مانع تسلط یک prototype ثابت می‌شود:

$$g_t(x_b) = a \quad \forall b \Rightarrow g_t(x_b) - c \simeq ۰ \Rightarrow p_t(y|x_b) \simeq \frac{۱}{K}$$

Sharpening با $\tau_t \ll ۱$ آنتروپی شرطی را کم می‌کند:

$$\tau_t \downarrow \Rightarrow H(Y|X) \downarrow$$

پس تعادل مطلوب:

$$\text{Centering}: \quad H(Y) \uparrow$$
$$\text{Sharpening}: \quad H(Y|X) \downarrow$$
$$I(X;Y) = H(Y) - H(Y|X) \uparrow$$

نمونه‌های منفی صریح حذف شده‌اند؛ رقابت هاprototype در Softmax و آمار batch همان نقش دافعهٔ توزیعی را ایفا می‌کند.

بخش سوم

آ_۱

در تصویر، همبستگی مکانی وصله‌ها زیاد است:

$$r_{\text{mask}} = ۰/۱۵ \Rightarrow \Pr(\text{همسایه‌های مرئی زیاد برای هر وصلهٔ مخفی}) \approx ۱$$

$$\hat{x}_i \approx \text{Interp}\{x_j : j \in \mathcal{N}(i),\ j \notin M\}$$

پس مدل می‌تواند با ادامه‌دادن بافت و لبه‌های محلی، بدون فهم معنایی، loss بازسازی را کم کند. در MAE:

$$r_{\text{mask}} = ۰/۷۵ \Rightarrow |\text{visible}| = ۰/۲۵N$$

و بازسازی ناچار به استفاده از ساختار سراسری شیء و صحنه می‌شود.

آ_۲

$$N = ۲۵۶, \qquad r_{\text{mask}} = ۰/۷۵$$

$$N_{\text{vis}} = (۱ - r_{\text{mask}})N = ۰/۲۵ \times ۲۵۶ = ۶۴$$

$$\frac{C_{\text{MAE}}}{C_{\text{full}}} = \frac{N_{\text{vis}}^۲}{N^۲} = \left(\frac{۶۴}{۲۵۶}\right)^۲ = \frac{۱}{۱۶} = ۶/۲۵٪$$

$$\text{صرفه‌جویی} = ۱ - ۶/۲۵٪ = ۹۳/۷۵٪$$

آ_۳

برای روش‌های مقابله‌ای:

$$L_{\text{CL}} = -\log \frac{\exp(s(q, k^+)/\tau)}{\sum_{i=۱}^{K} \exp(s(q, k_i)/\tau)}$$

هدف سراسری برای هر تصویر $\quad$ چگالی سیگنال $\sim O(۱)$

برای MIM:

$$L_{\text{MIM}} = \sum_{j \in M} \ell(\hat{x}_j, x_j)$$

$$|M| = r_{\text{mask}} N$$

$$r_{\text{mask}} = ۰/۷۵,\ N = ۲۵۶ \Rightarrow |M| = ۱۹۲$$

پس هر تصویر صدها قید بازسازی محلی‌ـ معنایی تولید می‌کند. در ViT-Huge ظرفیت مدل زیاد است و objective کم‌چگال مقابله‌ای زود اشباع می‌شود، اما MIM با سیگنال متراکم وصله‌ای، گرادیان غنی‌تر، regularization قوی‌تر، و انطباق مستقیم با معماری توکنی ViT بهتر مقیاس می‌گیرد.

پاسخ مسئله‌ی ۴.

بخش اول

آ

Generative : $\max_\theta \log p_\theta(x) \Rightarrow z$ کل کافی باشدx باید برای بازسازی/نمونه‌سازی

SSL : $\max_\theta I(f_\theta(t_۱(x)); f_\theta(t_۲(x)))$ یا $\min_\theta \mathcal{L}_{\text{pretext}} \Rightarrow z$ فقط نسبت به تبدیل‌های تعریف‌شده پایدار و تمایزبخش است

پس هدف SSL مدل‌کردن کامل $p(x)$ نیست، بلکه حذف جزئیات nuisance و حفظ عوامل قابل‌انتقال است.

ب

$$y_{\text{rot}} = r \in \{۰^\circ, ۹۰^\circ, ۱۸۰^\circ, ۲۷۰^\circ\}$$

$\min_\theta \mathbb{E}\, \ell(q(f_\theta(R_r x)), r) \Rightarrow f_\theta(x)$ حساس به سرنخ‌های جهت، بافت، مرز و هندسهٔ محلی می‌شود

اما:

$$y_{\text{downstream}} = \text{semantic class}, \qquad r \not\equiv y_{\text{downstream}}$$

بنابراین اطلاعات بهینه برای pretext الزاماً همان اطلاعات معنایی نیست و نمایش دچار task-specific bias می‌شود.

ج

$\text{Acc}_{\text{Jigsaw}} = ۹۹٪ \Rightarrow I(z; y_{\text{jigsaw}})$ زیاد است

$\text{Acc}_{\text{ImageNet}} = ۴۰٪ \Rightarrow I(z; y_{\text{semantic}})$ و/یا خطی‌بودن جداسازی معنایی کم است

پس مدل مسئلهٔ pretext را با سرنخ‌های سطحی حل کرده، نه با ساختن نمایش معنایی قابل‌انتقال.

بخش دوم

آ

$$\frac{s_+}{\tau} = \frac{۰/۹}{۰/۱} = ۹, \qquad \frac{s_۱}{\tau} = ۲, \quad \frac{s_۲}{\tau} = ۴, \quad \frac{s_۳}{\tau} = ۵$$

$$\begin{aligned} L &= -\log \frac{e^{۹}}{e^{۹} + e^{۲} + e^{۴} + e^{۵}} \\ &= \log \frac{۸۱۰۳ + ۷ + ۵۵ + ۱۴۸}{۸۱۰۳} \\ &= \log \frac{۸۳۱۳}{۸۱۰۳} \approx \log(۱/۰۲۵۹) \approx ۰/۰۲۵۶ \end{aligned}$$

ب

اگر همهٔ امتیازها برابر باشند:

$$s_+ = s_۱ = \cdots = s_{N-۱} = c \quad \Rightarrow \quad \frac{\exp(c/\tau)}{\exp(c/\tau) + \sum_{j=۱}^{N-۱} \exp(c/\tau)} = \frac{e^{c/\tau}}{N e^{c/\tau}} = \frac{۱}{N}$$

$$L = -\log \frac{۱}{N} = \log N$$

ج

$$MI(f(x), f(x^+)) \geq \log N - L$$

پس با ثابت ماندن L:

$$N \uparrow \quad \Rightarrow \quad \log N \uparrow \quad \Rightarrow \quad \text{کران پایین } MI \text{ بزرگ‌تر می‌شود}$$

ولی:

$$L \not\downarrow \text{ متناسب با } \log N \quad \Rightarrow \quad \log N - L \text{ شل می‌شود}$$

افزایش N نمونه‌های منفی سخت‌تر می‌دهد و فشار تمایزبخشی را زیاد می‌کند، اما کیفیت نتیجه به tightness همین کران وابسته است.

بخش سوم

آ

$$h = f(x), \qquad z = g(h)$$

$\mathcal{L}_{\text{InfoNCE}}(z) \quad \Rightarrow \quad z$ باشد invariant بسیار augmentations باید نسبت به

اگر loss مستقیم روی h اعمال شود:

$h \to$ حذف اطلاعاتی که برای loss contrastive مزاحم‌اند

ولی با projection head:

$h \to$ نمایش عمومی‌تر و معنایی‌تر , $z \to$ فضای مخصوص contrastive

بنابراین در downstream، g حذف می‌شود و از h استفاده می‌کنیم.

ب

$$۲N = ۲ \times ۸۱۹۲ = ۱۶۳۸۴$$

$$\begin{aligned}\text{Memory} &= (۲N)^{۲} \times ۴ \\ &= ۱۶۳۸۴^{۲} \times ۴ \\ &= ۲۶۸۴۳۵۴۵۶ \times ۴ \\ &= ۱۰۷۳۷۴۱۸۲۴\text{bytes} \ = ۱\text{GiB}\end{aligned}$$