پاسخ مسئله‌ی ۱.

۱

قضیهٔ تقریب جهانی فقط وجود تقریب‌گر را تضمین می‌کند، نه کارایی آن را. این قضیه می‌گوید با عرض کافی می‌توان هر تابع پیوسته را روی یک مجموعهٔ فشرده تقریب زد، اما هیچ کرانی روی تعداد نورون‌های لازم نمی‌گذارد؛ برای توابع پیچیده این تعداد می‌تواند به‌صورت exponential نسبت به بُعد ورودی رشد کند. در مقابل، نتایج جدایی عمق نشان می‌دهند توابعی هستند که یک شبکهٔ عمیق با تعداد پارامتر چندجمله‌ای آن‌ها را نمایش می‌دهد، حال‌آن‌که هر شبکهٔ کم‌عمق برای همان دقت به عرض نمایی نیاز دارد. علت آن است که عمق امکان ترکیب سلسله‌مراتبی و بازاستفاده از ویژگی‌ها را می‌دهد و این با ساختار ترکیبی دادهٔ واقعی هم‌خوان است. بنابراین شبکه‌های عمیق با پارامتر کمتر، بیان‌گری، آموزش و تعمیم بهتری دارند.

۲

به‌روزرسانی Adam (با $\epsilon = 0$) مؤلفه‌ای است؛ کافی است مؤلفهٔ i را دنبال کنیم. اگر گرادیان‌ها در ماتریس قطری مثبت $D = \mathrm{diag}(d_i)$ ضرب شوند، یعنی $g'_{t,i} = d_i\, g_{t,i}$، و چون d_i در طول زمان ثابت است، با استقرا داریم:

$$m'_{t,i} = \beta_1 m'_{t-1,i} + (1-\beta_1)\, d_i g_{t,i} = d_i\, m_{t,i}$$
$$v'_{t,i} = \beta_2 v'_{t-1,i} + (1-\beta_2)\, (d_i g_{t,i})^2 = d_i^2\, v_{t,i}$$

تصحیح اریبی هم همین ضرایب را حفظ می‌کند: $\hat{m}'_{t,i} = d_i \hat{m}_{t,i}$ و $\hat{v}'_{t,i} = d_i^2 \hat{v}_{t,i}$. پس گام به‌روزرسانی:

$$\Delta\theta_i = -\alpha\, \frac{\hat{m}'_{t,i}}{\sqrt{\hat{v}'_{t,i}}} = -\alpha\, \frac{d_i \hat{m}_{t,i}}{\sqrt{d_i^2 \hat{v}_{t,i}}} = -\alpha\, \frac{d_i \hat{m}_{t,i}}{d_i \sqrt{\hat{v}_{t,i}}} = -\alpha\, \frac{\hat{m}_{t,i}}{\sqrt{\hat{v}_{t,i}}}$$

(از $d_i > 0$ استفاده شد تا $\sqrt{d_i^2} = d_i$.) پس d_i حذف می‌شود و گام دقیقاً بدون تغییر می‌ماند؛ یعنی Adam نسبت به مقیاس‌گذاری قطری ناوردا است. تقسیم مؤلفه‌ای بر $\sqrt{\hat{v}}$ همان نقش نرمال‌سازی را دارد که مقیاس را خنثی می‌کند.

۳

چند کرنل کوچک پشت‌سرهم (مثلاً دو کرنل 3×3) همان میدان دریافت یک کرنل بزرگ‌تر (5×5) را می‌سازند، اما با پارامتر و محاسبهٔ کمتر: دو 3×3 یعنی $2 \cdot 9 = 18$ وزن در برابر ۲۵ وزنِ 5×5 (و سه 3×3 یعنی ۲۷ در برابر ۴۹ برای 7×7). افزون بر این، بین هر دو لایه یک نالینریتی (ReLU) قرار می‌گیرد، پس تابع حاصل بیان‌گرتر و تفکیک‌پذیرتر است. در مجموع: میدان دریافت یکسان، پارامتر کمتر و نالینریتی بیشتر.

۴

حالت سلول LSTM برابر است با $c_t = f_t \odot c_{t-۱} + i_t \odot \tilde{c}_t$. با $f_t = ۱$ و $i_t = ۰$ در همهٔ گام‌ها، $c_t = c_{t-۱} = \cdots = c_۰$؛ یعنی حالت سلول بدون تغییر منتقل می‌شود (چرخ‌فلک خطای ثابت). ژاکوبینِ مسیر حالت سلول:

$$\frac{\partial c_t}{\partial c_{t-۱}} = \mathrm{diag}(f_t) = I \implies \frac{\partial c_T}{\partial c_۰} = \prod_{t=۱}^{T} \mathrm{diag}(f_t) = I$$

حاصل‌ضرب بدون توجه به T برابر یک می‌ماند، پس گرادیان روی این مسیر نه تضعیف می‌شود و نه می‌خوابد. بنابراین بله؛ گرادیان هزینه نسبت به $c_۰$ از مسیر حالت سلول، مستقل از طول دنباله، محو نمی‌شود — همان سازوکاری که مشکل محوشدگی گرادیان را حل می‌کند.

۵

softmax نسبت به افزودن یک ثابت به همهٔ logits ناوردا است. با $c = \max_i z_i$:

$$\mathrm{softmax}(z - c)_j = \frac{e^{z_j - c}}{\sum_k e^{z_k - c}} = \frac{e^{-c} e^{z_j}}{e^{-c} \sum_k e^{z_k}} = \frac{e^{z_j}}{\sum_k e^{z_k}} = \mathrm{softmax}(z)_j$$

پس خروجی تغییر نمی‌کند. اما با این انتخاب، بزرگ‌ترین آرگومان نمایی صفر می‌شود ($e^{۰} = ۱$) و بقیه ≤ ۱ هستند؛ در نتیجه هیچ‌گاه e^{z_j} برای z_j بزرگ سرریز نمی‌کند. جمله‌های کوچک هم در صورت زیرریز به صفر میل می‌کنند که بی‌ضرر است.

۶

بین آموزش و آزمون یک تغییر توزیع رخ می‌دهد، پس می‌توان منظرهٔ خطای آزمون را تقریباً نسخه‌ای جابه‌جاشده از منظرهٔ خطای آموزش دانست؛ یعنی کمینهٔ آزمون نسبت به θ^* به اندازهٔ δ جابه‌جاست. با بسط تیلور حول کمینه:

$$L_{\text{test}}(\theta^* + \delta) - L_{\text{test}}(\theta^*) \approx \tfrac{۱}{۲}\, \delta^\top H_{\theta^*}\, \delta \leq \tfrac{۱}{۲}\, \lambda_{\max}(H_{\theta^*})\, \|\delta\|^۲$$

پس شکاف تعمیم با حاصل‌ضرب انحنا و اندازهٔ جابه‌جایی کران می‌خورد. در کمینهٔ تیز ($\lambda_{\max}$ بزرگ) همان جابه‌جایی کوچک خطا را به‌شدت بالا می‌برد، اما در کمینهٔ تخت ($\lambda_{\max}$ کوچک) خطا کم تغییر می‌کند. از این رو کمینه‌های تخت در برابر ناهم‌خوانی توزیع آموزش/آزمون مقاوم‌اند و تعمیم بهتری دارند.

۷

در برش مقدار، هر مؤلفه جداگانه به $[-c, c]$ محدود می‌شود؛ چون مؤلفه‌های مختلف به مقدار متفاوت بریده می‌شوند، بردار گرادیان جهت خود را از دست می‌دهد و دیگر لزوماً یک جهت کاهشی نیست — یعنی به به‌روزرسانی اریبی وارد می‌شود. در برش بهنجار، کل بردار با یک اسکالر مثبت $c/\|g\|$ مقیاس می‌شود، پس تنها بزرگی گام محدود می‌گردد و جهت گرادیان دقیقاً حفظ می‌شود:

$$g \leftarrow \frac{c}{\|g\|}\, g \quad (\|g\| > c) \implies \text{جهت ثابت،}\ \|g\| = c$$

چون مضربِ مثبتِ گرادیان همچنان یک جهت کاهشی معتبر است، روش (ب) از نظر نظری ترجیح دارد: انفجار گرادیان را مهار می‌کند بی‌آن‌که جهت نزول را تحریف کند.

۸

در BERT، از میان توکن‌های انتخاب‌شده برای پیش‌بینی، بخشی بدون ماسک‌شدن (به‌صورت توکن اصلی یا تصادفی) در ورودی می‌مانند ولی مدل باز هم باید توکن اصلی را در خروجی بازسازی کند. علت اصلی، کاهش ناهم‌خوانی بین پیش‌آموزش و تنظیم‌دقیق است: در تنظیم‌دقیق توکن [MASK] وجود ندارد، پس اگر مدل فقط روی موقعیت‌های ماسک‌شده پیش‌بینی می‌کرد، یاد می‌گرفت تنها برای [MASK] بازنمایی خوب بسازد. با واردکردن توکن‌های ماسک‌نشده به تابع هزینه، مدل مجبور می‌شود برای هر توکن مشاهده‌شده هم یک بازنمایی متنیِ معنادار نگه دارد و نمی‌تواند صرفاً به خودِ توکن ورودی اعتماد کند؛ این کار شکاف پیش‌آموزش/تنظیم‌دقیق را کم می‌کند و بازنمایی‌ها را به سمت معنای متنی واقعی سوق می‌دهد.

۹

Swin Transformer برخلاف ViT که در همهٔ لایه‌ها یک نقشهٔ ویژگی تک‌مقیاس و درشت دارد، با ادغام پچ‌ها نقشه‌های ویژگی *سلسله‌مراتبی و چندمقیاسی* تولید می‌کند (مانند هرم ویژگی در شبکه‌های کانولوشنی). افزون بر این، توجه پنجره‌ایِ شیفت‌دار پیچیدگی محاسباتی را نسبت به اندازهٔ تصویر linear می‌کند (در برابر مرتبهٔ درجهٔ دومِ توجه سراسری ViT). تسک‌هایی مانند segmentation به ویژگی‌های چندمقیاس و رزولوشن بالا نیاز دارند؛ همین ساختار هرمی، Swin را به یک ستون‌فقرات همه‌منظوره و مناسب پیش‌بینی متراکم تبدیل می‌کند، حال‌آن‌که نمایش تک‌مقیاسِ ViT برای این کار کم‌توان است.

پاسخ مسئله‌ی ۲.

قسمت ۱: تعداد پارامترهای لایه‌ی آخر

ابتدا ابعاد فضایی خروجی هر لایه را دنبال می‌کنیم تا به ورودی لایه‌ی تمام‌متصل برسیم. فرمول ابعاد خروجی:

$$O = \left\lfloor \frac{I - K + ۲P}{S} \right\rfloor + ۱$$

برای Conv1 با ورودی ۲۲۴، $K = ۷$، $P = ۳$، $S = ۲$:

$$O_۱ = \left\lfloor \frac{۲۲۴ - ۷ + ۶}{۲} \right\rfloor + ۱ = \left\lfloor \frac{۲۲۳}{۲} \right\rfloor + ۱ = ۱۱۱ + ۱ = ۱۱۲$$

پس خروجی ۶۴ × ۱۱۲ × ۱۱۲ است.

برای Conv2 با $K = ۳$، $P = ۱$، $S = ۱$:

$$O_۲ = \frac{۱۱۲ - ۳ + ۲}{۱} + ۱ = ۱۱۲$$

خروجی ۱۲۸ × ۱۱۲ × ۱۱۲.

برای MaxPool با $K = ۳$، $S = ۲$، بدون padding:

$$O_۳ = \left\lfloor \frac{۱۱۲ - ۳}{۲} \right\rfloor + ۱ = ۵۴ + ۱ = ۵۵$$

خروجی ۱۲۸ × ۵۵ × ۵۵.

برای Conv3 با $K = ۳$، $P = ۱$، $S = ۲$:

$$O_۴ = \left\lfloor \frac{۵۵ - ۳ + ۲}{۲} \right\rfloor + ۱ = ۲۷ + ۱ = ۲۸$$

خروجی ۲۵۶ × ۲۸ × ۲۸.

بنابراین بردار ورودی لایه‌ی تمام‌متصل دارای ۲۵۶ × ۲۸ × ۲۸ = ۲۰۰۷۰۴ نورون است و خروجی ۱۰ نورون. با احتساب bias:

$$\#params = ۲۰۰۷۰۴ \times ۱۰ + ۱۰ = ۲,۰۰۷,۰۵۰$$

قسمت ۲: کاهش پارامترها با کانولوشن عمق‌جدایی‌پذیر

در Conv3 استاندارد، ورودی ۱۲۸ کانال و خروجی ۲۵۶ کانال با فیلتر ۳ × ۳ است؛ پس:

$$P_{std} = ۳ \times ۳ \times ۱۲۸ \times ۲۵۶ = ۲۹۴۹۱۲$$

در حالت Depth-wise Separable، ابتدا یک depthwise روی هر کانال ورودی و سپس یک pointwise (۱ × ۱) برای ترکیب کانال‌ها:

$$P_{dw} = ۳ \times ۳ \times ۱۲۸ = ۱۱۵۲, \qquad P_{pw} = ۱ \times ۱ \times ۱۲۸ \times ۲۵۶ = ۳۲۷۶۸$$

$$P_{ds} = ۱۱۵۲ + ۳۲۷۶۸ = ۳۳۹۲۰$$

از این رو میزان کاهش:

$$\frac{P_{ds}}{P_{std}} = \frac{۳۳۹۲۰}{۲۹۴۹۱۲} \approx ۰/۱۱۵$$

یعنی تعداد پارامترها حدود ۸/۷ برابر کم می‌شود (به حدود ۱۱/۵٪ مقدار اولیه می‌رسد).

قسمت ۳: عملکرد ضعیف روی اشیای حاشیه‌ای

آ

وجود لایه‌ی تمام‌متصل در انتهای شبکه باعث می‌شود مکان قرارگیری شیء در تصویر در آموزش کدگذاری شود؛ چون داده‌ی آموزشی عمدتاً اشیا را در مرکز تصویر دارد، شبکه یاد می‌گیرد فعال‌سازی‌های مربوط به مرکز را به کلاس‌ها نگاشت کند و برای موقعیت‌های نامعمول تعمیم نمی‌یابد. این سوگیری مکانی (نه ضعف استخراج ویژگی) عامل اصلی است.

ب

لایه‌های کانولوشن Translation Equivariant هستند، یعنی جابه‌جایی ورودی به جابه‌جایی متناظر در نقشه‌ی ویژگی منجر می‌شود؛ اما این خاصیت تنها تا قبل از لایه‌ی FC حفظ می‌شود. لایه‌ی تمام‌متصل، نقشه‌ی ویژگی را به‌صورت تخت (flatten) و هر موقعیت را به وزن متفاوتی متصل می‌کند؛ پس کل شبکه Translation Invariant نیست و به مکان حساس می‌شود. به‌علاوه padding مرزها نیز خاصیت تغییرناپذیری مکانی را در حاشیه‌ها می‌شکند و سرنخ مکانی به شبکه می‌دهد.

ج

بدون تغییر معماری، می‌توان با Data Augmentation مکانی (جابه‌جایی تصادفی، random crop، translation) داده‌ها را غنی کرد تا اشیا در موقعیت‌های متنوع دیده شوند و سوگیری مرکزی از بین برود.

پرسش ۴

خروجی Conv3 برابر ۲۵۶ × ۲۸ × ۲۸ است و ROI-Pooling نتیجه را به ابعاد ثابتی نگاشت می‌کند که پس از تخت‌شدن باید با ورودی ۱۰۲۴ بُعدی لایه‌ی اول سازگار باشد. اگر خروجی ROI-Pooling ابعاد $H \times W \times ۲۵۶$ داشته باشد، آنگاه:

$$H \times W \times ۲۵۶ = ۱۰۲۴ \implies H \times W = ۴$$

پس $H = W = ۲$؛ یعنی ROI-Pooling باید طول و عرض ۲ × ۲ داشته باشد.

پرسش ۵

دلیل اصلی نیاز ViT به حافظه‌ی GPU بالاتر، مکانیزم Self-Attention است. در آن، ماتریس توجه برای N توکن (پچ) دارای پیچیدگی حافظه‌ی $O(N^2)$ است؛ چون باید شباهت هر پچ با همه‌ی پچ‌های دیگر محاسبه و ذخیره شود. در مقابل، کانولوشن در CNN ماهیتی محلی با اشتراک وزن دارد و مصرف حافظه‌اش به‌صورت خطی با اندازه‌ی ورودی رشد می‌کند. این رشد درجه‌دوم نقشه‌ی توجه نسبت به تعداد توکن‌ها، عامل تعیین‌کننده‌ی مصرف حافظه‌ی بالاتر ViT است.

پاسخ مسئله‌ی ۳.

۱

ضرب داخلی پرس‌وجو و کلید را می‌نویسیم:

$$q \cdot k = \sum_{i=۱}^{d_k} q_i k_i$$

چون $q_i, k_i \sim \mathcal{N}(۰, ۱)$ و مستقل‌اند، $E[q_i] = E[k_i] = ۰$ و $\mathrm{Var}(q_i) = \mathrm{Var}(k_i) = ۱$. از این رو:

$$E[q_i k_i] = E[q_i]\, E[k_i] = ۰$$
$$\mathrm{Var}(q_i k_i) = E[q_i^۲ k_i^۲] - \big(E[q_i k_i]\big)^۲ = E[q_i^۲]\, E[k_i^۲] = ۱$$

به دلیل استقلال جمله‌ها واریانس مجموع برابر مجموع واریانس‌هاست:

$$\mathrm{Var}(q \cdot k) = \sum_{i=۱}^{d_k} \mathrm{Var}(q_i k_i) = d_k$$

استدلال گرادیان: بدون ضریب $\frac{۱}{\sqrt{d_k}}$ ورودی‌های softmax واریانس d_k و انحراف معیار $\sqrt{d_k}$ دارند؛ پس با بزرگ شدن d_k لاجیت‌ها بزرگ می‌شوند و خروجی softmax به برداری تقریباً one-hot (اشباع) میل می‌کند. ژاکوبین softmax برابر است با:

$$\frac{\partial p_i}{\partial z_j} = p_i(\delta_{ij} - p_j)$$

وقتی یک $p_i \approx ۱$ و بقیه ≈ ۰ باشند، $p_i(۱ - p_i) \approx ۰$ و همهٔ مشتق‌ها به صفر میل می‌کنند؛ یعنی گرادیانِ عبوری از softmax محو می‌شود. ضرب در $\frac{۱}{\sqrt{d_k}}$ واریانس را مستقل از d_k روی ۱ نگه می‌دارد و از این اشباع جلوگیری می‌کند.

۲

نخست توجه کنیم هزینهٔ پارامتری دو حالت یکسان است: h سر با بعد $d_k = d_{\text{model}}/h$ روی هم $h \cdot d_{\text{model}} \cdot \frac{d_{\text{model}}}{h} = d_{\text{model}}^۲$ پارامتر در هر نگاشت دارند، دقیقاً مانند یک سر با $d_k = d_{\text{model}}$. پس برتری از تعداد پارامتر نمی‌آید.

یک سرِ تنها تنها یک توزیع توجه تولید می‌کند؛ یعنی خروجی هر پرس‌وجو صرفاً یک میانگین وزن‌دارِ (محدب) از بردارهای value است. اگر یک توکن لازم باشد اطلاعات را از چند موقعیتِ مختلف و به دلایل متفاوت گرد آورد، این میانگین‌گیریِ یگانه آن‌ها را در هم می‌آمیزد و تمایزشان از میان می‌رود.

در مقابل، h سر با نگاشت‌های مستقل W_i^Q, W_i^K, W_i^V داده را به h زیرفضای متفاوت می‌برند و h توزیع توجهِ مستقل می‌سازند. بنابراین مدل می‌تواند هم‌زمان به موقعیت‌های مختلف و روابط گوناگون (نحوی، معنایی، مکانی و ...) توجه کند و سپس نتایج را الحاق نماید. همین توانایی نمایش هم‌زمانِ چند الگوی توجه در زیرفضاهای متفاوت بیانگری را بالا می‌برد و با یک سرِ بزرگ که ناگزیر به تولید تنها یک توزیع است حاصل نمی‌شود.

۳

الف

از تعریف کدگذاری، ضرب داخلی را باز می‌کنیم:

$$p_a^T p_b = \sum_{i=۱}^{m} \left[\sin(\omega_i a)\sin(\omega_i b) + \cos(\omega_i a)\cos(\omega_i b) \right]$$

با قرار دادن $x = \omega_i a$ و $y = \omega_i b$ در رابطهٔ $\cos(x-y) = \cos x \cos y + \sin x \sin y$:

$$p_a^T p_b = \sum_{i=۱}^{m} \cos\left(\omega_i (a-b)\right)$$

ب

خیر. این نتیجه تنها می‌گوید ضرب داخلیِ دو بردار کدگذاری مکانیِ خام فقط به اختلاف $a-b$ بستگی دارد؛ یعنی خودِ کدگذاری ساختاری متناسب با فاصلهٔ نسبی دارد. اما این به معنای استفادهٔ صرفاً نسبی از اطلاعات مکانی در کل شبکه نیست:

نخست آنکه کدگذاری مکانی به‌صورت جمع با embedding توکن به ورودی افزوده می‌شود، پس هر موقعیت یک کدِ مطلق دارد و اطلاعات مطلق در دسترس شبکه قرار می‌گیرد. دوم آنکه امتیاز توجهِ واقعی برابر $p_a^T p_b$ نیست؛ بلکه پرس‌وجو و کلید نگاشتِ خطیِ مجموع (PE + embedding) هستند و با محتوا نیز برهم‌کنش دارند، و خاصیتِ نسبی‌بودنِ $p_a^T p_b$ پس از اعمال W_Q, W_K و افزودنِ محتوا لزوماً پابرجا نمی‌ماند. سوم آنکه لایه‌های بعدی می‌توانند از الگوی سینوسی موقعیتِ مطلق را بازسازی و استفاده کنند.

پس نتیجهٔ بند قبل صرفاً یک ویژگیِ ضرب‌داخلیِ کدهای مکانیِ خالص است، نه اثباتِ نسبی‌بودنِ استفاده از مکان در سراسر مدل.

پرسش ۴

الف

داریم $d_{\text{model}} = ۷۶۸$، اندازهٔ واژگان $V = ۱۰۰۰۰$ و بیشینهٔ طول دنباله $L = ۱۰۰۰$. در شمارش، بایاس‌ها و دو LayerNorm هر بلوک را نیز لحاظ می‌کنیم.

embedding:

$$\underbrace{۱۰۰۰۰ \times ۷۶۸}_{\text{توکن}} + \underbrace{۱۰۰۰ \times ۷۶۸}_{\text{مکانی}} = ۷,۶۸۰,۰۰۰ + ۷۶۸,۰۰۰ = ۸,۴۴۸,۰۰۰$$

یک بلوک دیکدر شامل self-attention نقاب‌دار و MLP است. چون $h \cdot d_k = ۴ \times ۱۹۲ = ۷۶۸ = d_{\text{model}}$، هر یک از نگاشت‌های Q, K, V, O

ماتریسی ۷۶۸ × ۷۶۸ است:

$$\text{attention} = ۴ \times (۷۶۸ \times ۷۶۸ + ۷۶۸) = ۴ \times ۵۹۰{,}۵۹۲ = ۲{,}۳۶۲{,}۳۶۸$$

$$\text{MLP} = (۷۶۸ \times ۳۰۰۰ + ۳۰۰۰) + (۳۰۰۰ \times ۷۶۸ + ۷۶۸) = ۲{,}۳۰۷{,}۰۰۰ + ۲{,}۳۰۴{,}۷۶۸ = ۴{,}۶۱۱{,}۷۶۸$$

$$\text{LayerNorm دو} = ۲ \times (۲ \times ۷۶۸) = ۳{,}۰۷۲$$

$$\text{یک بلوک} = ۲{,}۳۶۲{,}۳۶۸ + ۴{,}۶۱۱{,}۷۶۸ + ۳{,}۰۷۲ = ۶{,}۹۷۷{,}۲۰۸$$

(در صورت صرف‌نظر از بایاس و LayerNorm: $۶{,}۹۶۷{,}۲۹۶ = ۳۰۰۰ \times ۷۶۸ \times ۲ + ۴ \times ۷۶۸^۲$.)

لایهٔ خروجیِ پیش از softmax که $d_{\text{model}} \to V$ را نگاشت می‌کند:

$$۷۶۸ \times ۱۰۰۰۰ + ۱۰۰۰۰ = ۷{,}۶۹۰{,}۰۰۰$$

(بدون بایاس ۷٫۶۸۰٫۰۰۰؛ در صورت اشتراک وزن با embedding ورودی، پارامتر تازه‌ای افزوده نمی‌شود.)

ب

یک لایهٔ RNN ساده با $h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-۱} + b)$ و ورودی و حالت پنهانِ هر دو با بعد ۷۶۸:

$$\underbrace{۷۶۸ \times ۷۶۸}_{W_{xh}} + \underbrace{۷۶۸ \times ۷۶۸}_{W_{hh}} + \underbrace{۷۶۸}_{b} = ۱{,}۱۷۹{,}۶۴۸ + ۷۶۸ = ۱{,}۱۸۰{,}۴۱۶$$

که بسیار کمتر از پارامترهای یک بلوک ترنسفرمر است.

ج

LSTM چهار دروازه (ورودی، فراموشی، خروجی و کاندیدای سلول) دارد و هر دروازه ساختاری همانند RNN بالا:

$$۴ \times \big(۷۶۸ \times ۷۶۸ + ۷۶۸ \times ۷۶۸ + ۷۶۸\big) = ۴ \times ۱{,}۱۸۰{,}۴۱۶ = ۴{,}۷۲۱{,}۶۶۴$$

د

کانولوشن یک‌بعدی با ۷۶۸ کانال ورودی، ۷۶۸ فیلتر و اندازهٔ کرنل ۳:

$$\underbrace{۳ \times ۷۶۸ \times ۷۶۸}_{\text{وزن}} + \underbrace{۷۶۸}_{\text{بایاس}} = ۱{,}۷۶۹{,}۴۷۲ + ۷۶۸ = ۱{,}۷۷۰{,}۲۴۰$$

ایراد اساسی این است که میدان دیدِ این لایه محلی و محدود به پنجره‌ای ۳ـتایی است؛ یعنی یک لایهٔ کانولوشن تنها وابستگیِ میانِ توکن‌های بسیار نزدیک را می‌بیند و قادر به مدل‌کردنِ مستقیمِ وابستگی‌های دوربرد در دنباله نیست. برخلاف توجه (با میدان دیدِ سراسری) و RNN/LSTM (با انتشار حالت در کل دنباله)، برای پوشش وابستگی‌های بلندمدت باید شمار زیادی لایهٔ کانولوشن روی هم انباشته شوند.