پاسخ مسئله‌ی ۱.

الف

یک MLP با یک لایهٔ پنهان و بدون تابع فعال‌سازی، در واقع یک مدل خطی روی ورودی است. اگر $x \in \mathbb{R}^d$، وزن‌های لایهٔ پنهان و خروجی به‌ترتیب $W_1 \in \mathbb{R}^{k \times d}$، $W_2 \in \mathbb{R}^{m \times k}$ باشند، آنگاه

$$\hat{y} = W_2(W_1 x) = (W_2 W_1)\, x.$$

پس تنها چیزی که روی داده اثر می‌گذارد ماتریسِ ضرب‌شدهٔ

$$M := W_2 W_1 \in \mathbb{R}^{m \times d}$$

است و مسئلهٔ یادگیری را می‌توان به‌صورتِ بهینه‌سازی روی M دید. برای بسیاری از توابع هزینهٔ رایجِ یادگیری نظارت‌شده که روی linear predictor تعریف می‌شوند (مثل کمترین مربعات و logistic / softmax cross-entropy) تابع هزینه نسبت به M یک مسئلهٔ کوژ است:

$$\min_{W_1, W_2} L(W_2 W_1) \quad \equiv \quad \min_{M} L(M).$$

حال نشان می‌دهیم گزارهٔ سؤال نادرست است (یعنی کمینهٔ محلیِ بد نداریم). فرض کنید (W_1, W_2) یک کمینهٔ محلی باشد و $M = W_2 W_1$. اگر M کمینهٔ سراسریِ مسئلهٔ کوژ روی M نباشد، آنگاه چون $L(M)$ کوژ است، یک جهت کاهشی ΔM وجود دارد به‌طوری‌که برای $\alpha > 0$ کوچک:

$$L(M + \alpha \Delta M) < L(M).$$

از طرفی تغییرات کوچکِ W_1, W_2 تغییرِ مرتبهٔ اولِ زیر را روی M ایجاد می‌کند:

$$(W_2 + \Delta W_2)(W_1 + \Delta W_1) = W_2 W_1 + \underbrace{W_2 \Delta W_1 + \Delta W_2 W_1}_{\Delta M} + O(\|\Delta W\|^2).$$

اگر W_1 سطر_تمام‌رتبه باشد، می‌توان $\Delta W_1 = 0$ و

$$\Delta W_2 := \Delta M\, W_1^{\mathsf{T}} (W_1 W_1^{\mathsf{T}})^{-1}$$

گرفت تا $\Delta W_2 W_1 = \Delta M$ و بنابراین در همسایگیٔ (W_1, W_2) یک جهت کاهشی برای L ساخته شود؛ این با کمینهٔ محلی بودن تناقض دارد. اگر W_1 سطر_تمام‌رتبه نباشد، آنگاه نقطه روی یک منیفلدِ تخت از فاکتورگیری‌ها قرار می‌گیرد (جهت‌هایی وجود دارد که M را تغییر نمی‌دهند) و چنین نقاطی کمینهٔ موضعیِ جداافتاده نیستند؛ در واقع با یک اغتشاش بسیار کوچک می‌توان به فاکتورگیری هم‌ارز (با همان M) که سطر_تمام‌رتبه است

رسید و سپس استدلال بالا را اعمال کرد. نتیجه:

در این شبکهٔ خطی (بدون فعال‌سازی)، کمینهٔ محلیِ غیرسراسری وجود ندارد و گزاره نادرست است.

ب

با وجود غیرمحدب بودن، روش‌های گرادیانی در شبکه‌های عمیق غالباً موفق‌اند چون هندسهٔ نقاط بحرانی در ابعاد بالا به نفعِ فرار از بدترین نواحی است:

- در فضاهای پربعد، «بیشتر» نقاط بحرانی از نوع saddle point هستند نه کمینهٔ محلیِ بد. یعنی هسین در آن نقاط دارای مقادیر ویژهٔ با علامت‌های مختلف است.
- اگر $H = \nabla^۲ L(\theta^\star)$ هسین در یک نقطهٔ بحرانی باشد، طیف هسین معمولاً شامل یک bulk بزرگ نزدیک به صفر و تعداد کمی outlier است؛ بنابراین بسیاری از جهت‌ها «تخت» هستند (مقادیر ویژه نزدیک صفر) و چند جهتِ محدود خمیدگی قوی دارند.
- در saddleها وجود مقدار ویژهٔ منفی یعنی یک جهتِ کاهشیِ درجهٔ دوم وجود دارد؛ الگوریتم‌هایی مثل SGD به‌خاطر نویز ذاتی مینی‌بچ یا اغتشاشات عددی، با احتمال بالا از این جهت‌ها استفاده کرده و از saddle فرار می‌کنند.
- کمینه‌های قابل‌دستیابی در شبکه‌های بزرگ اغلب «هم‌ارزش»اند (مقدار هزینه نزدیک) و به‌واسطهٔ تقارن‌ها و بیش‌پارامتری بودن، نواحی کم‌هزینه به‌صورت پهن و بعضاً به هم متصل‌اند؛ این باعث می‌شود رسیدن به یک کمینهٔ خوب آسان‌تر از گیر افتادن در کمینهٔ بد باشد.

پ

گرادیان در گام t برابر است با

$$\nabla L = \begin{bmatrix} ۱۰۰ \\ ۰/۰۱ \end{bmatrix}.$$

(۱) اگر نرخ یادگیری ثابت η باشد، اندازهٔ گام در مؤلفه‌ها به‌ترتیب

$$\Delta\theta_۱ = -۱۰۰\eta, \qquad \Delta\theta_۲ = -۰/۰۱\eta$$

می‌شود. این یک دوگانگی می‌سازد:

- اگر η را برای پایداری در راستای اول کوچک بگیریم (تا نوسان/واگرایی در راستای با شیب بزرگ رخ ندهد)، در راستای دوم گام بسیار کوچک شده و همگرایی کند می‌شود.
- اگر η را برای پیشرفت مناسب در راستای دوم بزرگ بگیریم، در راستای اول جهش بسیار بزرگ رخ می‌دهد و ممکن است از مینیمم عبور کنیم یا واگرا شویم.

این دقیقاً همان مشکل ill-conditioning (ناهم‌مقیاسی مؤلفه‌ها/خمیدگی‌ها) است.

(۲) روش‌های تطبیقی مانند RMSProp و Adam به‌جای یک η مشترک، یک مقیاس‌بندی مؤلفه‌به‌مؤلفه اعمال می‌کنند و عملاً گام را بر اساس «بزرگی گرادیان‌های گذشته» نرمال می‌کنند. به‌صورت خلاصه:

$$v_t = \rho v_{t-۱} + (۱ - \rho)\, g_t \odot g_t$$

و سپس به‌روزرسانی از فرمِ

$$\theta_{t+۱} = \theta_t - \eta \frac{g_t}{\sqrt{v_t} + \epsilon}$$

(RMSProp) یا در Adam با میانگینِ مرتبهٔ اول نیز:

$$m_t = \beta m_{t-۱} + (۱ - \beta) g_t, \qquad \theta_{t+۱} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}.$$

بنابراین این روش‌ها روی «ریشهٔ میانگین مربعات گرادیان» (برآورد لحظهٔ دوم، یعنی $g^۲$) نرمال‌سازی انجام می‌دهند و برای مؤلفهٔ بزرگ (مثل ۱۰۰) گام را کوچک‌تر و برای مؤلفهٔ کوچک (مثل ۰٫۰۱) گام نسبی را بزرگ‌تر می‌کنند.

ت

فرض کنید $p \gg n$ و شبکه تا خطای آموزش صفر آموزش داده شود. اکنون ۱۰٪ برچسب‌ها به‌صورت تصادفی برعکس و شبکه دوباره آموزش داده می‌شود.

(۱) در حالت بیش‌پارامتری‌شده، ظرفیت مدل بسیار بالاست و شبکه می‌تواند داده‌ها را «حفظ» کند. به‌طور شهودی، وقتی پارامترها بسیار بیشتر از قیود ناشی از داده‌هاست، مدل می‌تواند تابعی بسازد که روی همان n نمونه هر الگوی برچسب (حتی الگوی نویزی/تصادفی) را بازتولید کند؛ بنابراین حتی با برچسب‌های غلط نیز می‌توان به خطای آموزش صفر رسید (در عمل نیز شبکه‌های عمیق توانایی memorization دارند).

(۲) اما روی آزمون، نویز برچسب قابل‌تعمیم نیست. اگر برچسب را به‌شکل

$$y = y_{\text{signal}} + \epsilon$$

در نظر بگیریم (که ϵ نویز ناشی از برچسب‌های برعکس‌شده است)، آموزش تا خطای صفر یعنی مدل ناچار است علاوه بر سیگنال، مؤلفهٔ نویز را هم برازش کند:

$$f \approx f_{\text{signal}} + f_{\text{noise}}.$$

جزء f_{noise} روی دادهٔ آموزش کمک می‌کند خطا صفر شود، ولی چون این نویز با دادهٔ آزمون همبستگی ندارد، باعث افزایش خطای آزمون می‌شود. بیش‌پارامتری‌بودن این اثر را تشدید می‌کند چون مدل برای برازش نویز نیز آزادی کافی دارد (مرز تصمیم/تابع تقریب پیچیده‌تر می‌شود)؛ در نتیجه با وجود دقت کامل روی آموزش، تعمیم‌پذیری افت می‌کند.

پاسخ مسئله‌ی ۲.

الف

برای یک نمونه ورودی $x \in \mathbb{R}^d$ و برچسب $y \in \mathbb{R}^K$ (مثلاً one-hot)، پیش‌رو را به صورت زیر می‌نویسیم:

$$z^{(1)} = W^{(1)}x + b^{(1)}, \qquad a^{(1)} = \phi(z^{(1)}) = \mathrm{ReLU}(z^{(1)})$$
$$z^{(2)} = W^{(2)}a^{(1)} + b^{(2)}, \qquad a^{(2)} = \sigma(z^{(2)})$$
$$z^{(3)} = W^{(3)}a^{(2)} + b^{(3)}, \qquad \hat{y} = \mathrm{softmax}(z^{(3)})$$
$$L = -\sum_{k=1}^{K} y_k \log(\hat{y}_k)$$

گرادیان لایه خروجی (خاصیت softmax + cross-entropy) برابر است با:

$$\delta^{(3)} \;=\; \frac{\partial L}{\partial z^{(3)}} \;=\; \hat{y} - y$$

حال با قاعده زنجیره‌ای به عقب می‌آییم:

$$\frac{\partial L}{\partial a^{(2)}} = (W^{(3)})^\top \delta^{(3)}$$
$$\delta^{(2)} \;=\; \frac{\partial L}{\partial z^{(2)}} = \frac{\partial L}{\partial a^{(2)}} \odot \sigma'(z^{(2)}) = \left((W^{(3)})^\top \delta^{(3)}\right) \odot \left(\sigma(z^{(2)})(1 - \sigma(z^{(2)}))\right)$$
$$\frac{\partial L}{\partial a^{(1)}} = (W^{(2)})^\top \delta^{(2)}$$
$$\delta^{(1)} \;=\; \frac{\partial L}{\partial z^{(1)}} = \frac{\partial L}{\partial a^{(1)}} \odot \phi'(z^{(1)}) = \left((W^{(2)})^\top \delta^{(2)}\right) \odot \phi'(z^{(1)})$$

در اینجا مشتق ReLU برای هر مؤلفه:

$$\phi'(u) = \begin{cases} 1 & u > 0 \\ 0 & u < 0 \\ \text{انتخاب می‌شود} 1 \text{ یا } 0 \text{ مشتق تعریف نشده و معمولاً یک subgradient مانند } 0 & u = 0 \text{ در} \end{cases}$$

اکنون مشتق نسبت به وزن‌های لایه اول:

$$\frac{\partial L}{\partial W^{(1)}} = \frac{\partial L}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial W^{(1)}} = \delta^{(1)} x^\top$$

و به صورت مؤلفه‌ای:

$$\frac{\partial L}{\partial W^{(1)}_{ij}} = \delta^{(1)}_i \, x_j.$$

ب

فرض کنید برای همه نورون‌های لایه دوم:

$$a_i^{(۲)} \in \{۰/۰۱,\ ۰/۹۹\}.$$

پس برای هر مؤلفه داریم:

$$\sigma'(z_i^{(۲)}) = a_i^{(۲)}(۱ - a_i^{(۲)}) = ۰/۰۱ \times ۰/۹۹ = ۰/۰۰۹۹ \approx ۱۰^{-۲}.$$

بنابراین (با در نظر گرفتن $\|\cdot\|$ به عنوان operator norm و استفاده از نامساوی زیرضربی) داریم:

$$\begin{aligned}\|\delta^{(۲)}\| &= \left\|\left((W^{(۳)})^\top \delta^{(۳)}\right) \odot \sigma'(z^{(۲)})\right\| \ \le\ \|\sigma'(z^{(۲)})\|_\infty \, \|(W^{(۳)})^\top \delta^{(۳)}\| \\ &\le ۰/۰۰۹۹ \, \|W^{(۳)}\| \, \|\delta^{(۳)}\|.\end{aligned}$$

همچنین چون $\phi'(z^{(۱)}) \in \{۰, ۱\}$ (و در ۰ یک subgradient انتخاب می‌کنیم) داریم $\|\phi'(z^{(۱)})\|_\infty \le ۱$ و لذا:

$$\begin{aligned}\|\delta^{(۱)}\| &= \left\|\left((W^{(۲)})^\top \delta^{(۲)}\right) \odot \phi'(z^{(۱)})\right\| \le \|(W^{(۲)})^\top \delta^{(۲)}\| \le \|W^{(۲)}\| \, \|\delta^{(۲)}\| \\ &\le ۰/۰۰۹۹ \, \|W^{(۲)}\| \, \|W^{(۳)}\| \, \|\delta^{(۳)}\|.\end{aligned}$$

از طرفی

$$\frac{\partial L}{\partial W_{ij}^{(۱)}} = \delta_i^{(۱)} x_j \quad \Longrightarrow \quad \max_{i,j} \left|\frac{\partial L}{\partial W_{ij}^{(۱)}}\right| \le \|x\|_\infty \, \|\delta^{(۱)}\|_\infty \le \|x\|_\infty \, \|\delta^{(۱)}\|.$$

پس (در صورت نرمال‌بودن ورودی‌ها مثلاً $\|x\|_\infty \le ۱$):

$$\max_{i,j} \left|\frac{\partial L}{\partial W_{ij}^{(۱)}}\right| \ \le\ ۰/۰۰۹۹ \, \|W^{(۲)}\| \, \|W^{(۳)}\| \, \|\delta^{(۳)}\| \ \approx\ ۱۰^{-۲} \, \|W^{(۲)}\| \, \|W^{(۳)}\| \, \|\delta^{(۳)}\|.$$

یعنی به خاطر $\sigma'(z) = \sigma(z)(۱ - \sigma(z))$ در ناحیه اشباع، یک ضریب حدود $۱۰^{-۲}$ وارد زنجیره گرادیان می‌شود و گرادیان تقریباً دو مرتبه بزرگی کوچک‌تر می‌گردد.

پاسخ مسئله‌ی ۳.

(۱)

برای اختصار بگذارید $g_t = \nabla L(\theta_t)$ و $H_t = \nabla^۲ L(\theta_t)$. بسط تیلور مرتبه دوم حول θ_t برای جابه‌جایی Δ:

$$L(\theta_t + \Delta) \approx L(\theta_t) + \nabla L(\theta_t)^\top \Delta + \frac{۱}{۲} \Delta^\top \nabla^۲ L(\theta_t) \Delta.$$

در نزول گرادیان داریم $\Delta = \theta_{t+1} - \theta_t = -\eta g_t$، پس:

$$L(\theta_{t+1}) \approx L(\theta_t) + g_t^\top(-\eta g_t) + \frac{1}{2}(-\eta g_t)^\top H_t(-\eta g_t)$$
$$= L(\theta_t) - \eta\|g_t\|^2 + \frac{\eta^2}{2}\, g_t^\top H_t g_t.$$

(۲)

اگر بیشینه مقدار ویژه هسین در گام t برابر $\lambda_{\max}$ باشد، آنگاه به کمک کران طیفی داریم:

$$g_t^\top H_t g_t \le \lambda_{\max}\|g_t\|^2.$$

جایگذاری در رابطه قسمت (۱):

$$L(\theta_{t+1}) \le L(\theta_t) - \eta\|g_t\|^2 + \frac{\eta^2}{2}\lambda_{\max}\|g_t\|^2$$
$$= L(\theta_t) - \eta\Big(1 - \frac{\eta\lambda_{\max}}{2}\Big)\|g_t\|^2.$$

بنابراین برای تضمین کاهش تابع هزینه (برای $g_t \neq 0$) کافی است:

$$\eta\Big(1 - \frac{\eta\lambda_{\max}}{2}\Big) > 0 \quad\Longrightarrow\quad 0 < \eta < \frac{2}{\lambda_{\max}}.$$

(اگر $g_t = 0$ باشد، در همان نقطه بحرانی هستیم و کاهش لزوماً رخ نمی‌دهد.)

پاسخ مسئله‌ی ۴.

پرسش ۱. مفاهیم نظری (۴۰ نمره)

(الف) ثابت کنید یا نشان دهید که گزاره نادرست است: یک MLP با یک لایه پنهان و بدون تابع فعال‌سازی می‌تواند کمینه‌های محلی‌ای داشته باشد که کمینه سراسری نباشند.

(ب) در شبکه‌های عمیق، با وجود غیرمحدب بودن تابع هزینه، روش‌های گرادیانی اغلب در عمل موفق‌اند. این موضوع را با تکیه بر هندسه نقاط بحرانی در فضاهای پربعد و طیف هسین توضیح دهید.

(پ) به‌روزرسانی نزول گرادیان به صورت زیر است:

$$\theta_{t+۱} = \theta_t - \eta \nabla L(\theta_t).$$

فرض کنید در گام t، گرادیان برابر باشد با

$$\nabla L = \begin{bmatrix} ۱۰۰ \\ ۰/۰۱ \end{bmatrix}.$$

(۱) توضیح دهید که چرا استفاده از یک نرخ یادگیری ثابت η باعث ایجاد یک دوگانگی برای همگرایی می‌شود.

(۲) به طور خلاصه توضیح دهید که روش‌های نرخ یادگیری تطبیقی مانند Adam یا RMSProp از نظر ریاضی چگونه این مشکل را حل می‌کنند. این روش‌ها بر چه کمیتی نرمال‌سازی انجام می‌دهند؟

(ت) یک شبکه عصبی با تعداد پارامترهای بسیار بیشتر از تعداد نمونه‌ها را در نظر بگیرید، یعنی

$$p \gg n$$

و فرض کنید این شبکه روی n نمونه آموزش داده می‌شود تا به خطای آموزش صفر برسد. اکنون فرض کنید ۱۰% از برچسب‌های آموزشی به صورت تصادفی برعکس شوند و شبکه دوباره آموزش داده شود.

(۱) توضیح دهید چرا این شبکه بیش‌پارامتری‌شده، با وجود نویز در برچسب‌ها، هنوز می‌تواند به خطای آموزش صفر برسد.

(۲) با وجود دقت کامل روی دادهٔ آموزش، خطای آزمون به طور قابل توجهی افزایش می‌یابد. این موضوع را با استفاده از مفهوم برازش سیگنال در برابر نویز و این که بیش‌پارامتری‌بودن چگونه بر چیزی که مدل یاد می‌گیرد اثر می‌گذارد، توضیح دهید.

پرسش ۲. پس‌انتشار و عبور گرادیان (۳۵ نمره)

یک MLP با ساختار زیر را در نظر بگیرید:

ورودی:	d
لایه پنهان اول:	$h_۱$ نورون با تابع فعال‌سازی ReLU
لایه پنهان دوم:	$h_۲$ نورون با تابع فعال‌سازی sigmoid
لایه خروجی:	K نورون با تابع فعال‌سازی softmax

تابع هزینه نیز cross-entropy است.

(الف) مشتق

$$\frac{\partial L}{\partial W^{(۱)}}$$

را با استفاده از پس‌انتشار به دست آورید. همه مراحل قاعده زنجیره‌ای را نشان دهید و به نامشتق‌پذیر بودن ReLU در صفر اشاره کنید.

(ب) فرض کنید همه فعال‌سازی‌های لایه پنهان دوم در ناحیه اشباع باشند، یعنی

$$a_i^{(۲)} \in \{۰/۰۱, ۰/۹۹\}.$$

بیشینه قدر مطلق

$$\frac{\partial L}{\partial W_{ij}^{(۱)}}$$

را بر حسب $\|W^{(۳)}\|$، $\|W^{(۲)}\|$ و $\|\delta^{(۳)}\|$ به دست آورید. نشان دهید که چگونه رابطه

$$\sigma'(z) = \sigma(z)(۱ - \sigma(z))$$

باعث می‌شود گرادیان تقریباً دو مرتبه بزرگی کوچک شود.

پرسش ۳. مبانی نظری بهینه‌سازی (۲۵ نمره)

برای نزول گرادیان

$$\theta_{t+۱} = \theta_t - \eta \nabla L(\theta_t)$$

داریم:

(۱) بسط تیلور مرتبه دوم $L(\theta_{t+۱})$ را حول θ_t بنویسید.

(۲) شرطی روی η به دست آورید که کاهش تابع هزینه را تضمین کند، در حالتی که بیشینه مقدار ویژه هسین برابر $\lambda_{\max}$ است.