پاسخ مسئله‌ی ۱.

الف

۱) دو دلیل اصلی:

- Convolutionها با اشتراک وزن و اتصال محلی تعداد پارامترها را به‌شدت کاهش می‌دهند و از بیش‌برازش جلوگیری می‌کنند.
- ساختار مکانی تصویر را حفظ می‌کنند و خاصیت جابه‌جایی‌ـ هموردا بودن دارند، پس استخراج ویژگی‌های محلی و سلسله‌مراتبی بهتر انجام می‌شود.

۲) اندازه میدان دید با کرنل ۴ × ۴ و stride۱ =:

$$r_۱ = ۴$$
$$r_۲ = r_۱ + (۴ - ۱) = ۷$$
$$r_۳ = r_۲ + (۴ - ۱) = ۱۰$$

پس هر نورون خروجی لایه سوم ناحیه‌ای به اندازه ۱۰ × ۱۰ از تصویر ورودی را می‌بیند.

ب

Inception ورودی را به چند شاخه با کرنل‌های مختلف می‌فرستد و خروجی‌ها را concatenate می‌کند؛ برای کنترل هزینه محاسباتی معمولاً از 1×1 به‌عنوان bottleneck استفاده می‌شود. Residual یک مسیر میان‌بر دارد و خروجی را به‌صورت $y = x + F(x)$ می‌سازد که عبور گرادیان را آسان و عمق شبکه را قابل افزایش می‌کند. یک Inception ساده فقط در صورتی شبیه Residual می‌شود که شاخه هویت اضافه و عمل جمع جایگزین الحاق شود. اگر تعداد کانال‌های ورودی و خروجی برابر نباشد، برای تطبیق ابعاد در مسیر میان‌بر به کانولوشن 1×1 نیاز داریم.

پ

نوآوری اصلی Faster R-CNN، استفاده از RPN برای تولید ناحیه‌های پیشنهادی روی همان نقشه ویژگی و حذف Selective Search است؛ بنابراین محاسبات به‌اشتراک گذاشته و سرعت بیشتر می‌شود. Bounding Box Regression با پیش‌بینی آفست‌های (t_x, t_y, t_w, t_h) نسبت به anchor انجام می‌شود:

$$x = x_a + t_x w_a, \quad y = y_a + t_y h_a$$
$$w = w_a e^{t_w}, \quad h = h_a e^{t_h}$$

و معمولاً از Smooth L1 برای خطا استفاده می‌شود.

ت

۱) مدل فقط از آخرین حالت نهان Unidirectional RNN استفاده می‌کند؛ بنابراین اطلاعات کل توالی در یک بردار فشرده می‌شود و نشانه‌های منفی متعدد (به‌ویژه نزدیک انتها مثل ترافیک خسته‌کننده) غالب می‌مانند، ضمن آن‌که مدل توجه و تفکیک «فیلم» از «شام» ندارد. پس خروجی منفی طبیعی است.

۲) برای رفتار جمع تجمعی، بایاس دروازه فراموشی را بزرگ و مثبت می‌گذاریم تا $f_t \approx ۱$ و بایاس دروازه ورودی را نیز مثبت می‌کنیم تا $i_t \approx ۱$؛ در این صورت:

$$c_t \approx c_{t-۱} + \tilde{c}_t$$

تابع tanh برای کاندید حافظه دامنه را محدود می‌کند و جمع را اشباع می‌سازد؛ اگر جمع واقعی و نامحدود مدنظر است، تابع خطی (یا ReLU با کنترل مقادیر) مناسب‌تر است.

پاسخ مسئله‌ی ۲.

برای خروجی کانولوشن داریم:

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + ۲P - K}{S} \right\rfloor + ۱, \quad W_{\text{out}} = \left\lfloor \frac{W_{\text{in}} + ۲P - K}{S} \right\rfloor + ۱$$

در upsampling طول و عرض دو برابر می‌شود و در concatenation تعداد کانال‌ها جمع می‌شود. با ورودی $[۱۰, ۱, ۳۲, ۳۲]$ خواهیم داشت:

a: $۳۲ \to ۳۲ \Rightarrow P = ۰,\ S = ۱,\ [۱۰, ۱۶, ۳۲, ۳۲]$

b: $\left\lfloor \frac{۳۲ + ۲(۱) - ۳}{۲} \right\rfloor + ۱ = ۱۶ \Rightarrow [۱۰, ۳۲, ۱۶, ۱۶]$

c: $\left\lfloor \frac{۱۶ + ۲(۱) - ۳}{۲} \right\rfloor + ۱ = ۸ \Rightarrow [۱۰, ۱۲۸, ۸, ۸]$

d: $\left\lfloor \frac{۸ + ۲(۱) - ۳}{۱} \right\rfloor + ۱ = ۸ \Rightarrow [۱۰, ۱۶, ۸, ۸]$

e: $\left\lfloor \frac{۱۶ + ۲(۱) - ۳}{۱} \right\rfloor + ۱ = ۱۶ \Rightarrow [۱۰, ۸, ۱۶, ۱۶]$

پس جدول کامل به صورت زیر است:

لایه	شکل خروجی	padding	stride	اندازه فیلتر
a	$[۱۰, ۱۶, ۳۲, ۳۲]$	۰	۱	۱×۱
b	$[۱۰, ۳۲, ۱۶, ۱۶]$	۱	۲	۳×۳
c	$[۱۰, ۱۲۸, ۸, ۸]$	۱	۲	۳×۳
d	$[۱۰, ۱۶, ۸, ۸]$	۱	۱	۳×۳
e	$[۱۰, ۸, ۱۶, ۱۶]$	۱	۱	۳×۳
f	$[۱۰, ۱, ۳۲, ۳۲]$	۰	۱	۱×۱

پاسخ مسئله‌ی ۳.

الف

رابطه بازگشتی را به صورت $u_m = \theta h_{m-۱} + x_m$ و $h_m = \sigma(u_m)$ می‌نویسیم. آنگاه

$$\frac{\partial h_m}{\partial h_{m-۱}} = \sigma'(u_m)\,\theta$$

پس برای $k \geq ۱$:

$$\frac{\partial h_{m+k}}{\partial h_m} = \prod_{t=۱}^{k} \Big(\theta\,\sigma'(u_{m+t})\Big)$$

با توجه به ویژگی سیگموید داریم $۰ < \sigma'(u) \leq \frac{۱}{۴}$، بنابراین

$$\left|\frac{\partial h_{m+k}}{\partial h_m}\right| \leq \left(\frac{|\theta|}{۴}\right)^k \xrightarrow[k\to\infty]{} ۰$$

و برای $|\theta| < ۱$ گرادیان به صفر میل می‌کند.

ب

برای سادگی

$$u_i = B_i x[n] + A_i c[n-۱], \quad i = \sigma(u_i)$$
$$u_f = B_f x[n] + A_f c[n-۱], \quad f = \sigma(u_f)$$
$$u_c = B_c x[n] + A_c c[n-۱], \quad \tilde{c} = g(u_c)$$

و مؤلفه jام:

$$c_j[n] = f_j[n]\; c_j[n-۱] + i_j[n]\; \tilde{c}_j[n]$$

اکنون مشتق نسبت به $c_k[n-۱]$:

$$\frac{\partial c_j[n]}{\partial c_k[n-۱]} = f_j[n]\delta_{jk} + c_j[n-۱]\;\sigma'(u_{f,j})\,(A_f)_{jk} + \tilde{c}_j[n]\;\sigma'(u_{i,j})\,(A_i)_{jk} + i_j[n]\;g'(u_{c,j})\,(A_c)_{jk}$$

که در آن δ_{jk} دلتای کرونکر است و می‌توان $\sigma'(u) = \sigma(u)(۱-\sigma(u))$ را جایگذاری کرد.