تمرین چهارم | بخش نظری | ۴۰۴۲۰۳۵۰۹

پرسش ۱: یادگیری مدل انرژی با Score Matching (۲۰ نمره)

فرض کنید از چگالی ناشناختهٔ $p_{\text{data}}(x) > 0$ روی $\mathbb{R}^d$ نمونه داریم و می‌خواهیم مدل زیر را آموزش دهیم:

$$p_\theta(x) = \frac{\exp(-E_\theta(x))}{Z(\theta)}, \qquad Z(\theta) = \int_{\mathbb{R}^d} \exp(-E_\theta(u))\, du,$$
$$s_\theta(x) = \nabla_x \log p_\theta(x).$$

محاسبهٔ $Z(\theta)$ ممکن است دشوار باشد. هدف اولیهٔ Score Matching را به صورت زیر تعریف می‌کنیم:

$$\mathcal{L}(\theta) = \frac{1}{2}\, \mathbb{E}_{x\sim p_{\text{data}}} \left[\| s_\theta(x) - \nabla_x \log p_{\text{data}}(x) \|_2^2 \right].$$

فرض کنید توابع به اندازهٔ کافی هموارند، تمام امیدهای مورد استفاده متناهی‌اند و جمله‌های مرزی در انتگرال‌گیری جزءبه‌جزء صفر می‌شوند.

الف) (۴ نمره) $s_\theta(x)$ را برحسب $E_\theta(x)$ به دست آورید. چرا وابستگی Z به θ در این محاسبه مشکل‌ساز نیست؟ آیا هنگام محاسبهٔ $\nabla_\theta \log p_\theta(x)$ نیز می‌توان جملهٔ مربوط به $Z(\theta)$ را حذف کرد؟

ب) (۸ نمره) هدف اولیه هنوز به $\nabla_x \log p_{\text{data}}(x)$ وابسته است که در اختیار نداریم. ابتدا مربع را بسط دهید؛ سپس با انتگرال‌گیری جزءبه‌جزء نشان دهید که می‌توان هزینه‌ای با همان کمینه‌سازها به دست آورد که فقط شامل $s_\theta(x)$ و $\operatorname{div} s_\theta(x)$ باشد. این هزینه را برحسب E_θ نیز بنویسید و نسخهٔ تجربی آن را برای نمونه‌های $x^{(1)}, \dots, x^{(n)}$ مشخص کنید.

راهنمایی: جملهٔ مختلط را به مجموع عبارت‌های $\int s_{\theta,i}(x)\, \partial_{x_i} p_{\text{data}}(x)\, dx$ تبدیل کنید. از تعاریف زیر استفاده کنید:

$$\operatorname{div} s_\theta(x) = \sum_{i=1}^{d} \frac{\partial s_{\theta,i}(x)}{\partial x_i}, \qquad \Delta E_\theta(x) = \sum_{i=1}^{d} \frac{\partial^2 E_\theta(x)}{\partial x_i^2}.$$

ج) (۸ نمره) اکنون $d = 1$ و مدل انرژی زیر را در نظر بگیرید:

$$E_\theta(x) = \frac{\theta}{2} x^2 + \frac{\lambda}{4} x^4, \qquad \theta \in \mathbb{R}, \quad \lambda > 0,$$
$$m_k = \frac{1}{n} \sum_{j=1}^{n} \big(x^{(j)}\big)^k, \qquad k \in \{2, 4, 6\}, \quad m_2 > 0.$$

λ معلوم است و فقط θ آموزش داده می‌شود. با استفاده از بخش قبل، هزینهٔ تجربی و کمینه‌ساز یکتای $\widehat{\theta}(\lambda)$ را به دست آورید.

سپس داده‌ها را ثابت نگه دارید و فرض کنید برای هر مقدار λ، مدل دوباره برازش می‌شود. آستانهٔ تغییر چگالی برازش‌شده از تک‌قله‌ای به دوقله‌ای و مکان قله‌ها را مشخص کنید. آیا منفی‌شدن $\widehat{\theta}$ باعث غیرقابل‌نرمال‌سازی‌شدن مدل می‌شود؟

پاسخ‌نامهٔ پرسش ۱

الف)

$$s_\theta(x) = \nabla_x \big[-E_\theta(x) - \log Z(\theta)\big] = -\nabla_x E_\theta(x),$$
$$\nabla_x \log Z(\theta) = ۰,$$
$$\nabla_\theta \log p_\theta(x) = -\nabla_\theta E_\theta(x) - \nabla_\theta \log Z(\theta).$$

Z نسبت به x ثابت است؛ اما مشتق آن نسبت به θ عموماً صفر نیست.

ب)

با انتگرال‌گیری جزءبه‌جزء:

$$\begin{aligned}\mathbb{E}_{p_{\text{data}}}\left[s_\theta^\top \nabla_x \log p_{\text{data}}\right] &= \sum_{i=۱}^{d} \int_{\mathbb{R}^d} s_{\theta,i}(x)\, \partial_{x_i} p_{\text{data}}(x)\, dx \\ &= -\sum_{i=۱}^{d} \int_{\mathbb{R}^d} p_{\text{data}}(x)\, \partial_{x_i} s_{\theta,i}(x)\, dx \\ &= -\mathbb{E}_{p_{\text{data}}}\left[\operatorname{div} s_\theta(x)\right].\end{aligned}$$

بنابراین:

$$\mathcal{L}(\theta) = \mathbb{E}_{p_{\text{data}}}\left[\frac{۱}{۲}\|s_\theta(x)\|_۲^۲ + \operatorname{div} s_\theta(x)\right] + C,$$
$$C = \frac{۱}{۲}\mathbb{E}_{p_{\text{data}}}\left[\|\nabla_x \log p_{\text{data}}(x)\|_۲^۲\right], \qquad \nabla_\theta C = ۰,$$
$$\mathcal{J}(\theta) = \mathbb{E}_{p_{\text{data}}}\left[\frac{۱}{۲}\|\nabla_x E_\theta(x)\|_۲^۲ - \Delta E_\theta(x)\right],$$
$$\widehat{\mathcal{J}}(\theta) = \frac{۱}{n}\sum_{j=۱}^{n}\left[\frac{۱}{۲}\|\nabla_x E_\theta(x^{(j)})\|_۲^۲ - \Delta E_\theta(x^{(j)})\right].$$

$\mathcal{J}$ با $\mathcal{L}$ کمینه‌سازهای یکسان دارد؛ $\widehat{\mathcal{J}}$ تقریب نمونه‌ای آن است.

ج)

$$
\begin{aligned}
s_\theta(x) &= -\theta x - \lambda x^{۳}, \qquad s'_\theta(x) = -\theta - ۳\lambda x^{۲},\\
\widehat{\mathcal{J}}(\theta) &= \frac{\theta^{۲}}{۲} m_{۲} + \theta\lambda m_{۴} + \frac{\lambda^{۲}}{۲} m_{۶} - \theta - ۳\lambda m_{۲},\\
\frac{d\widehat{\mathcal{J}}}{d\theta} &= \theta m_{۲} + \lambda m_{۴} - ۱, \qquad \frac{d^{۲}\widehat{\mathcal{J}}}{d\theta^{۲}} = m_{۲} > ۰,\\
\boxed{\widehat{\theta}(\lambda)} &= \boxed{\frac{۱ - \lambda m_{۴}}{m_{۲}}}.
\end{aligned}
$$

قله‌های چگالی، کمینه‌های انرژی‌اند:

$$
\begin{aligned}
E'_{\widehat{\theta}}(x) &= x\big(\widehat{\theta} + \lambda x^{۲}\big),\\
\lambda_{\mathrm{c}} &= \frac{۱}{m_{۴}},\\
\arg\max_x p_{\widehat{\theta}}(x) &= \begin{cases} \{۰\}, & ۰ < \lambda \le \lambda_{\mathrm{c}},\\ \left\{-\sqrt{\dfrac{\lambda m_{۴} - ۱}{\lambda m_{۲}}}, \sqrt{\dfrac{\lambda m_{۴} - ۱}{\lambda m_{۲}}}\right\}, & \lambda > \lambda_{\mathrm{c}}. \end{cases}\\
\frac{d\widehat{\theta}}{d\lambda} &= -\frac{m_{۴}}{m_{۲}} < ۰.
\end{aligned}
$$

در آستانه، انرژی برابر $\lambda x^{۴}/۴$ است و همچنان فقط یک کمینه در صفر دارد. منفی‌شدن $\widehat{\theta}$ مانع نرمال‌سازی نیست:

$$
\lim_{|x|\to\infty} \frac{E_\theta(x)}{x^{۴}} = \frac{\lambda}{۴} > ۰ \quad \Longrightarrow \quad ۰ < Z(\theta) < \infty \qquad (\theta \in \mathbb{R}).
$$

پرسش ۲: Denoising Score Matching چه چیزی را یاد می‌گیرد؟ (۲۰ نمره)

برای آموزش شبکهٔ امتیاز، به دادهٔ پاک $X \in \mathbb{R}^d$ نویز اضافه می‌کنیم:

$$
\begin{aligned}
Y &= X + \sigma\varepsilon, \qquad \varepsilon \sim \mathcal{N}(۰, I_d), \qquad \varepsilon \perp X, \quad \sigma > ۰,\\
q_\sigma(y \mid x) &= \frac{۱}{(۲\pi\sigma^{۲})^{d/۲}} \exp\left(-\frac{\|y - x\|_{۲}^{۲}}{۲\sigma^{۲}}\right),\\
q_\sigma(y) &= \mathbb{E}_X\left[q_\sigma(y \mid X)\right], \qquad s_\sigma(y) = \nabla_y \log q_\sigma(y).
\end{aligned}
$$

در این پرسش σ ثابت است. فرض کنید مشتق‌گیری زیر امید مجاز است، امیدهای مورد استفاده متناهی‌اند و شبکه ظرفیت کافی برای نمایش تابع بهینه دارد.

الف) (۶ نمره) ابتدا $h_\sigma(y,x) = \nabla_y \log q_\sigma(y \mid x)$ را محاسبه کنید. سپس نشان دهید:

$$s_\sigma(y) = \mathbb{E}\left[h_\sigma(Y,X) \mid Y=y\right] = \frac{\mathbb{E}[X \mid Y=y] - y}{\sigma^۲}.$$

راهنمایی: از $\nabla_y q_\sigma(y) = \mathbb{E}_X[\nabla_y q_\sigma(y \mid X)]$ شروع کنید و وزن‌های حاصل را به صورت توزیع شرطی $X \mid Y=y$ تفسیر کنید.

ب) (۸ نمره) شبکهٔ $s_\theta(y,\sigma)$ را با هزینهٔ زیر آموزش می‌دهیم:

$$\mathcal{L}_D(\theta) = \frac{۱}{۲}\mathbb{E}_{X,Y}\left[\|s_\theta(Y,\sigma) - h_\sigma(Y,X)\|_۲^۲\right].$$

با استفاده از بخش قبل نشان دهید:

$$\mathcal{L}_D(\theta) = \frac{۱}{۲}\mathbb{E}_Y\left[\|s_\theta(Y,\sigma) - s_\sigma(Y)\|_۲^۲\right] + C_\sigma,$$

که C_σ مستقل از θ است. در نتیجه، تابع بهینهٔ شبکه چیست؟

اکنون پارامترسازی $s_\theta(y,\sigma) = -\varepsilon_\theta(y,\sigma)/\sigma$ را در نظر بگیرید. هزینه را برحسب خطای پیش‌بینی نویز بنویسید و $\varepsilon^*(y,\sigma)$ را مشخص کنید. آیا برای هر زوج آموزشی (x,y) می‌توان $s_\sigma(y) = -\varepsilon/\sigma$ را یک تساوی دقیق دانست؟

راهنمایی: اختلاف شبکه و هدف را به دو جمله، با واسطهٔ $s_\sigma(Y)$، بشکنید و امید شرطی جملهٔ مختلط را بررسی کنید.

ج) (۶ نمره) برای تحلیل اثر شدت نویز، فرض کنید $d = ۱$ و دادهٔ پاک فقط دو مقدار دارد:

$$\mathbb{P}(X=a) = \mathbb{P}(X=-a) = \frac{۱}{۲}, \qquad a > ۰,$$
$$q_\sigma(y) = \frac{۱}{۲\sqrt{۲\pi}\sigma}\left[\exp\left(-\frac{(y-a)^۲}{۲\sigma^۲}\right) + \exp\left(-\frac{(y+a)^۲}{۲\sigma^۲}\right)\right].$$

$s_\sigma(y)$ و $s'_\sigma(۰)$ را به دست آورید. برای دو حالت $\sigma < a$ و $\sigma > a$، مشخص کنید صفر کمینهٔ محلی چگالی است یا بیشینهٔ محلی، و میدان امتیاز در نزدیکی صفر به کدام جهت اشاره می‌کند. آیا صفرشدن امتیاز الزاماً به معنای قرارداشتن در قلهٔ چگالی است؟

راهنمایی: از $e^u + e^{-u} = ۲\cosh u$ و $\frac{d}{du}\log\cosh u = \tanh u$ استفاده کنید.

پاسخ‌نامهٔ پرسش ۲

الف)

$$h_\sigma(y,x) = -\frac{y-x}{\sigma^۲},$$
$$\begin{aligned} s_\sigma(y) &= \frac{\mathbb{E}_X\left[q_\sigma(y \mid X) h_\sigma(y,X)\right]}{q_\sigma(y)} \\ &= \mathbb{E}\left[h_\sigma(y,X) \mid Y=y\right] \\ &= \boxed{\frac{\mathbb{E}[X \mid Y=y] - y}{\sigma^۲}}. \end{aligned}$$

ب)

$$
\begin{aligned}
\mathbb{E}\left[h_\sigma(Y,X) - s_\sigma(Y) \mid Y\right] &= ۰, \\
\mathbb{E}\left[\left(s_\theta(Y,\sigma) - s_\sigma(Y)\right)^\top \left(s_\sigma(Y) - h_\sigma(Y,X)\right)\right] &= ۰, \\
\mathcal{L}_D(\theta) &= \frac{۱}{۲}\mathbb{E}\left[\|s_\theta(Y,\sigma) - s_\sigma(Y)\|_۲^۲\right] + C_\sigma, \\
C_\sigma &= \frac{۱}{۲}\mathbb{E}\left[\|h_\sigma(Y,X) - s_\sigma(Y)\|_۲^۲\right], \\
s^*(y,\sigma) &= s_\sigma(y) = \nabla_y \log q_\sigma(y).
\end{aligned}
$$

این برابری برای تابع بهینه، تقریباً همه‌جا نسبت به q_σ برقرار است.

با پارامترسازی پیش‌بینی نویز:

$$
\begin{aligned}
h_\sigma(Y,X) &= -\frac{\varepsilon}{\sigma}, \\
\mathcal{L}_D(\theta) &= \frac{۱}{۲\sigma^۲}\mathbb{E}_{X,\varepsilon}\left[\|\varepsilon_\theta(X + \sigma\varepsilon, \sigma) - \varepsilon\|_۲^۲\right], \\
\varepsilon^*(y,\sigma) &= \mathbb{E}[\varepsilon \mid Y = y] = -\sigma s_\sigma(y).
\end{aligned}
$$

$-\varepsilon/\sigma$ هدف یک زوج آموزشی است؛ $s_\sigma(y)$ میانگین شرطی این هدف است. این دو عموماً برای یک زوج منفرد برابر نیستند.

ج)

$$
\begin{aligned}
q_\sigma(y) &= \frac{۱}{\sqrt{۲\pi}\sigma}\exp\left(-\frac{y^۲ + a^۲}{۲\sigma^۲}\right)\cosh\left(\frac{ay}{\sigma^۲}\right), \\
\boxed{s_\sigma(y)} &= \boxed{-\frac{y}{\sigma^۲} + \frac{a}{\sigma^۲}\tanh\left(\frac{ay}{\sigma^۲}\right)}, \\
s'_\sigma(y) &= -\frac{۱}{\sigma^۲} + \frac{a^۲}{\sigma^۴}\left[۱ - \tanh^۲\left(\frac{ay}{\sigma^۲}\right)\right], \\
s_\sigma(۰) &= ۰, \qquad s'_\sigma(۰) = \frac{a^۲ - \sigma^۲}{\sigma^۴}, \\
\frac{q''_\sigma(۰)}{q_\sigma(۰)} &= s'_\sigma(۰) + s_\sigma(۰)^۲ = \frac{a^۲ - \sigma^۲}{\sigma^۴}.
\end{aligned}
$$

برای $\sigma < a$، صفر کمینهٔ محلی چگالی است و میدان امتیاز در نزدیکی آن از صفر دور می‌شود. برای $\sigma > a$، صفر بیشینهٔ محلی است و میدان به سمت صفر اشاره می‌کند. پس افزایش نویز می‌تواند مرکزِ میان دو خوشه را به یک قله تبدیل کند؛ $s_\sigma(۰) = ۰$ به‌تنهایی میان قله و دره تمایز نمی‌گذارد.